

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN – TIN



BÁO CÁO BÀI TẬP NHÓM
HỌC PHẦN HỆ HỖ TRỢ QUYẾT ĐỊNH

**HỆ HỖ TRỢ QUYẾT ĐỊNH ỨNG PHÓ THẢM
HỌA**

TỪ VĂN BẢN VÀ HÌNH ẢNH MẠNG XÃ HỘI

A Multimodal Decision Support System for Disaster Response

Giảng viên: TS. Lê Hải Hà

Nhóm thực hiện: Nhóm 29

Thành viên 1: Đoàn Danh Long – 20237354

Thành viên 2: Vũ Quang Vinh – 20237408

Thành viên 3: Nguyễn Đăng Đức – 20237312

Thành viên 4: Nguyễn Tuấn Anh – 20237293

Học kỳ: 2025.2

Hà Nội, tháng 6 năm 2026

Bảng phân công công việc

Thông tin còn thiếu được đánh dấu rõ; báo cáo không tự gán danh tính hoặc phần việc.

Phân công và tỷ lệ đóng góp của các thành viên Nhóm 29

Thành viên	MSSV	Công việc chính	Tỷ lệ đóng góp
Đoàn Danh Long	20237354	Chưa cung cấp	Chưa cung cấp
Vũ Quang Vinh	20237408	Chưa cung cấp	Chưa cung cấp
Nguyễn Đăng Đức	20237312	Chưa cung cấp	Chưa cung cấp
Nguyễn Tuấn Anh	20237293	Chưa cung cấp	Chưa cung cấp

Lời mở đầu

Trong thảm họa, mạng xã hội cung cấp thông tin hiện trường nhanh nhưng đồng thời tạo ra khối lượng dữ liệu lớn, nhiễu và khó xác minh. Một hệ thống hữu ích không thể dừng ở việc gán nhãn bài đăng; nó phải chuyển bằng chứng từ dữ liệu thành quyết định có thể kiểm tra: bài nào cần chú ý, mức độ ưu tiên, đội nào tiếp nhận và trường hợp nào phải có người duyệt.

Báo cáo trình bày quy trình xây dựng một DSS đa phương thức trên CrisisMMD v2.0, từ kiểm tra dữ liệu, EDA train-only, so sánh sáu thuật toán, late fusion, đến Risk Score, routing và dashboard. Mọi kết quả mô hình được chọn trên dev và báo cáo trên test đã loại ảnh/text trùng với split trước. Những phần không có ground truth, đặc biệt Risk Score và Priority, được công khai là chính sách heuristic và được kiểm tra bằng scenario/sensitivity thay vì tuyên bố tối ưu thống kê.

Lời cảm ơn

Nhóm 29 xin trân trọng cảm ơn TS. Lê Hải Hà đã cung cấp nền tảng kiến thức và định hướng cho học phần Hệ hỗ trợ quyết định. Nhóm đồng thời ghi nhận bộ dữ liệu mở CrisisMMD của QCRI, các thư viện mã nguồn mở và những công cụ hỗ trợ đã được liệt kê trong phụ lục.

Tóm tắt

Báo cáo xây dựng một DSS đa phương thức giúp trung tâm điều phối cứu nạn lụt, ưu tiên và phân luồng thông tin từ mạng xã hội. Dữ liệu sử dụng là CrisisMMD v2.0, gồm 18.082 cặp tweet–ảnh. Sáu thuật toán cổ điển được so sánh trên TF–IDF và đặc trưng ảnh 512 chiều do mô hình CLIP tiền huấn luyện trích xuất. Quá trình kiểm tra dữ liệu phát hiện 2.649 nhãn informative sẽ sai nếu suy diễn từ humanitarian và 305 hàng ảnh trùng theo SHA-256; hệ thống vì vậy ghép nhãn informative chính thức và đánh giá trên 2.189 mẫu dev, 2.169 mẫu test leakage-safe. Với informative, Late Fusion đạt Accuracy 0,6948, F1 0,8025 và F2 0,9045; tuy nhiên baseline luôn dự báo informative đã đạt F2 0,8939, nên F2 không được diễn giải độc lập. Với tám lớp humanitarian, fusion đạt Macro-F1 0,4005 so với majority baseline 0,0686. Hậu kiểm robust không tune lại đạt F2 0,9016 và Macro-F1 0,3908; bootstrap/event analysis cho thấy lợi thế humanitarian rõ nhưng lớp hiếm và domain shift vẫn là giới hạn. Tầng quyết định cung cấp Risk Score, Priority, routing và Manual Review; các trọng số ưu tiên được xem là chính sách minh bạch, không phải ground truth học được.

Từ khóa: DSS, CrisisMMD, Text Mining, CLIP, Late Fusion, Human-in-the-loop.

Bảng thuật ngữ viết tắt

Thuật ngữ	Giải nghĩa
DSS	Decision Support System – Hệ hỗ trợ quyết định.
TF-IDF	Term Frequency–Inverse Document Frequency.
CLIP	Contrastive Language–Image Pre-training; dùng để trích đặc trưng ảnh.
EDA	Exploratory Data Analysis – Phân tích khám phá dữ liệu.
F2	Chỉ số F-score nhấn mạnh Recall hơn Precision.
Macro-F1	F1 trung bình đều trên các lớp, phù hợp dữ liệu mất cân bằng.
Embedding	Vector số biểu diễn nội dung của văn bản hoặc ảnh.
Late Fusion	Kết hợp xác suất của các mô hình sau khi từng nhánh đã dự báo.
Calibration	Chuyển score của mô hình thành xác suất có thể diễn giải tốt hơn.
MCC	Matthews Correlation Coefficient; đo tương quan của dự báo nhị phân.
Human-in-the-loop	Thiết kế giữ con người tại các điểm quyết định rủi ro.
SHA-256	Hàm băm dùng phát hiện file ảnh giống hệt nhau.

Mục lục

Bảng phân công công việc	i
Lời mở đầu	ii
Lời cảm ơn	iii
Tóm tắt	iv
Bảng thuật ngữ viết tắt	v
1 Giới thiệu bài toán	1
1.1 Bối cảnh thực tế	1
1.2 Bài toán ra quyết định	1
1.3 Người sử dụng và nhu cầu thông tin	2
1.4 Ví dụ xuyên suốt	2
1.5 Mục tiêu của dự án	3
1.6 Câu hỏi nghiên cứu	4
1.7 Phạm vi và giới hạn	4
1.8 Cấu trúc báo cáo	4
2 Nền tảng hệ hỗ trợ quyết định	5
2.1 Từ dữ liệu đến hành động	5
2.2 Khái niệm hệ hỗ trợ quyết định	5
2.3 Mức độ cấu trúc của quyết định	6
2.4 Chu trình ra quyết định	6
2.5 Ba nhóm năng lực của hệ thống	6
2.5.1 Phân tích mô tả và chẩn đoán	6
2.5.2 Phân tích dự báo	7
2.5.3 Phân tích định hướng hành động	7
2.6 Kiến trúc DSS của dự án	7
2.7 Vai trò của con người trong hệ thống	8
2.8 Nguyên tắc phân biệt bằng chứng và chính sách	8
3 Dữ liệu, tiền xử lý và biểu diễn đặc trưng	9
3.1 Vai trò của dữ liệu trong bài toán	9
3.2 Bộ dữ liệu CrisisMMD v2.0	9

3.2.1	Nguồn, đơn vị quan sát và phạm vi	9
3.2.2	Hai nhiệm vụ dự báo	10
3.3	Hợp nhất annotation và bảo toàn split	10
3.3.1	Vấn đề khác partition giữa hai task	10
3.3.2	Kích thước và phân bố	11
3.4	Kiểm soát trùng lặp và rò rỉ dữ liệu	11
3.4.1	Rò rỉ dữ liệu là gì?	12
3.4.2	Hai mặt nạ đánh giá	12
3.5	Tiền xử lý và feature engineering văn bản	12
3.5.1	Làm sạch tweet	12
3.5.2	TF-IDF	13
3.6	Tiền xử lý và feature engineering ảnh	14
3.6.1	Từ pixel đến vector đặc trưng	14
3.6.2	Quy trình trích xuất thực tế	14
3.6.3	Lý do giữ CLIP cố định	15
3.7	Tổng hợp đặc trưng đầu vào mô hình	16
4	Phân tích khám phá dữ liệu	17
4.1	Mục đích và nguyên tắc EDA	17
4.2	Phân bố nhãn và hệ quả	17
4.3	Khác biệt theo sự kiện	18
4.4	Khám phá văn bản	18
4.5	K-Means cho khám phá chủ đề	19
4.5.1	Khái niệm và hàm mục tiêu	19
4.5.2	Silhouette và kết quả	19
4.6	Apriori và luật kết hợp	20
4.6.1	Từ tweet thành transaction	20
4.6.2	Kết quả và cách diễn giải	21
4.7	EDA ảnh và không gian embedding	21
4.8	Bất đồng đa phương thức	22
4.9	Từ bằng chứng EDA đến quyết định thiết kế	23
5	Mô hình dự báo, hợp nhất và chính sách DSS	24
5.1	Bài toán học có giám sát	24
5.2	Sáu thuật toán phân lớp	24
5.2.1	Logistic Regression	24
5.2.2	Decision Tree	24
5.2.3	Naive Bayes	25
5.2.4	k-Nearest Neighbors	25
5.2.5	Support Vector Machine	25

5.2.6	Random Forest	26
5.3	Mất cân bằng lớp và trọng số	26
5.4	Các chỉ số đánh giá	26
5.4.1	Nhị phân informative	26
5.4.2	Tám lớp humanitarian	27
5.5	Thiết kế thực nghiệm	27
5.5.1	Vai trò của train, dev và test	27
5.6	Vòng 1: so sánh sáu thuật toán	28
5.7	Vòng 2: tuning classifier	29
5.8	Vòng 3: xác suất, Late Fusion và conflict	29
5.8.1	Căn chỉnh xác suất	29
5.8.2	Conflict score và Manual Review	30
5.9	Kết quả cuối trên canonical test	30
5.9.1	Informative và đối chứng hằng	30
5.9.2	Humanitarian tám lớp	31
5.10	Hậu kiểm robustness và độ bất định	31
5.11	Từ dự báo đến chính sách DSS	32
5.11.1	Risk Score	32
5.11.2	Routing, override và sensitivity	33
6	Diễn giải kết quả và khuyến nghị	34
6.1	Kết quả end-to-end	34
6.2	Ý nghĩa của kết quả mô hình	34
6.2.1	Sàng lọc informative	34
6.2.2	Phân loại nhu cầu humanitarian	34
6.2.3	Giá trị của nhánh ảnh	35
6.3	Ý nghĩa của Manual Review	35
6.4	Khuyến nghị vận hành	35
6.5	Trả lời tám câu hỏi của bài tập	36
6.6	Điều đã chứng minh và chưa chứng minh	37
7	Sản phẩm: Dashboard hỗ trợ điều phối	38
7.1	Vai trò của giao diện trong DSS	38
7.2	Năm trang chức năng	38
7.3	Kiến trúc dữ liệu của dashboard	39
7.4	Công nghệ và lý do lựa chọn	40
7.5	Chạy local và triển khai Streamlit Community Cloud	40
7.5.1	Chạy local đầy đủ	40
7.5.2	Bundle cloud	41
7.6	Kiểm thử giao diện và giới hạn triển khai	41

8	Kết luận và hướng phát triển	42
8.1	Kết luận	42
8.2	Hạn chế	42
8.3	Hướng phát triển	43
A	Phụ lục	44
A.1	Khai báo sử dụng công cụ AI	44
A.2	Bảng tự đánh giá	44
A.3	Cấu hình và siêu tham số chính	45
A.4	Tập minh chứng và khả năng tái lập	45
A.5	Thông tin còn cần nhóm xác nhận	46
	Tài liệu tham khảo	47

Danh sách hình

2.1	Chuỗi chuyển đổi từ dữ liệu thô tới khuyến nghị hành động.	5
2.2	Kiến trúc logic của hệ hỗ trợ quyết định đa phương thức.	7
3.1	Ảnh train đại diện cho tám lớp humanitarian chung.	15
4.1	Phân bố informative và humanitarian trên train.	17
4.2	Số mẫu và cơ cấu humanitarian theo sự kiện trên train.	18
4.3	Phân bố độ dài và token nổi bật trên train.	19
4.4	Phân cụm TF-IDF trên train.	20
4.5	Một số ảnh train theo tám lớp humanitarian.	21
4.6	t-SNE của CLIP embedding train, tô màu theo ground truth chung.	22
4.7	Tỷ lệ nhãn category text và image bất đồng trên train.	22
7.1	Tổng quan vận hành và căn cứ dữ liệu.	39
7.2	Từ bằng chứng mô hình tới hàng đợi quyết định.	39

1 Giới thiệu bài toán

1.1 Bối cảnh thực tế

Trong những giờ đầu của một trận lũ, bão, động đất hoặc cháy rừng, thông tin thường xuất hiện trên mạng xã hội trước khi được tổng hợp đầy đủ trong các báo cáo chính thức. Người dân có thể đăng lời kêu cứu, vị trí đường bị chặn, hình ảnh công trình sập, nhu cầu lương thực hoặc thông tin về hoạt động tình nguyện. Nguồn dữ liệu này có giá trị vì nhanh và gần hiện trường, nhưng đồng thời cũng rất khó sử dụng trực tiếp:

- số lượng bài đăng tăng nhanh hơn khả năng đọc thủ công;
- văn bản ngắn, có URL, hashtag, viết tắt và nhiều nội dung không liên quan đến cứu trợ;
- một bài đăng có thể chứa cả văn bản và ảnh nhưng hai nguồn bằng chứng không nhất thiết nói cùng một nội dung;
- thông tin thường thiếu vị trí chính xác, có thể được đăng lại hoặc dùng lại một ảnh cũ;
- chi phí của các loại sai khác nhau: bỏ sót một lời kêu cứu có thể nghiêm trọng hơn việc chuyển nhầm một bài đăng ít khẩn cấp cho người kiểm tra.

Vấn đề của trung tâm điều phối không đơn thuần là “gán nhãn đúng cho một tweet”. Người điều phối cần quyết định *bài nào phải được chú ý trước, vấn đề thuộc nhóm nào, đội nào nên tiếp nhận và trường hợp nào cần con người xác minh*. Vì vậy, sản phẩm phù hợp phải là một **hệ hỗ trợ quyết định** (Decision Support System – DSS), trong đó mô hình học máy chỉ là một thành phần tạo bằng chứng đầu vào cho quyết định.

1.2 Bài toán ra quyết định

Đơn vị phân tích của dự án là một bài đăng gồm nội dung văn bản và một ảnh đính kèm. Với mỗi bài đăng, hệ thống hỗ trợ cần quyết định liên tiếp:

1. **Sàng lọc:** bài đăng có chứa thông tin hữu ích cho ứng phó thảm họa hay chỉ là nội dung không liên quan?
2. **Phân loại nhu cầu:** thông tin thuộc nhóm thương vong, người mất tích, hạ tầng, người bị ảnh hưởng, cứu trợ/quyên góp hay một nhóm khác?
3. **Xếp mức ưu tiên:** bài đăng nên nằm ở mức Low, Medium hay High trong hàng đợi xử lý?

4. **Phân luồng:** nhóm phản ứng nào nên tiếp nhận bài đăng?
5. **Kiểm duyệt:** bằng chứng có đủ nhất quán để dùng trực tiếp hay cần một giám sát viên xem lại?

Năm quyết định có quan hệ phụ thuộc. Nếu bài đăng bị đánh giá là không hữu ích, việc phân luồng cứu hộ không còn nhiều ý nghĩa. Nếu bài đăng được xếp vào nhóm thương vong nhưng hai phương thức mâu thuẫn mạnh, hệ thống vẫn phải cảnh báo đội khẩn cấp đồng thời yêu cầu người giám sát kiểm tra; không được tự động hạ mức ưu tiên chỉ vì mô hình chưa chắc chắn.

1.3 Người sử dụng và nhu cầu thông tin

Bảng 1.1: Người sử dụng, quyết định và thông tin cần thiết.

Người sử dụng	Quyết định cần hỗ trợ	Thông tin hệ thống cung cấp
Ban điều phối	Ưu tiên nguồn lực và theo dõi khối lượng sự vụ	Số bài theo mức ưu tiên, sự kiện, nhóm nhu cầu và đội tiếp nhận
Đội khẩn cấp	Xác định trường hợp liên quan sinh mạng cần kiểm tra trước	Nhãn thương vong/mất tích, điểm rủi ro, nội dung gốc và cảnh báo mâu thuẫn
Đội hạ tầng	Lập danh sách đường, cầu, điện nước hoặc phương tiện bị hư hỏng	Nhãn hạ tầng/phương tiện, thứ tự ưu tiên và bài đăng gốc
Đội cứu trợ	Điều phối lương thực, nơi trú ẩn, tình nguyện và quyên góp	Nhãn người bị ảnh hưởng/cứu trợ, mức ưu tiên và khối lượng theo sự kiện
Giám sát viên	Xác minh trường hợp không nhất quán hoặc thiếu tin cậy	Xác suất từng nhánh, conflict score, ảnh, văn bản và lý do cần review

Bảng trên cho thấy cùng một dự báo phải được trình bày khác nhau tùy người dùng. Một nhà nghiên cứu quan tâm đến F1 hoặc confusion matrix, trong khi điều phối viên cần hàng đợi có thể sắp xếp và hành động đề xuất. DSS phải nối được hai góc nhìn này.

1.4 Ví dụ xuyên suốt

Giả sử hệ thống nhận được bài đăng:

“Urgent! People are trapped after the bridge collapsed in rising flood water. Need rescue now.”

kèm một ảnh đường ngập. Hệ thống không đi thẳng từ câu chữ tới lệnh điều động. Quá trình xử lý được chia thành các bước có thể kiểm tra:

1. làm sạch văn bản và chuyển văn bản thành vector TF-IDF;
2. dùng CLIP tiền huấn luyện, với trọng số giữ nguyên, để chuyển ảnh thành vector đặc trưng 512 chiều;
3. các bộ phân loại riêng cho văn bản và ảnh tạo xác suất informative và xác suất của tám nhóm humanitarian;
4. Late Fusion kết hợp hai tập xác suất bằng trọng số được chọn trên tập dev;
5. tầng DSS kết hợp xác suất, mức nghiêm trọng của nhóm, từ khóa khẩn cấp và độ tin cậy để tạo Risk Score;
6. Risk Score và nhóm humanitarian được chuyển thành Priority, đội tiếp nhận và chờ Manual Review.

Ví dụ này thể hiện ranh giới quan trọng: mô hình dự báo cung cấp bằng chứng, còn quy tắc DSS chuyển bằng chứng thành một đề xuất hành động. Quyết định cuối cùng vẫn thuộc về con người.

1.5 Mục tiêu của dự án

Mục tiêu tổng quát là xây dựng và đánh giá một nguyên mẫu DSS đa phương thức có khả năng chuyển dữ liệu mạng xã hội thành thông tin hỗ trợ điều phối cứu trợ. Các mục tiêu cụ thể gồm:

1. sử dụng toàn bộ dữ liệu CrisisMMD v2.0, gồm 18.082 cặp tweet-ảnh; bảo toàn cách chia train/dev/test thống nhất;
2. mô tả, làm sạch và kiểm soát chất lượng dữ liệu, đặc biệt là nhãn sai khi join, mất cân bằng và bản sao xuyên split;
3. so sánh sáu thuật toán phân lớp cổ điển trên hai phương thức và hai nhiệm vụ dự báo;
4. đánh giá việc kết hợp văn bản-ảnh so với từng phương thức đơn lẻ và so với baseline đơn giản;
5. xây dựng tầng quyết định gồm Risk Score, Priority, Routing và Manual Review với giả định được công khai;
6. cung cấp dashboard để người sử dụng xem tổng quan, kiểm tra mô hình, thử một trường hợp và xử lý hàng đợi ưu tiên.

1.6 Câu hỏi nghiên cứu

1. Văn bản và hình ảnh đóng góp khác nhau như thế nào khi dự báo cùng ground truth đa phương thức?
2. Late Fusion có cải thiện chất lượng so với text-only, image-only và dummy baseline hay không?
3. Mất cân bằng lớp và sự khác biệt giữa các thảm họa ảnh hưởng thế nào tới khả năng nhận diện các nhóm hiếm?
4. Có thể sử dụng bất đồng text-ảnh để tạo một hàng đợi kiểm duyệt nằm trong năng lực xử lý của con người hay không?
5. Làm thế nào chuyển kết quả dự báo thành khuyến nghị ưu tiên và phân luồng mà không nhầm chính sách heuristic với kết quả đã học từ dữ liệu?

1.7 Phạm vi và giới hạn

Dự án sử dụng dữ liệu tiếng Anh của bảy thảm họa trong năm 2017. Hệ thống không thu thập bài đăng thời gian thực, không xác minh danh tính người đăng, không trích xuất chính xác tọa độ và không tự động điều động lực lượng ngoài đời. Risk Score và Priority không có ground truth tương ứng trong CrisisMMD; do đó chúng được xem là **chính sách vận hành thử nghiệm**, được kiểm tra bằng kịch bản và phân tích độ nhạy chứ không được tuyên bố là tối ưu thống kê.

Sản phẩm hướng tới sàng lọc và tổ chức thông tin. Các nhóm có số mẫu rất thấp, đặc biệt người mất tích và hư hỏng phương tiện, luôn cần con người kiểm tra trước khi dùng cho quyết định có hậu quả lớn.


1.8 Cấu trúc báo cáo

Các chương tiếp theo lần lượt trình bày nền tảng DSS; dữ liệu và cách tạo đặc trưng; cơ sở các phương pháp; EDA; thiết kế thực nghiệm và kết quả mô hình; Late Fusion và tăng quyết định; dashboard; khuyến nghị, giới hạn và hướng phát triển. Phụ lục chứa phân công, khai báo sử dụng công cụ hỗ trợ, siêu tham số và bảng tự đánh giá theo hướng dẫn học phần.

2 Nền tảng hệ hỗ trợ quyết định

2.1 Từ dữ liệu đến hành động

Dữ liệu là các quan sát thô, chẳng hạn nội dung một tweet, một ảnh, thời điểm đăng và tên sự kiện. Khi dữ liệu được làm sạch, đặt trong bối cảnh và tổng hợp, nó trở thành *thông tin*: bài đăng có khả năng hữu ích, liên quan đến hạ tầng và có mức bất đồng text–ảnh cao. Khi thông tin được kết hợp với quy tắc nghiệp vụ, giới hạn nguồn lực và trách nhiệm của người sử dụng, hệ thống mới có thể tạo *khuyến nghị hành động*: chuyển bài đăng tới đội hạ tầng, xếp Medium và yêu cầu giám sát viên kiểm tra.



Hình 2.1: Chuỗi chuyển đổi từ dữ liệu thô tới khuyến nghị hành động.

Việc phân biệt bốn mức trên giúp tránh một sai lầm phổ biến: một xác suất dự báo cao không tự nó là quyết định. Ví dụ, xác suất 0,82 cho lớp hạ tầng chưa cho biết đội nào tiếp nhận hoặc trường hợp đó có khẩn cấp hơn một lời kêu cứu khác hay không. Những câu hỏi đó cần thêm chính sách và bối cảnh vận hành.

2.2 Khái niệm hệ hỗ trợ quyết định

Hệ hỗ trợ quyết định là hệ thống thông tin kết hợp dữ liệu, mô hình phân tích và giao diện tương tác để giúp con người giải quyết các vấn đề mà việc lựa chọn không thể được tự động hóa hoàn toàn [1, 14]. DSS không nhất thiết phải đưa ra một đáp án duy nhất. Giá trị của nó có thể nằm ở việc:

- giảm khối lượng thông tin con người phải đọc;
- cung cấp nhiều góc nhìn và chỉ số có thể kiểm tra;
- sắp xếp các phương án theo tiêu chí rõ ràng;
- cảnh báo trường hợp bất thường hoặc thiếu chắc chắn;
- ghi lại lý do của khuyến nghị để người sử dụng chịu trách nhiệm cuối.

Trong dự án này, DSS không thay thế trung tâm điều phối. Nó biến hàng nghìn bài đăng thành một hàng đợi có cấu trúc, nhưng con người vẫn kiểm tra vị trí, độ xác thực và điều kiện hiện trường trước khi triển khai nguồn lực.

2.3 Mức độ cấu trúc của quyết định

Một **quyết định có cấu trúc** có quy tắc và đầu vào rõ ràng, có thể thực hiện lặp lại. Ví dụ, nếu một bài đăng đã được xác nhận thuộc nhóm hư hỏng hạ tầng thì chuyển về Infrastructure Team là một quy tắc tương đối có cấu trúc.

Một **quyết định bán cấu trúc** có một phần được mô hình hoặc quy tắc hỗ trợ nhưng vẫn cần phán đoán con người. Xếp mức ưu tiên cho bài đăng là quyết định bán cấu trúc: Risk Score tạo thứ tự ban đầu, nhưng điều phối viên có thể thay đổi khi biết bệnh viện nào đang quá tải hoặc tuyến đường nào đã được xử lý.

Một **quyết định phi cấu trúc** phụ thuộc mạnh vào kinh nghiệm và bối cảnh khó biểu diễn thành quy tắc cố định, chẳng hạn quyết định điều động lực lượng ngoài đời trong một thảm họa đang diễn biến. Phạm vi dự án dừng ở mức hỗ trợ cho loại quyết định này, không tự động thực thi.

2.4 Chu trình ra quyết định

Theo mô hình của Simon, quá trình ra quyết định có thể được mô tả qua các pha nhận biết vấn đề, thiết kế phương án, lựa chọn và thực thi [2]. Áp dụng vào dự án:

1. **Nhận biết (Intelligence):** thu nhận bài đăng, loại dữ liệu lỗi, phát hiện bài informative và nhận diện loại nhu cầu.
2. **Thiết kế (Design):** tạo các phương án xử lý như Emergency, Relief, Infrastructure, Coordination hoặc Manual Review.
3. **Lựa chọn (Choice):** dùng Risk Score, Priority và routing để đề xuất phương án phù hợp.
4. **Thực thi và phản hồi:** người điều phối xác nhận, thực hiện và ghi nhận kết quả để sau này hiệu chỉnh chính sách.

Dữ liệu CrisisMMD chỉ cung cấp ground truth cho informative và humanitarian, không có phản hồi thực tế về Priority hoặc đội được điều động. Vì vậy dự án thực hiện tốt ba pha đầu ở mức nguyên mẫu; pha phản hồi vận hành được xác định là hướng phát triển.

2.5 Ba nhóm năng lực của hệ thống

2.5.1 Phân tích mô tả và chẩn đoán

Phân tích mô tả trả lời “dữ liệu đang có đặc điểm gì?”: bao nhiêu bài theo sự kiện, tỷ lệ informative, phân bố tám lớp và độ dài tweet. Phân tích chẩn đoán đi thêm một bước để tìm lý do hoặc mối quan hệ: lớp hiếm, sự kiện có phân bố khác nhau, text và ảnh bất đồng ở nhóm nào. EDA, K-Means và Apriori thuộc nhóm này.

2.5.2 Phân tích dự báo

Phân tích dự báo trả lời “mẫu mới có khả năng thuộc lớp nào?”. Các classifier văn bản và ảnh tạo ra xác suất informative và xác suất của tám nhóm humanitarian. Kết quả này được đánh giá bằng nhãn chính thức, confusion matrix và các chỉ số phù hợp với dữ liệu mất cân bằng.


2.5.3 Phân tích định hướng hành động

Phân tích định hướng hành động trả lời “nên làm gì với dự báo?”. Tầng DSS dùng xác suất, mức nghiêm trọng, từ khóa và conflict score để đề xuất thứ tự ưu tiên, đội tiếp nhận và nhu cầu kiểm duyệt. Vì CrisisMMD không có nhãn Priority, đây là chính sách minh bạch chứ không phải một mô hình được chứng minh tối ưu.

Bảng 2.1: Phân biệt các nhóm năng lực phân tích trong dự án.

Nhóm	Câu hỏi	Đầu ra	Thành phần
Mô tả/chẩn đoán	Dữ liệu có đặc điểm và vấn đề gì?	Phân bố, insight, cụm, luật kết hợp	EDA, K-Means, Apriori
Dự báo	Bài đăng có khả năng thuộc lớp nào?	Xác suất informative và humanitarian	Sáu classifier, Late Fusion
Định hướng hành động	Nên xử lý bài đăng như thế nào?	Risk, Priority, Routing, Review	Rule engine và dashboard

2.6 Kiến trúc DSS của dự án



Hình 2.2: Kiến trúc logic của hệ hỗ trợ quyết định đa phương thức.

Đường nét đứt biểu diễn vòng phản hồi dự kiến: quyết định của người vận hành và kết quả xác minh có thể được lưu lại để theo dõi sai lệch, cập nhật chính sách hoặc tái huấn luyện mô hình ở các phiên bản sau.

Kiến trúc gồm bốn khối:

1. **Dữ liệu và biểu diễn:** làm sạch tweet, tạo TF-IDF; chuẩn hóa ảnh và dùng CLIP tiền huấn luyện với trọng số giữ nguyên để tạo vector.
2. **Mô hình dự báo:** các classifier cổ điển được huấn luyện trên CrisisMMD cho hai nhiệm vụ informative và humanitarian.
3. **Hợp nhất và chính sách:** xác suất hai phương thức được căn chỉnh, kết hợp và chuyển thành khuyến nghị.
4. **Giao diện:** người dùng xem KPI, lọc theo sự kiện, kiểm tra một ca và tải hàng đợi xử lý.

2.7 Vai trò của con người trong hệ thống

Human-in-the-loop là thiết kế trong đó con người được đưa vào những điểm mà mô hình không đủ dữ liệu, thiếu chắc chắn hoặc quyết định có hậu quả lớn. Với dự án này, con người xuất hiện ở ba mức:

- **xác minh dữ liệu:** kiểm tra bài đăng, ảnh, vị trí và nguồn;
- **xác nhận khuyến nghị:** chấp nhận hoặc thay đổi Priority và Routing theo tình hình thực tế;
- **giám sát hệ thống:** theo dõi sai lệch theo sự kiện, công suất hàng review và hiệu quả sau triển khai.

Manual Review không chỉ là một “nhân lỗi”. Nó là một cơ chế quản trị rủi ro: hệ thống chủ động chuyển các trường hợp bất đồng mạnh mẽ cho người có trách nhiệm. Tuy nhiên, công suất con người là hữu hạn. Nếu ngưỡng quá thấp, gần như mọi bài đăng đều bị chuyển review và DSS không còn giảm tải. Vì vậy ngưỡng conflict được chọn trên dev dưới một giới hạn công suất, sau đó mới khóa để đánh giá.

2.8 Nguyên tắc phân biệt bằng chứng và chính sách

Ba mức khẳng định trong báo cáo

Bằng chứng dữ liệu là đại lượng đo được, chẳng hạn số mẫu, phân bố nhãn, metric hoặc tỷ lệ bất đồng. **Suy luận phân tích** là cách diễn giải có giới hạn từ bằng chứng, chẳng hạn “mất cân bằng có thể làm Accuracy che giấu lỗi lớp hiếm”. **Chính sách vận hành** là lựa chọn của tổ chức khi dữ liệu không có ground truth, chẳng hạn trọng số severity hoặc ngưỡng Priority. Ba mức này phải được trình bày tách biệt.

Nguyên tắc trên đặc biệt quan trọng với Risk Score. Dự án có thể chứng minh classifier được đánh giá trên nhãn informative/humanitarian, nhưng không thể chứng minh Priority là tối ưu khi chưa có nhãn Priority. Thay vào đó, báo cáo phải công khai công thức, thử nhiều ngưỡng và mô tả điều kiện cần để xác nhận chính sách trong tương lai.

3 Dữ liệu, tiền xử lý và biểu diễn đặc trưng

3.1 Vai trò của dữ liệu trong bài toán

Một mô hình học máy không trực tiếp “hiểu” tweet hay ảnh. Nó học quan hệ thống kê giữa một biểu diễn số của đầu vào và nhãn mục tiêu. Vì vậy, chất lượng của dự án phụ thuộc vào ba điều kiện trước khi lựa chọn thuật toán:

1. **đúng đối tượng:** mỗi dòng phải thực sự mô tả một cặp tweet–ảnh và mang đúng nhãn chính thức;
2. **đúng ranh giới đánh giá:** thông tin của dev/test không được đi vào quá trình fit đặc trưng hoặc huấn luyện;
3. **đúng biểu diễn:** văn bản và ảnh phải được chuyển thành các vector có ý nghĩa đối với classifier.

Trong chương này, *tiền xử lý* là các thao tác làm đầu vào nhất quán hơn, chẳng hạn bỏ URL hoặc chuyển ảnh sang RGB. *Biểu diễn đặc trưng* là bước chuyển đầu vào thành vector số. *Feature engineering* là toàn bộ quá trình lựa chọn, tạo và kiểm soát các đặc trưng để mô hình sử dụng. Theo nghĩa đó, dự án có hai nhánh feature engineering: TF–IDF cho văn bản và embedding CLIP cho ảnh.

3.2 Bộ dữ liệu CrisisMMD v2.0

3.2.1 Nguồn, đơn vị quan sát và phạm vi

CrisisMMD là bộ dữ liệu đa phương thức do Qatar Computing Research Institute công bố cho nghiên cứu ứng phó thảm họa [3]. Phiên bản sử dụng trong dự án gồm **18.082 cặp tweet–ảnh** thuộc bảy sự kiện năm 2017: ba cơn bão Harvey, Irma, Maria; cháy rừng California; động đất Mexico; động đất Iraq–Iran; và lũ Sri Lanka.

Đơn vị quan sát của dự án là **một cặp tweet–ảnh**, không phải một người dùng hay một sự kiện. Một tweet có thể xuất hiện với nhiều ảnh, do đó `tweet_id` không nhất thiết duy nhất trong tập train; cặp `tweet_id`, `image_id` mới là khóa của một quan sát. Sự phân biệt này quan trọng khi kiểm tra trùng lặp và khi căn thứ tự embedding với annotation.

3.2.2 Hai nhiệm vụ dự báo

Dự án sử dụng hai bộ nhãn chung do CrisisMMD cung cấp:

Informativeness Bài đăng có chứa thông tin hữu ích cho hoạt động ứng phó thảm họa hay không. Đây là bài toán nhị phân gồm `informative` và `not_informative`.

Humanitarian category

Nếu xét nội dung nhân đạo, bài đăng thuộc nhóm nhu cầu hoặc thiệt hại nào. Đây là bài toán tám lớp: người bị ảnh hưởng; người bị thương hoặc tử vong; người mất tích hoặc được tìm thấy; thiệt hại hạ tầng và tiện ích; thiệt hại phương tiện; cứu hộ, tình nguyện hoặc quyên góp; thông tin liên quan khác; và nội dung không mang tính nhân đạo.

Ngoài nhãn chung của cặp, dữ liệu còn có nhãn riêng do người gán nhãn quan sát văn bản và ảnh. Các nhãn riêng này được dùng để chẩn đoán sự bất đồng giữa hai phương thức, không thay thế ground truth chung khi huấn luyện mô hình vận hành.

Bảng 3.1: Các trường dữ liệu được sử dụng trong pipeline.

Trường	Ý nghĩa và cách sử dụng
<code>event_name</code>	Tên thảm họa; dùng cho EDA và kiểm tra độ ổn định theo sự kiện.
<code>tweet_id, image_id</code>	Khóa nhận dạng, cần thứ tự cache và kiểm tra giao nhau giữa split.
<code>tweet_text, image</code>	Văn bản gốc và đường dẫn ảnh đầu vào.
<code>label</code>	Nhãn chung chính thức của nhiệm vụ informative.
<code>label_top</code>	Nhãn chung chính thức của nhiệm vụ humanitarian tám lớp.
<code>label_text_*</code>	Nhãn chỉ dựa trên văn bản; dùng cho phân tích bất đồng.
<code>label_image_*</code>	Nhãn chỉ dựa trên ảnh; dùng cho phân tích bất đồng.
<code>multimodal_agree</code>	Cờ đồng thuận category giữa người gán nhãn text và image.

3.3 Hợp nhất annotation và bảo toàn split

3.3.1 Vấn đề khác partition giữa hai task

CrisisMMD phát hành các file train/dev/test riêng cho từng nhiệm vụ. Partition của informative và humanitarian không giống nhau. Nếu chỉ inner join hai file cùng tên, nhiều cặp sẽ bị loại vì một mẫu có thể nằm ở train của task này nhưng nằm ở dev của task kia. Nếu suy diễn nhãn

informative chung từ nhãn humanitarian chung, **2.649/18.082 mẫu** sẽ bị gán sai, tương đương 14,65%.

Pipeline giải quyết theo ba bước:

1. chọn partition humanitarian làm ranh giới train/dev/test thống nhất;
2. ghép toàn bộ annotation informative thành bảng tra cứu theo cặp tweet_id, image_id;
3. left join nhãn informative chính thức vào từng partition humanitarian và yêu cầu quan hệ khóa là one-to-one.

Cách làm này giữ đủ 18.082 dòng, đồng thời hai nhiệm vụ dùng chung một ranh giới đánh giá. Quan hệ “khác not_humanitarian thì informative” chỉ đúng với nhãn riêng từng phương thức trong dữ liệu này; dự án không dùng quan hệ đó để tạo ground truth chung.

3.3.2 Kích thước và phân bố

Bảng 3.2: Kích thước và chất lượng cơ bản sau khi hợp nhất.

Chỉ số	Train	Dev	Test
Số cặp tweet–ảnh	13.608	2.237	2.237
Giá trị thiếu	0	0	0
Trùng cặp tweet–ảnh trong split	0	0	0
Đường dẫn ảnh thiếu	0	0	0
Số lớp humanitarian quan sát được	8	8	8
Hàng qua bộ lọc exact-duplicate	13.608	2.189	2.169
Hàng qua bộ lọc robustness	13.608	2.078	2.032

Trong train, informative có 8.338 mẫu và not-informative có 5.270 mẫu. Độ mất cân bằng nghiêm trọng hơn ở task tám lớp: not_humanitarian có 5.260 mẫu, trong khi missing_or_found_people chỉ có 24 mẫu, chênh lệch khoảng **219:1**. Accuracy vì vậy không đủ phản ánh khả năng phát hiện lớp hiếm; thiết kế đánh giá phải bổ sung Macro-F1, F2 và kết quả theo từng lớp.

3.4 Kiểm soát trùng lặp và rò rỉ dữ liệu

3.4.1 Rò rỉ dữ liệu là gì?

Rò rỉ dữ liệu xảy ra khi quá trình huấn luyện tiếp cận thông tin mà trong sử dụng thực tế chỉ xuất hiện ở tương lai hoặc thuộc tập đánh giá. Khi đó, chỉ số test có thể cao nhưng không phản ánh khả năng tổng quát hóa. Với mạng xã hội, chỉ kiểm tra ID là chưa đủ: hai bài đăng khác ID vẫn có thể dùng cùng một ảnh hoặc cùng nội dung sau khi bỏ URL và mention.

Dự án kiểm tra bốn mức:

1. giao nhau của `tweet_id`, `image_id` và cặp ID;
2. trùng ảnh chính xác bằng SHA-256;
3. trùng văn bản sau bước làm sạch;
4. gần trùng bằng perceptual hash cho ảnh và độ tương tự ngữ nghĩa/từ vựng cho văn bản.

Không có ID hoặc cặp ID giao nhau giữa các split. Tuy nhiên, SHA-256 phát hiện 43 hash ảnh chung train–dev, 46 hash chung train–test và 21 hash chung dev–test. Có một văn bản sau làm sạch trùng giữa train với dev và một văn bản trùng giữa train với test. Trên toàn bộ corpus, 18.082 dòng chỉ tạo ra 17.777 hash ảnh duy nhất, tức 305 lần lặp ngoài ảnh đại diện đầu tiên.

3.4.2 Hai mặt nạ đánh giá

Canonical mask Loại một dòng dev/test nếu ảnh SHA-256 hoặc văn bản đã làm sạch của nó đã xuất hiện ở split trước. Đây là bộ lọc tự động có tiêu chí xác định và được dùng trong quy trình chọn mô hình ban đầu.

Robustness mask Bắt đầu từ canonical mask, sau đó loại thêm các cặp gần trùng đã được duyệt theo từng cặp. Ảnh ứng viên dùng pHash DCT 64-bit với khoảng cách Hamming không quá 4; văn bản dùng kết hợp cosine của CLIP text embedding và TF–IDF ký tự/từ. Mặt nạ này dùng để kiểm tra độ bền của kết luận, không tự động coi mọi ứng viên là bản sao.

Sau duyệt cặp, robustness mask loại thêm 111 dòng dev và 137 dòng test so với canonical mask. Việc báo cáo cả kết quả canonical và robustness giúp phân biệt hai câu hỏi: mô hình hoạt động thế nào trên split đã làm sạch bản sao chính xác, và kết luận còn giữ được hay không khi loại cả những bản sao gần.

3.5 Tiền xử lý và feature engineering văn bản

3.5.1 Làm sạch tweet

Tweet chứa nhiều token phục vụ nền tảng hơn là nội dung: URL rút gọn, mention, HTML entity và dấu câu. Hàm làm sạch thực hiện lần lượt:

1. chuyển chữ thường;
2. bỏ HTML entity, URL và @mention;
3. bỏ ký hiệu # nhưng giữ từ khóa hashtag;
4. chỉ giữ chữ cái Latin, chữ số và khoảng trắng;
5. gộp nhiều khoảng trắng liên tiếp.

Ví dụ:

Trước	URGENT:\Flood\waters\rising!\@Police\https://t.co/x\ #Harvey
Sau	urgent\flood\waters\rising\harvey

Giữ nội dung hashtag là quyết định có chủ đích vì tên thảm họa hoặc chủ đề cứu trợ thường nằm trong hashtag. Ngược lại, bỏ URL và mention giúp giảm số token chỉ xuất hiện một lần. Giới hạn của quy tắc hiện tại là loại emoji, dấu tiếng nước ngoài và không xử lý mỉa mai; đây là sự đánh đổi để có một pipeline đơn giản, có thể kiểm tra và phù hợp với corpus chủ yếu bằng tiếng Anh.

3.5.2 TF-IDF

Classifier không nhận chuỗi ký tự trực tiếp. TF-IDF chuyển mỗi văn bản thành vector thưa, trong đó một chiều tương ứng với một từ hoặc cặp từ. Trọng số của term t trong document d được mô tả bởi:

$$\text{tfidf}(t, d) = \text{tf}(t, d) \times \log \left(\frac{N + 1}{\text{df}(t) + 1} \right) + 1,$$

trong đó $\text{tf}(t, d)$ phản ánh số lần term xuất hiện, $\text{df}(t)$ là số văn bản chứa term và N là số văn bản train. Trực giác là một từ xuất hiện nhiều trong một tweet nhưng hiếm trên toàn corpus sẽ mang nhiều thông tin phân biệt hơn từ phổ biến ở mọi tweet.

Các cấu hình thực tế của vectorizer là:

- tối đa 2.000 đặc trưng có thứ tự theo thống kê của tập train;
- unigram và bigram, tức một từ và hai từ liên tiếp;
- stopwords tiếng Anh của scikit-learn;
- chuẩn hóa L_2 mặc định cho từng vector.

Bigram giúp phân biệt các cụm như power\outage, missing\people hoặc need\shelter, trong khi unigram giữ độ phủ khi câu ngắn. Giới hạn 2.000 chiều giảm chi phí và nhiễu so với giữ toàn bộ từ vựng, nhưng có thể bỏ sót term hiếm. Vectorizer **chỉ fit trên train**; dev và test chỉ gọi transform. Nếu fit trên toàn corpus, tần suất tài liệu của dev/test sẽ đi vào IDF và gây rò rỉ nhẹ nhưng có thật.

3.6 Tiền xử lý và feature engineering ảnh

3.6.1 Từ pixel đến vector đặc trưng

Ảnh có hàng trăm nghìn giá trị pixel, quá nhiều để các classifier cổ điển học trực tiếp trên 13.608 mẫu train. Dự án sử dụng CLIP ViT-B/32 [5] như một **bộ trích đặc trưng tiền huấn luyện**. Các khái niệm cần phân biệt:

Tiền huấn luyện	Mô hình CLIP đã được tác giả gốc học trước trên lượng lớn cặp ảnh–văn bản, trước khi dự án này sử dụng nó.
Transfer learning	Tri thức hình ảnh đã học được chuyển sang bài toán CrisisMMD thay vì huấn luyện mạng sâu từ đầu.
Frozen feature extractor	Trọng số CLIP được giữ nguyên; dự án chỉ chạy forward pass để lấy vector. Không có gradient và không cập nhật CLIP.
Fine-tuning	Là cập nhật một phần hoặc toàn bộ trọng số mô hình tiền huấn luyện bằng dữ liệu đích. Dự án không fine-tune CLIP.

Trong ViT-B/32, ảnh 224×224 được chia thành các patch 32×32 . Mỗi patch được biến thành một token và đi qua Transformer để tổng hợp quan hệ giữa các vùng ảnh. CLIP được học bằng mục tiêu tương phản: đưa vector của ảnh gần vector của mô tả phù hợp và xa mô tả không phù hợp. Vì vậy embedding thường chứa thông tin ngữ nghĩa cao hơn màu hoặc histogram đơn giản.

3.6.2 Quy trình trích xuất thực tế

Mỗi ảnh được:

1. mở bằng Pillow, chuyển về ba kênh RGB và resize 224×224 ;
2. đưa qua bộ xử lý chính thức của CLIP và forward pass ở chế độ eval trong `torch.no_grad()`;
3. lấy projected image embedding 512 chiều;

4. chuẩn hóa L_2 : $\hat{\mathbf{x}} = \mathbf{x} / \|\mathbf{x}\|_2$;

5. lưu cache theo đúng thứ tự `tweet_id, image_id`.

Chuẩn hóa L_2 đưa mọi vector lên mặt cầu đơn vị, giúp khoảng cách và tích vô hướng phản ánh hướng ngữ nghĩa thay vì độ lớn tùy ý. Cache có shape (13.608, 512), (2.237, 512), (2.237, 512) cho train/dev/test. Audit cho thấy norm trung bình bằng 1, độ lệch chuẩn toàn ma trận khoảng 0,04418, không có vector zero và metadata khớp thứ tự annotation.



Hình 3.1: Ảnh train đại diện cho tám lớp humanitarian chung.

3.6.3 Lý do giữ CLIP cố định

Giữ CLIP cố định phù hợp với phạm vi dự án vì:

- mục tiêu học phần là so sánh các thuật toán phân lớp và xây dựng DSS, không phải thiết kế mạng sâu;
- 13.608 mẫu train và các lớp hiếm rất nhỏ làm fine-tuning toàn mạng có nguy cơ overfit;
- embedding được tính một lần, sau đó cùng một không gian đặc trưng được dùng để so sánh công bằng sáu classifier;
- chi phí huấn luyện và triển khai thấp hơn, kết quả dễ tái lập hơn.

Đánh đổi là đặc trưng không được điều chỉnh riêng cho ảnh thảm họa. Kết quả của nhánh ảnh vì vậy phải được hiểu là “classifier trên đặc trưng CLIP cố định”, không phải thành tích của một CLIP đã được huấn luyện cho CrisisMMD.

3.7 Tổng hợp đặc trưng đầu vào mô hình

Bảng 3.3: Đặc trưng được tạo và nơi chúng được sử dụng.

Nguồn	Biểu diễn	Kích thước	Vai trò
Tweet	TF-IDF word 1–2 gram	2.000, vector thừa	Đầu vào sáu classifier văn bản cho hai task.
Ảnh	CLIP ViT-B/32 frozen embedding	512, vector đặc	Đầu vào sáu classifier ảnh cho hai task.
Xác suất mô hình	Vector xác suất đã căn lớp	2 hoặc 8	Đầu vào Late Fusion và conflict score.
Từ khóa nghiệp vụ	Cờ xuất hiện trong tweet đã làm sạch	một số cờ nhị phân	Tín hiệu bổ sung cho Risk Score, không dùng để thay đổi ground truth.

Như vậy, feature engineering của dự án không phải là một bước trang trí trước mô hình. Nó quyết định loại thông tin mà classifier có thể nhìn thấy, chi phí tính toán, nguy cơ rò rỉ và khả năng giải thích. Chương tiếp theo sử dụng chính các biểu diễn này để phân tích cấu trúc dữ liệu trước khi huấn luyện.

4 Phân tích khám phá dữ liệu


4.1 Mục đích và nguyên tắc EDA

Exploratory Data Analysis (EDA) là quá trình dùng thống kê mô tả và trực quan để hiểu cấu trúc dữ liệu trước khi xây mô hình. EDA không chỉ nhằm tạo biểu đồ; nó phải trả lời các câu hỏi có ảnh hưởng tới thiết kế:

- nhãn có mất cân bằng hay không;
- phân bố có thay đổi giữa các sự kiện hay không;
- văn bản và ảnh có chứa tín hiệu quan sát được nào;
- có cấu trúc cụm hoặc luật đồng xuất hiện nào;
- hai phương thức thường đồng thuận hay mâu thuẫn;
- các quan sát trên dẫn tới quyết định kỹ thuật nào.

EDA phục vụ lựa chọn phương pháp chỉ sử dụng **13.608 mẫu train**. Nếu xem phân bố nhãn hoặc pattern của test rồi điều chỉnh model, test sẽ tham gia gián tiếp vào thiết kế. Kiểm kê file và kiểm tra duplicate được phép bao phủ toàn corpus vì đó là kiểm soát tính toàn vẹn đầu vào, không phải tìm pattern để tối ưu model.

4.2 Phân bố nhãn và hệ quả




Hình 4.1: Phân bố informative và humanitarian trên train.

Informative chiếm 61,27% train. Đây là mức lệch vừa phải nhưng đủ làm always-informative có Recall và F2 cao. Ở task humanitarian, lớp not-humanitarian có 5.260 mẫu trong khi missing/found chỉ có 24 mẫu, chênh **219:1**. Ba hệ quả trực tiếp là:

1. không chọn model chỉ bằng Accuracy;
2. sử dụng class weight khi thuật toán hỗ trợ;
3. báo cáo Macro-F1, confusion matrix và F1 theo lớp.

Từ phân bố không thể kết luận lớp hiếm sẽ dự báo kém trong mọi trường hợp, nhưng có thể kết luận ước lượng metric của lớp đó có độ bất định lớn và một vài dự báo có thể làm F1 thay đổi mạnh.

4.3 Khác biệt theo sự kiện




Hình 4.2: Số mẫu và cơ cấu humanitarian theo sự kiện trên train.

Sri Lanka floods có 69,29% not-humanitarian, trong khi Iraq–Iran earthquake chỉ 22,76%. Mexico earthquake có 27,95% rescue/donation; Iraq–Iran có 13,57% injured/dead, cao hơn rõ rệt các cơn bão. Đây là *distribution shift theo sự kiện*: quan hệ giữa event và tỷ lệ nhãn không đồng nhất.

EDA chưa chứng minh model sẽ thất bại trên event mới, vì tất cả event vẫn xuất hiện trong train/dev/test. Tuy nhiên, nó chỉ ra rằng metric gộp có thể che khác biệt từng thảm họa. Vì vậy dashboard có bộ lọc event và phần đánh giá sau này báo cáo độ ổn định theo event. Một đánh giá nghiêm ngặt hơn trong tương lai là leave-one-event-out: giữ toàn bộ một thảm họa ngoài train.

4.4 Khám phá văn bản

Tweet có trung bình 117,48 ký tự và 11,72 từ sau làm sạch. Số từ trung bình của informative là 11,75, gần như bằng 11,68 của not-informative.



Hình 4.3: Phân bố độ dài và token nổi bật trên train.

Sự gần nhau của độ dài cho thấy một rule kiểu “tweet dài thì informative” không có cơ sở. Nội dung từ và cụm từ mới là tín hiệu phù hợp cho TF-IDF. Các token nổi bật còn phản ánh tên địa điểm, cứu trợ, thiệt hại và bối cảnh sự kiện; vì thế khi clustering theo chủ đề, dự án loại thêm tên event và token nền tảng như `rt`, `amp`, `http` để tránh cụm chỉ tái hiện nguồn dữ liệu.

4.5 K-Means cho khám phá chủ đề

4.5.1 Khái niệm và hàm mục tiêu

Clustering là học không giám sát: thuật toán không nhìn nhãn humanitarian mà nhóm các điểm giống nhau. K-Means tìm K tâm cụm $\mu_1, \dots, \mu_K$ để tối thiểu hóa tổng bình phương khoảng cách trong cụm:

$$J = \sum_{i=1}^n \|\mathbf{x}_i - \mu_{c_i}\|_2^2.$$

Thuật toán lặp hai bước: gán mỗi điểm vào tâm gần nhất, rồi cập nhật tâm bằng trung bình các điểm được gán. K-Means nhanh và dễ đọc top term từ centroid, nhưng phải chọn K , nhạy với khởi tạo và giả định cụm gần dạng cầu trong không gian khoảng cách [9].

Dự án dùng TF-IDF tối đa 2.000 unigram/bigram, `min_df=3`, mười lần khởi tạo và random seed 42. Sweep $K = 2, \dots, 12$ được thực hiện trên cùng một mẫu 8.000 dòng train để các giá trị so sánh được.


4.5.2 Silhouette và kết quả

Silhouette của điểm i là:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

trong đó $a(i)$ là khoảng cách trung bình tới điểm cùng cụm và $b(i)$ là khoảng cách trung bình nhỏ nhất tới một cụm khác. Giá trị gần 1 cho thấy điểm nằm gọn trong cụm; gần 0 cho thấy các

cụm chồng lấn; âm cho thấy có thể gán sai.



Hình 4.4: Phân cụm TF-IDF trên train.

Silhouette chỉ khoảng 0,014–0,024 và tăng nhẹ tới biên khảo sát, không có điểm gãy rõ. Với $K = 8$, silhouette là 0,021. $K = 8$ được giữ để đối chiếu với taxonomy tám lớp, **không phải** vì dữ liệu chứng minh tám cụm là tối ưu.

Top term cho thấy một số chủ đề có nghĩa như storm/surge, relief effort, help victims, Puerto Rico/power và rescue. Tuy nhiên, mỗi cụm vẫn chứa nhiều nhãn humanitarian. Kết luận hợp lệ là K-Means hữu ích để duyệt chủ đề và phát hiện nhóm nội dung; nó không đủ ổn định để thay classifier hoặc routing.

4.6 Apriori và luật kết hợp

4.6.1 Từ tweet thành transaction

Association analysis tìm các item thường xuất hiện cùng nhau. Mỗi tweet được chuyển thành một “giỏ” gồm từ khóa khủng hoảng và hashtag. Chỉ transaction có ít nhất hai item được giữ. Nếu một từ đã xuất hiện dưới dạng hashtag, phiên bản không có dấu # bị bỏ để tránh luật hiển nhiên như $\{\#earthquake\} \Rightarrow \{earthquake\}$.

Apriori dựa trên tính chất: nếu một itemset không đủ phổ biến, mọi superset của nó cũng không thể đủ phổ biến. Nhờ vậy thuật toán loại sớm nhiều ứng viên [10]. Ba đại lượng chính là:

$$\text{support}(A \Rightarrow B) = P(A \cup B),$$

$$\text{confidence}(A \Rightarrow B) = P(B | A) = \frac{P(A \cup B)}{P(A)},$$

$$\text{lift}(A \Rightarrow B) = \frac{P(A \cup B)}{P(A)P(B)}.$$

Lift bằng 1 tương ứng đồng xuất hiện như kỳ vọng nếu độc lập; lớn hơn 1 cho thấy liên kết dương. Support trong phân tích này được tính trên tập transaction đã giữ, không phải toàn bộ 13.608 tweet. Ngưỡng dùng là support 0,005 và confidence 0,25; 20 luật lift cao nhất được lưu.

4.6.2 Kết quả và cách diễn giải

Bảng 4.1: Một số luật Apriori trên train.

Tiền đề	Kết quả	Support	Confidence	Lift
#floodsl	#lka	.010	.539	40.013
#iraq	#iran	.006	.659	25.672
#wildfires	#california	.007	.508	25.541
#iran	#earthquake	.018	.717	18.507
#puertorico	#hurricane maria	.025	.627	7.045

Các luật chủ yếu nổi địa danh với sự kiện, phù hợp cho filter và drill-down. Lift cao không có nghĩa tiền đề gây ra kết quả; nó cũng có thể cao vì hai hashtag cùng được dùng trong một chiến dịch truyền thông nhỏ. Association rules vì vậy không dùng để dự báo Priority hay thay classifier.

4.7 EDA ảnh và không gian embedding

Kiểm kê toàn corpus xác nhận 18.082 ảnh annotation hợp lệ, nhiều kích thước và mode màu; toàn bộ được chuyển RGB trước CLIP. Gallery theo lớp được lấy từ train để kiểm tra trực quan rằng dữ liệu là ảnh thảm họa thật, không phải ô màu hay placeholder.



Hình 4.5: Một số ảnh train theo tám lớp humanitarian.


t-SNE là phương pháp giảm chiều phi tuyến, cố gắng bảo toàn lân cận cục bộ khi chiếu vector 512 chiều xuống hai chiều [11]. Hình t-SNE được tạo từ 3.000 embedding train, perplexity 30, khởi tạo PCA và seed 42.



Hình 4.6: t-SNE của CLIP embedding train, tô màu theo ground truth chung.

Một số vùng cục bộ xuất hiện nhưng các lớp chồng lấn mạnh. t-SNE có thể thay đổi theo tham số và làm biến dạng khoảng cách toàn cục, nên hình này không chứng minh khả năng phân lớp. Giá trị của CLIP phải được xác nhận bằng dev/test ở Chương 5.

4.8 Bất đồng đa phương thức



Hình 4.7: Tỷ lệ nhãn category text và image bất đồng trên train.

55,0% mẫu train có nhãn category text và ảnh khác nhau. Theo từng lớp, tỷ lệ bất đồng là 91,7% ở missing/found, 91,0% ở injured/dead, 88,9% ở affected và 87,3% ở vehicle damage. Not-humanitarian thấp hơn nhưng vẫn đạt 38,2%.

Các con số không chứng minh text đúng và ảnh sai, vì nhãn riêng chỉ phản ánh nội dung nhìn thấy ở từng phương thức. Một tweet có thể nhắc người mất tích nhưng dùng ảnh phong cảnh, hoặc ảnh có thiệt hại mà câu chữ chỉ nêu địa danh. Suy luận hợp lệ là hai phương thức mang bằng chứng không đồng nhất. Vì vậy:

1. fusion phải được tune trên nhãn chung chính thức;
2. không dùng phép “nếu text khác image thì một bên sai”;
3. conflict cao là tín hiệu yêu cầu người kiểm tra, không tự động hạ độ tin cậy của mọi dự báo.

4.9 Từ bằng chứng EDA đến quyết định thiết kế

Bảng 4.2: Chuỗi bằng chứng, suy luận và quyết định.

Bằng chứng train	Suy luận có giới hạn	Quyết định
Mất cân bằng 219:1	Accuracy che khuất lớp hiếm	F2, Macro-F1, class weight
Event profile khác nhau	Có nguy cơ domain shift	Filter và metric theo event
Độ dài hai lớp gần nhau	Length không đủ phân loại	TF-IDF nội dung
Silhouette rất thấp	Cụm không đủ ổn định cho quyết định	K-Means chỉ cho khám phá
Luật hashtag lift cao	Context sự kiện có cấu trúc	Drill-down phụ trợ
55% modality bất đồng	Không tin tuyệt đối một nhánh	Tune fusion, Manual Review
Ảnh lặp xuyên split	Metric có thể lạc quan	Canonical/robust mask

EDA vì vậy có giá trị khi nó thay đổi cách đánh giá và kiến trúc. Các kết luận trên đều dừng ở mức dữ liệu cho phép; tương quan, hình chiếu hai chiều và luật đồng xuất hiện không được diễn giải thành quan hệ nhân quả.

5 Mô hình dự báo, hợp nhất và chính sách DSS

5.1 Bài toán học có giám sát

Học có giám sát sử dụng các cặp $(\mathbf{x}_i, y_i)$, trong đó $\mathbf{x}_i$ là vector đặc trưng và y_i là nhãn đã biết, để học hàm $f(\mathbf{x})$ dự báo nhãn cho mẫu mới. Dự án có bốn bài toán con:

1. TF-IDF $\rightarrow$ informative;
2. TF-IDF $\rightarrow$ humanitarian category;
3. CLIP image embedding $\rightarrow$ informative;
4. CLIP image embedding $\rightarrow$ humanitarian category.

Cùng sáu họ thuật toán được so sánh ở cả hai phương thức. Cách làm này tách hai câu hỏi: biểu diễn nào chứa tín hiệu hữu ích, và thuật toán nào khai thác biểu diễn đó tốt hơn. Nó cũng tránh quy toàn bộ kết quả nhánh ảnh cho CLIP: CLIP chỉ tạo đặc trưng; classifier phía sau mới được huấn luyện trên CrisisMMD.

5.2 Sáu thuật toán phân lớp

5.2.1 Logistic Regression

Mặc dù có tên “regression”, Logistic Regression là mô hình phân lớp. Với bài toán nhị phân, mô hình tính:

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Vector trọng số $\mathbf{w}$ cho biết mỗi đặc trưng đẩy log-odds về lớp nào. Với tám lớp, phiên bản đa lớp dùng softmax để tạo một phân bố xác suất tổng bằng 1. Logistic Regression phù hợp với TF-IDF và embedding vì học biên quyết định tuyến tính, huấn luyện nhanh và xuất xác suất trực tiếp. Giới hạn là quan hệ giữa đặc trưng và log-odds bị giả định tuyến tính; tương tác phức tạp không được tự động khám phá.

5.2.2 Decision Tree

Decision Tree chia không gian đặc trưng bằng chuỗi điều kiện dạng “đặc trưng j có lớn hơn ngưỡng c hay không”. Mỗi phép chia được chọn để giảm độ hỗn tạp, thường đo bằng Gini:

$$G = 1 - \sum_{k=1}^K p_k^2,$$

với p_k là tỷ lệ lớp k trong một nút. Cây dễ giải thích bằng đường đi từ gốc tới lá và có thể mô tả quan hệ phi tuyến. Tuy nhiên, cây đơn lẻ có phương sai cao, dễ học chi tiết ngẫu nhiên; trên TF-IDF 2.000 chiều, nhiều phép chia trên term hiếm làm cây đặc biệt dễ overfit. Dự án giới hạn `max_depth=20` ở vòng so sánh ban đầu.

5.2.3 Naive Bayes

Naive Bayes áp dụng định lý Bayes:

$$P(y \mid \mathbf{x}) \propto P(y) \prod_j P(x_j \mid y),$$

và giả định các đặc trưng độc lập có điều kiện khi biết lớp. Giả định này “ngây thơ” nhưng thường hiệu quả với văn bản. Multinomial Naive Bayes được dùng cho TF-IDF không âm; Gaussian Naive Bayes được dùng cho embedding đặc, với giả định mỗi chiều gần phân phối chuẩn trong từng lớp. Ưu điểm là nhanh, ổn định ở dữ liệu nhiều chiều. Nhược điểm là giả định độc lập/chuẩn hóa hiếm khi đúng hoàn toàn và xác suất có thể quá tự tin.

5.2.4 k-Nearest Neighbors

k-NN không học một công thức tham số. Khi có mẫu mới, thuật toán tìm k mẫu train gần nhất rồi bỏ phiếu. Với distance weighting, láng giềng gần có trọng số lớn hơn. Trên embedding ảnh đã chuẩn hóa L_2 , khoảng cách Euclidean và cosine có quan hệ đơn điệu:

$$\|\hat{\mathbf{x}} - \hat{\mathbf{z}}\|_2^2 = 2 - 2 \cos(\hat{\mathbf{x}}, \hat{\mathbf{z}}).$$

k-NN phù hợp để kiểm tra cấu trúc lân cận trong không gian CLIP. Trên TF-IDF thưa, “lời nguyên số chiều” làm nhiều điểm có khoảng cách gần tương tự nhau, dẫn đến kết quả yếu. Chi phí dự báo cũng cao vì phải so sánh với tập train và model phải lưu đặc trưng train.

5.2.5 Support Vector Machine

SVM tuyến tính tìm siêu phẳng $\mathbf{w}^T \mathbf{x} + b = 0$ có biên lớn giữa các lớp. Trục góc của biên lớn là không chỉ phân đúng mẫu train mà còn giữ khoảng cách với các mẫu gần ranh giới. Tham số C điều khiển đánh đổi: C lớn phạt lỗi train mạnh hơn, còn C nhỏ chấp nhận thêm lỗi để có biên đều hơn [7].

SVM tuyến tính thường mạnh trên TF-IDF vì xử lý tốt không gian nhiều chiều và thưa. Bản thân LinearSVC tạo decision score, không tạo xác suất. Dự án bọc mô hình bằng lớp

CalibratedClassifierCV với sigmoid và ba fold nội bộ để tạo predict_proba cho Late Fusion. Calibration này chỉ dùng dữ liệu train, không dùng dev/test.

5.2.6 Random Forest

Random Forest là ensemble của nhiều Decision Tree. Mỗi cây học trên một bootstrap sample và chỉ xét một tập con đặc trưng ở mỗi nút; dự báo cuối là bỏ phiếu hoặc trung bình xác suất [8]. Hai nguồn ngẫu nhiên làm các cây bớt tương quan, từ đó giảm phương sai so với một cây đơn. Dự án dùng 200 cây và balanced_subsample. Đánh đổi là model lớn hơn, giải thích khó hơn cây đơn và có thể không tận dụng không gian TF-IDF tuyến tính tốt bằng SVM.

5.3 Mất cân bằng lớp và trọng số

Với K lớp, scikit-learn đặt trọng số cân bằng xấp xỉ:

$$w_k = \frac{n}{K n_k},$$

trong đó n_k là số mẫu lớp k . Lớp hiếm nhận trọng số lỗi lớn hơn trong hàm mục tiêu. Logistic Regression, Decision Tree, SVM và Random Forest sử dụng class weight tương ứng; Naive Bayes và k-NN giữ cơ chế gốc.

Class weight không tạo thêm thông tin. Nó chỉ thay đổi chi phí sai số, thường tăng Recall lớp hiếm nhưng có thể giảm Precision. Với lớp missing chỉ có 24 mẫu train, không thể suy luận rằng class weight đã giải quyết thiếu dữ liệu; kết quả theo lớp vẫn phải được báo cáo.

5.4 Các chỉ số đánh giá

5.4.1 Nhị phân informative

Gọi TP là informative dự báo đúng, FP là not-informative bị báo nhầm, FN là informative bị bỏ sót và TN là not-informative dự báo đúng:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$

F1 là trung bình điều hòa của Precision và Recall. F_β tổng quát:

$$F_\beta = (1 + \beta^2) \frac{\text{Precision Recall}}{\beta^2 \text{Precision} + \text{Recall}}.$$

Dự án dùng F_2 , tức Recall có trọng số lớn hơn Precision vì bỏ sót thông tin khẩn cấp được xem là tổn kém hơn chuyển nhầm một bài cho bước kiểm tra. Tuy nhiên, khi informative chiếm đa số, classifier luôn dự báo informative cũng có F_2 cao. Vì vậy F_2 phải đi cùng Accuracy,

Balanced Accuracy, F1 và Matthews Correlation Coefficient (MCC). Balanced Accuracy lấy trung bình Recall của hai lớp; MCC bằng 0 với dự báo hằng và chỉ cao khi cả bốn ô confusion matrix hợp lý.

5.4.2 Tám lớp humanitarian

Accuracy bị chi phối bởi lớp lớn. Macro-F1 tính F1 riêng cho từng lớp rồi lấy trung bình không trọng số:

$$\text{MacroF1} = \frac{1}{K} \sum_{k=1}^K F1_k.$$

Do đó mỗi lớp hiếm có tiếng nói ngang lớp lớn. Weighted-F1 bổ sung góc nhìn theo tần suất thực tế. Tiêu chí chọn model là Macro-F1; báo cáo đồng thời Accuracy, Weighted-F1 và bảng từng lớp.

5.5 Thiết kế thực nghiệm

5.5.1 Vai trò của train, dev và test

Bảng 5.1: Ranh giới sử dụng dữ liệu trong thực nghiệm.

Split	Số hàng sạch	Mục đích
Train	13.608	Fit TF-IDF, classifier và calibration nội bộ.
Dev	2.189	Chọn họ model, siêu tham số, trọng số fusion và threshold.
Test	2.169	Đánh giá cuối sau khi mọi lựa chọn đã khóa.

“Model parameter” là trọng số học từ train, chẳng hạn $\mathbf{w}$ của Logistic Regression. “Hyperparameter” là cấu hình do người thiết kế chọn, chẳng hạn C , k , độ sâu cây hoặc số cây. Dùng test để chọn hyperparameter sẽ biến test thành dev và làm kết quả lạc quan. Dự án vì vậy dùng quy trình ba vòng:

1. so sánh sáu họ thuật toán trên dev với cấu hình chung;
2. chỉ tune họ thắng của mỗi bài toán trên dev;
3. khóa model, tune fusion trên dev và đánh giá đúng một lần trên test.

Đây không phải nested cross-validation đầy đủ; vì vậy vẫn có rủi ro thích nghi với một dev split. Để giảm rủi ro, lưới tuning nhỏ, được xác định trước và kết quả còn được hậu kiểm trên robust test không tune lại.

5.6 Vòng 1: so sánh sáu thuật toán

Bảng 5.2: Text informative trên dev, chọn theo F2.

Model	Acc.	Prec.	Recall	F1	F2
Logistic Regression	.7085	.7816	.7368	.7585	.7453
Decision Tree	.6044	.7546	.5382	.6283	.5710
Naive Bayes	.7177	.7265	.8750	.7939	.8406
k-NN	.4523	.7193	.1941	.3057	.2273
Linear SVM	.7204	.7234	.8904	.7983	.8511
Random Forest	.7195	.7457	.8324	.7867	.8135

Bảng 5.3: Text humanitarian trên dev, chọn theo Macro-F1.

Model	Acc.	Macro-P	Macro-R	Macro-F1	Weighted-F1
Logistic Regression	.4641	.3145	.4095	.3297	.4875
Decision Tree	.2810	.2118	.2346	.1302	.1747
Naive Bayes	.5263	.2677	.2429	.2446	.4982
k-NN	.4079	.3940	.1449	.1195	.2871
Linear SVM	.5112	.3019	.2697	.2787	.4856
Random Forest	.4947	.2921	.2571	.2626	.4734

Bảng 5.4: Image informative trên embedding CLIP, chọn theo F2.

Model	Acc.	Prec.	Recall	F1	F2
Logistic Regression	.7579	.8529	.7375	.7910	.7580
Decision Tree	.6807	.7487	.7316	.7401	.7350
Naive Bayes	.7177	.8681	.6434	.7390	.6785
k-NN	.7542	.7915	.8206	.8058	.8146
Linear SVM	.7593	.8078	.8037	.8058	.8045
Random Forest	.7478	.7949	.8007	.7978	.7996

Bảng 5.5: Image humanitarian trên embedding CLIP, chọn theo Macro-F1.

Model	Acc.	Macro-P	Macro-R	Macro-F1	Weighted-F1
Logistic Regression	.5354	.3603	.4768	.3637	.5653
Decision Tree	.4079	.2288	.2406	.2323	.4163
Naive Bayes	.5477	.3462	.4028	.3362	.5590
k-NN	.5943	.4101	.3530	.3563	.5851
Linear SVM	.6190	.4889	.3586	.3631	.5970
Random Forest	.5706	.5433	.2760	.2795	.5262

k-NN yếu rõ trên TF-IDF nhưng cạnh tranh trên CLIP embedding, phù hợp với phân tích về khoảng cách ở trên. Ở bài toán tám lớp, model có Accuracy cao nhất không nhất thiết có

Macro-F1 cao nhất. Việc định nghĩa tiêu chí trước khi xem kết quả ngăn lựa chọn metric thuận lợi sau thực nghiệm.

5.7 Vòng 2: tuning classifier

Tuning là tìm hyperparameter trong một lưới hữu hạn, không phải cập nhật CLIP. Chỉ bốn họ thắng vòng 1 được tune để hạn chế số phép thử. Với task đa lớp, Macro-F1 chênh không quá 0,001 được coi là hòa; khi đó ưu tiên Weighted-F1 rồi Accuracy. Quy tắc này tránh chọn một cấu hình chỉ vì vài dự báo lớp cực hiếm làm Macro-F1 dao động.

Bảng 5.6: Không gian tuning và cấu hình được chọn trên dev.

Task	Họ model	Lưới	Kết quả
Text informative	Linear SVM	$C \in \{0,05; 0,1; 0,3; 1; 3\}$	$C = 3$, F2=.8548
Text humanitarian	Logistic Regression	$C \in \{0,05; 0,1; 0,3; 1; 3; 10\}$	$C = 1$, Macro-F1=.3297
Image informative	k-NN	$k \in \{5, 9, 15, 25, 41\}$, uniform/distance	$k = 41$, distance, F2=.8216
Image humanitarian	Logistic Regression	$C \in \{0,05; 0,1; 0,3; 1; 3; 10\}$	$C = 1$, Macro-F1=.3637

SVM text tăng F2 dev từ .8511 lên .8548. k-NN ảnh tăng từ .8146 lên .8216. Hai model tám lớp giữ $C = 1$; lưới tuning đã được chạy nhưng không tìm thấy cấu hình khác tốt hơn đủ rõ. Đây là kết quả hợp lệ: tuning là kiểm định lựa chọn, không bảo đảm luôn tạo cải thiện.

5.8 Vòng 3: xác suất, Late Fusion và conflict

5.8.1 Căn chỉnh xác suất

Late Fusion kết hợp đầu ra sau khi mỗi nhánh đã dự báo. Với informative:

$$p_{\text{fused}} = \alpha p_{\text{text}} + (1 - \alpha) p_{\text{image}}, \quad \hat{y} = \mathbb{I}[p_{\text{fused}} \geq \tau].$$

Với humanitarian, mỗi model tạo vector tám xác suất. Pipeline căn cột theo cùng thứ tự lớp, điền 0 nếu một model thiếu lớp, rồi tính:

$$\mathbf{q}_{\text{fused}} = \beta \mathbf{q}_{\text{text}} + (1 - \beta) \mathbf{q}_{\text{image}}.$$

Trên dev, grid search chọn $\alpha = 0,70$, $\tau = 0,38$ cho informative và $\beta = 0,55$ cho humanitarian. Text nhận trọng số lớn hơn nhưng ảnh vẫn đóng góp 30–45%. Fusion là late fusion, không phải nối raw feature; ưu điểm là hai nhánh có thể dùng classifier khác nhau và dễ quan sát đóng góp từng nhánh. Nhược điểm là trung bình tuyến tính không học tương tác phức tạp.

5.8.2 Conflict score và Manual Review

Mức bất đồng informative là $|p_{\text{text}} - p_{\text{image}}|$. Với category, dự án dùng total variation distance:

$$C_{\text{cat}} = \frac{1}{2} \sum_{k=1}^8 |q_{\text{text},k} - q_{\text{image},k}|.$$

Conflict score là giá trị lớn hơn giữa hai đại lượng. Ngưỡng 0,54 được chọn trên dev để tối đa F1 phát hiện cờ bất đồng trong khi tỷ lệ review không vượt 25%. Đây là tối ưu có ràng buộc công suất: ngưỡng quá thấp tăng Recall nhưng làm hàng review quá tải; ngưỡng quá cao bỏ qua nhiều xung đột.

5.9 Kết quả cuối trên canonical test

5.9.1 Informative và đối chứng hằng

Bảng 5.7: Informative trên 2.169 hàng test sạch.

Hệ thống	Thr.	Acc.	Bal. Acc.	Prec.	Recall	F1	F2	MCC
Always informative	—	.6275	.5000	.6275	1.0000	.7711	.8939	.0000
Text-only	.38	.6823	.5792	.6675	.9838	.7954	.8987	.2904
Image-only	.20	.6773	.5759	.6662	.9735	.7910	.8913	.2660
Late Fusion	.38	.6948	.5944	.6755	.9882	.8025	.9045	.3325

Always-informative đạt F2 .8939 vì Recall bằng 1. Fusion chỉ tăng F2 thêm .0106, nhưng đồng thời tăng Accuracy .0673, F1 .0314, Balanced Accuracy và MCC. Do đó giá trị của fusion không được trình bày chỉ bằng F2. Image-only có Average Precision .8999, cao hơn text .7968, nhưng threshold ưu tiên Recall làm Accuracy hai nhánh gần nhau; điều này cho thấy chất lượng xếp hạng và quyết định tại một ngưỡng là hai khái niệm khác nhau.

5.9.2 Humanitarian tám lớp

Bảng 5.8: Humanitarian trên 2.169 hàng test sạch.

Hệ thống	Accuracy	Macro-F1	Weighted-F1
Majority baseline	.3785	.0686	.2079
Text-only	.4481	.3260	.4693
Image-only	.5440	.3646	.5695
Late Fusion	.5569	.4005	.5776

Ảnh mạnh hơn text ở task tám lớp, và fusion tiếp tục tăng Macro-F1 .0359 so với image-only. Điều này là bằng chứng thực nghiệm để giữ nhánh ảnh, nhưng không có nghĩa ảnh luôn đáng tin hơn text ở mọi lớp hoặc mọi sự kiện.

Bảng 5.9: Late Fusion humanitarian theo lớp trên canonical test.

Lớp	Precision	Recall	F1	Support
injured/dead	.2202	.6316	.3265	38
missing/found	.0435	.2000	.0714	5
rescue/donation	.5262	.5468	.5363	331
infrastructure	.4925	.5305	.5108	311
affected	.2124	.5000	.2982	82
vehicle damage	.1385	.5000	.2169	18
other relevant	.6588	.4938	.5645	563
not humanitarian	.7507	.6200	.6791	821

F1 của missing/found chỉ .0714 với 5 mẫu; vehicle damage chỉ .2169 với 18 mẫu. Các lớp này chưa đủ bằng chứng để tự động điều động nguồn lực. Recall tương đối cao ở vài lớp hiếm đi cùng Precision rất thấp, nghĩa là hệ thống bắt được thêm ca thật bằng cách tạo nhiều cảnh báo nhầm.

5.10 Hậu kiểm robustness và độ bất định

Robustness mask loại thêm 137 hàng test gần trùng đã duyệt, còn 2.032 hàng. Model, fusion và threshold được giữ nguyên, không tune lại.

Bảng 5.10: Độ nhạy khi chuyển từ canonical sang robust test.

Metric	Canonical	Robust	Chênh lệch
Informative Accuracy	.6948	.6900	-.0048
Informative F1	.8025	.7978	-.0047
Informative F2	.9045	.9016	-.0029
Informative MCC	.3325	.3340	+.0015
Humanitarian Macro-F1	.4005	.3908	-.0097
Humanitarian Weighted-F1	.5776	.5789	+.0013
Manual Review F1	.4585	.4558	-.0027

Kết luận tổng thể không phụ thuộc mạnh vào các near-duplicate đã xác nhận. Macro-F1 nhạy hơn vì robust test chỉ còn 28 injured/dead, 4 missing/found và 15 vehicle damage.

Bootstrap phân tầng 2.000 lần trên robust test cho:

Bảng 5.11: Khoảng tin cậy percentile 95%, cấu hình đã khóa.

Đại lượng	Ước lượng	CI thấp	CI cao
Informative F2	.9016	.8960	.9070
F2 gain so với always-informative	.0110	.0054	.0163
Humanitarian Macro-F1	.3908	.3636	.4208
Macro-F1 gain so với majority	.3208	.2936	.3508
Manual Review F1	.4558	.4251	.4868

CI của gain không chứa 0 dưới giả định lấy mẫu độc lập theo hàng. Tuy nhiên, row-bootstrap không mô phỏng một thảm họa hoàn toàn mới và nhiều tweet trong cùng event có thể tương quan. Informative F2 theo event nằm trong .8205–.9243; humanitarian Macro-F1 trên các lớp hiện diện nằm trong .3458–.4615. Đây là bằng chứng về domain shift còn lại.

5.11 Từ dự báo đến chính sách DSS

5.11.1 Risk Score

Classifier tạo xác suất và category, nhưng dữ liệu không có nhãn Priority. Risk Score do đó là một chính sách minh bạch, không phải một model đã được chứng minh tối ưu:

$$\text{Risk} = 0,40S_{\text{informative}} + 0,25S_{\text{severity}} + 0,20S_{\text{keyword}} + 0,15(S_{\text{severity}} \times C_{\text{category}}).$$

$S_{\text{informative}}$ là xác suất fusion theo thang 0–100; S_{severity} đến từ bảng trọng số category công khai; S_{keyword} phản ánh từ khóa khẩn cấp; và C_{category} là độ tin cậy category. Nhân confidence với severity tránh trường hợp rất chắc chắn rằng bài đăng là not-humanitarian lại làm tăng risk. Các ngưỡng 0–39, 40–69 và 70–100 tạo Low, Medium, High.

5.11.2 Routing, override và sensitivity

Tám category đều có một đội nhận mặc định. Khi conflict vượt 0,54, Supervisor được thêm song song. Một case High không bị hạ mức hoặc chặn phản ứng chỉ vì cần review; ví dụ critical conflict được chuyển Supervisor+EmergencyTeam.

Bảng 5.12: Độ nhảy của Priority theo ngưỡng trên 2.169 hàng test sạch.

Policy	Low max	Medium max	Low	Medium	High
Sensitive	29	59	651	1.186	332
Current	39	69	769	1.351	49
Strict	49	79	1.212	955	2

Sau override conflict, cấu hình hiện tại có 624 Low, 1.496 Medium và 49 High; 539 case được Manual Review, tương đương 24,85%. Chênh lệch lớn giữa ba policy cho thấy Priority phụ thuộc mạnh vào lựa chọn tổ chức. Muốn xác nhận trọng số và ngưỡng cần dữ liệu nghiệp vụ như mức ưu tiên do chuyên gia gán, thời gian phản ứng và chi phí của false negative/false positive.

Phạm vi kết luận

Các classifier, fusion và conflict detector đã được đánh giá trên nhãn có sẵn. Risk Score, Priority và Routing là nguyên mẫu chính sách có công thức, scenario test và sensitivity analysis, nhưng chưa có ground truth để khẳng định tối ưu. Hệ thống phù hợp hỗ trợ sàng lọc và điều phối sơ bộ; chưa phù hợp tự động ra quyết định sinh tử.

6 Diễn giải kết quả và khuyến nghị

6.1 Kết quả end-to-end

Hệ thống hoàn chỉnh chuyển một cặp tweet–ảnh qua chuỗi:

dữ liệu → đặc trưng → xác suất → fusion → chính sách DSS → hàng đợi.

Integration test sử dụng một bài đăng Hurricane Harvey về hoạt động cứu trợ. Hệ thống dự báo đúng nhóm rescue/donation, tạo Risk Score 54,3, Priority Medium và định tuyến Relief Team. Kiểm thử này chứng minh các module có thể phối hợp trên một ảnh thật; nó không thay thế đánh giá thống kê trên toàn test.

Dashboard vận hành trên 2.237 dòng test để người dùng có đủ batch quan sát: 50 case High và 571 case Manual Review. Các metric khoa học chỉ tính trên 2.169 dòng canonical test; trong tập này có 49 High và 539 Manual Review. Việc tách hai con số tránh nhằm dashboard workload với tập đánh giá đã lọc duplicate.

6.2 Ý nghĩa của kết quả mô hình

6.2.1 Sàng lọc informative

Fusion đạt F2 .9045, nhưng baseline luôn dự báo informative đã đạt .8939. Mức tăng .0106 là nhỏ về độ lớn thực tiễn dù CI bootstrap của gain không chứa 0. Giá trị bổ sung rõ hơn ở Accuracy (.6948 so với .6275), F1 (.8025 so với .7711), Balanced Accuracy (.5944 so với .5000) và MCC (.3325 so với 0).

Điều này có nghĩa hệ thống phân biệt hai lớp tốt hơn dự báo hăng, nhưng ưu tiên Recall khiến nhiều not-informative vẫn bị chuyển tiếp. Trong bối cảnh cứu trợ, đó có thể là đánh đổi chấp nhận được ở tầng sàng lọc đầu tiên, miễn là tầng sau có hàng đợi và con người kiểm tra. Không nên mô tả informative model là bộ lọc chính xác cao hoặc dùng nó để tự động loại bỏ mọi bài có xác suất thấp.

6.2.2 Phân loại nhu cầu humanitarian

Humanitarian fusion đạt Macro-F1 .4005, cao hơn image-only .3646, text-only .3260 và majority baseline .0686. Mức tăng so với baseline rõ hơn task informative vì model thực sự phân biệt nhiều lớp thay vì chỉ tận dụng tỷ lệ lớp dương.

Tuy nhiên, kết quả không đồng đều. F1 là .6791 ở not-humanitarian, .5645 ở other-relevant và .5363 ở rescue/donation, nhưng chỉ .0714 ở missing/found. Do đó hệ thống có giá trị cho tổ chức hàng đội tổng thể, chưa đủ tin cậy để một nhân lớp hiểm tự kích hoạt điều động sinh tử.

6.2.3 Giá trị của nhánh ảnh

Image-only tốt hơn text-only ở humanitarian Macro-F1 (.3646 so với .3260), và fusion tốt hơn cả hai. Đây là bằng chứng ảnh cung cấp thông tin bổ sung. EDA lại cho thấy nhãn text-image bất đồng cao ở lớp khẩn cấp. Hai kết quả không mâu thuẫn: ảnh có thể hữu ích trên trung bình nhưng vẫn không khớp văn bản ở nhiều case cụ thể.

Kết luận vận hành là giữ ảnh như một nguồn bằng chứng độc lập, không gán cho nó vai trò “xác nhận chân lý”. Khi hai nhánh bất đồng mạnh, hệ thống tăng nhu cầu xác minh thay vì tự chọn một nhánh.

6.3 Ý nghĩa của Manual Review

Với giới hạn công suất dev 25%, ngưỡng conflict 0,54 tạo review rate 24,85% trên canonical test. Precision .7532 nghĩa là khoảng ba phần tư case được chọn review thực sự mang cờ bất đồng theo annotation; Recall .3295 nghĩa là hệ thống chỉ thu hồi khoảng một phần ba toàn bộ case bất đồng.

Đây là cơ chế *triage*, không phải detector toàn diện. Nếu trung tâm có thêm người, có thể hạ threshold để tăng Recall. Nếu hàng đợi quá tải, cần tăng threshold hoặc ưu tiên conflict đi cùng category nghiêm trọng. Thay đổi threshold phải được giám sát bằng cả review rate và chất lượng review, không chỉ một metric.

6.4 Khuyến nghị vận hành

1. **Dùng hệ thống để sàng lọc, không tự động điều động.** Priority và Routing là đề xuất ban đầu; người điều phối xác minh nguồn, vị trí và tình trạng hiện trường trước khi phân bổ nguồn lực.
2. **Xử lý High trước nhưng vẫn phân tầng trong High.** Case injured/missing, có từ khóa khẩn cấp và địa điểm rõ nên được xem trước case thiệt hại tài sản.
3. **Review song song, không chặn phản ứng khẩn cấp.** Khi case High có conflict, Supervisor và đội phản ứng gốc cùng nhận; không chờ xác minh xong mới gửi tín hiệu cho Emergency Team.
4. **Quản lý công suất Manual Review.** Theo dõi số case theo ca trực. Capacity thấp hơn 25% cần tăng ngưỡng; capacity cao hơn có thể hạ ngưỡng sau khi kiểm tra Precision/Recall.

5. **Không tự động hóa lớp support rất thấp.** Missing/found và vehicle damage cần xác minh bắt buộc cho tới khi có thêm dữ liệu và đánh giá ngoài mẫu.
6. **Theo dõi drift theo sự kiện.** Dùng event filter, so sánh phân bố và metric. Không áp dụng nguyên threshold từ dữ liệu năm 2017 cho một thảm họa mới mà không hiệu chỉnh.
7. **Phê duyệt Risk policy bằng dữ liệu nghiệp vụ.** Cần chuyên gia gán Priority, chi phí bỏ sót, thời gian xử lý và kết quả thực tế để kiểm định trọng số Risk Score.

6.5 Trả lời tám câu hỏi của bài tập

1. Bài toán thực tế mà nhóm giải quyết là gì?

Trong thảm họa, lượng bài đăng mạng xã hội vượt khả năng đọc thủ công, nội dung nhiễu và hai nguồn text–image có thể không đồng nhất. Bài toán là chuyển dòng dữ liệu này thành một hàng đợi có cấu trúc để giảm thời gian sàng lọc và hỗ trợ điều phối.

2. Ai là người sử dụng hệ thống?

Người dùng chính là ban điều phối và các Emergency, Relief, Infrastructure, Coordination Team. Supervisor xử lý case mâu thuẫn. Người dân không trực tiếp nhận quyết định từ model.

3. Hệ thống hỗ trợ những quyết định nào?

Năm quyết định gồm: bài có đáng chú ý hay không; thuộc nhóm nhu cầu nào; Priority Low/Medium/High; đội nào tiếp nhận; và có cần Manual Review hay không. Hệ thống đề xuất, con người chịu trách nhiệm quyết định cuối.

4. Dữ liệu nào được sử dụng?

18.082 cặp tweet–ảnh CrisisMMD v2.0 từ bảy thảm họa năm 2017, gồm nhãn informative, tám lớp humanitarian, nhãn riêng text/image và cờ đồng thuận. Nhãn informative chính thức được join theo cặp ID; duplicate chính xác và gần trùng được kiểm tra trước đánh giá.

5. Dữ liệu được xử lý và phân tích như thế nào?

Văn bản được làm sạch và biểu diễn bằng TF–IDF 2.000 chiều. Ảnh được chuyển thành CLIP embedding 512 chiều với trọng số CLIP giữ nguyên. EDA dùng thống kê, K-Means, Apriori, t-SNE và conflict analysis. Sáu classifier được so sánh; họ thắng được tune trên dev rồi Late Fusion kết hợp xác suất.

6. Kết quả quan trọng nhất là gì?

Informative fusion đạt Accuracy .6948, F1 .8025, F2 .9045; F2 chỉ hơn always-informative .0106. Humanitarian fusion đạt Macro-F1 .4005 so với majority .0686. Trên robust test không tune lại, F2 còn .9016 và Macro-F1 .3908. Lớp hiếm vẫn là điểm yếu lớn nhất.

7. Hành động nào được đề xuất từ kết quả?

Dùng Priority Queue, routing theo category, review song song khi conflict, bắt buộc xác minh lớp hiểm và hiệu chỉnh ngưỡng theo công suất. Giám sát kết quả theo event để phát hiện domain shift.

8. Hạn chế và rủi ro là gì?

Dữ liệu chỉ từ năm 2017, thiếu GPS và xác minh hiện trường, lớp hiểm rất nhỏ, còn tương quan trong cùng event, có duplicate, CLIP không được thích nghi riêng cho miền, và Priority không có ground truth. Prototype chưa được kiểm thử tại production hoặc tác động thực địa.

6.6 Điều đã chứng minh và chưa chứng minh

Bảng 6.1: Biên giới của kết luận.

Đã có bằng chứng	Chưa có bằng chứng
Fusion hơn dummy về nhiều metric và hơn từng nhánh ở humanitarian	F2 gain khoảng .01 tạo lợi ích vận hành lớn
Classifier đã được so sánh và tune chỉ trên dev	Một cấu hình sẽ tổng quát hóa sang thảm họa chưa thấy
Conflict rule có Precision .7532 dưới capacity 25%	Manual Review thu hồi được mọi xung đột quan trọng
Routing phủ đủ tám category và qua scenario test	Priority threshold và severity weight là tối ưu thực tế
Robustness/CI không đảo ngược kết luận tổng thể	Lớp missing đủ tin cậy để tự động điều động
Dashboard chạy với model và cache đã khóa	Hệ thống đáp ứng bảo mật, tải và độ trễ production

Giá trị chính của dự án nằm ở sự kết hợp giữa dự báo và quản trị quyết định: model giảm khối lượng thông tin, còn chính sách minh bạch, capacity constraint, scenario test và human-in-the-loop giới hạn cách kết quả được sử dụng.

7

Sản phẩm: Dashboard hỗ trợ điều phối

7.1 Vai trò của giao diện trong DSS

Một DSS chỉ có model nhưng không có giao diện quyết định sẽ khó được sử dụng. Dashboard là lớp tương tác giữa dữ liệu, mô hình và người điều phối. Nó không chỉ hiển thị Accuracy; nó phải cho phép người dùng:

- quan sát workload và phân bố Priority;
- truy vết từ khuyến nghị về xác suất, category và conflict;
- lọc theo event, đội nhận và nhu cầu review;
- thử một trường hợp mới;
- xuất hàng đợi để tiếp tục xử lý.


Streamlit là frontend của prototype. Đây là framework Python tạo giao diện web từ widget, biểu đồ và state; trình duyệt là phía hiển thị, còn mã Python chạy ở server. Vì vậy dự án không cần thêm React hoặc một frontend riêng để đáp ứng luồng sử dụng học thuật. Frontend tách rời chỉ cần khi có API độc lập, phân quyền phức tạp, nhiều người dùng đồng thời hoặc yêu cầu giao diện cao hơn.

7.2 Năm trang chức năng


Overview	Hiển thị số case, Priority, Manual Review, routing team, category và phân bố Risk Score. Bộ lọc event giúp quan sát thay đổi workload giữa các thảm họa.
EDA	Trình bày thống kê train-only, phân bố nhãn, K-Means, Apriori, kiểm kê ảnh và bất đồng đa phương thức. Trang này giải thích căn cứ thiết kế, không dùng test để khám phá.
Model Evaluation	Hiển thị so sánh sáu model trên dev, tuning, baseline, fusion, robust test và metric từng lớp. Người đọc có thể thấy cả điểm mạnh lẫn lớp yếu.
Single-Case Demo	Nhận tweet và ảnh upload. Chế độ text-only cho kết quả nhanh; chế độ text+image chạy CLIP rồi toàn bộ fusion-DSS. Kết quả gồm xác suất, category, conflict, Risk, Priority, team và action.

Priority Queue

Cho phép lọc theo Priority, team, event và Manual Review; xem chi tiết từng hàng và tải CSV để bàn giao.




(a) Overview và workload.




(b) EDA train-only.

Hình 7.1: Tổng quan vận hành và căn cứ dữ liệu.



(a) Đánh giá mô hình.



(b) Priority Queue.

Hình 7.2: Từ bảng chứng mô hình tới hàng đợi quyết định.

7.3 Kiến trúc dữ liệu của dashboard

Dashboard không huấn luyện lại model khi người dùng mở trang. Batch test đã được xử lý thành `dashboard_test_predictions.csv`, gồm xác suất fusion, category, Risk Score, Priority, routing và cò review. Cách cache này:

- giảm thời gian tải trang;
- bảo đảm biểu đồ dùng đúng model đã khóa;
- tách đánh giá hàng loạt khỏi suy luận một trường hợp.

Single-Case Demo tải vectorizer và bốn classifier. Model ảnh được lazy-load: chỉ khi người dùng upload ảnh thì PyTorch/Transformers và CLIP mới được nạp. Nhờ vậy chế độ text-only khởi động nhanh và cloud không phải tải CLIP ở mọi trang.

7.4 Công nghệ và lý do lựa chọn

Bảng 7.1: Vai trò của các công nghệ chính.

Công nghệ	Định nghĩa/vai trò	Lý do sử dụng
Python	Ngôn ngữ thực thi pipeline	Hệ sinh thái dữ liệu/ML thống nhất, dễ tái lập.
pandas/NumPy	Bảng dữ liệu và đại số mảng	Join annotation, audit, cache và tính metric.
scikit-learn	Thư viện ML cổ điển	Cung cấp TF-IDF, sáu classifier, metric và API nhất quán.
PyTorch + Transformers	Runtime mô hình huấn luyện	Nạp CLIP và chạy forward pass ảnh.
Streamlit	Framework web bằng Python	Tạo frontend trực tiếp trên cùng logic dự án.
Plotly/Matplotlib	Thư viện trực quan	Biểu đồ tương tác trên app và hình tĩnh cho báo cáo.
Jupyter	Notebook thực thi	Lưu code, output và hình EDA/model trong một tài liệu.
XeLaTeX	Hệ dàn trang báo cáo	Hỗ trợ tiếng Việt, công thức, bảng và PDF nhất quán.

Việc dùng một stack Python giảm nguy cơ giao diện tính lại metric khác backend. Đánh đổi là Streamlit không tối ưu cho ứng dụng giao dịch thời gian thực hoặc UI tùy biến sâu.

7.5 Chạy local và triển khai Streamlit Community Cloud

7.5.1 Chạy local đầy đủ

```
pip install -r requirements.txt
streamlit run app/streamlit_app.py
```

Nếu cần tái tạo toàn bộ dữ liệu, embedding và mô hình:

```
python -m scripts.run_all
```

Lệnh tái tạo đầy đủ cần corpus ảnh CrisisMMD khoảng 1,8 GB và thời gian chạy CLIP. Khi model/cache đã có, không cần chạy lại pipeline trước khi mở dashboard.

7.5.2 Bundle cloud

Repository cloud chứa:

- processed train/test cần cho EDA và dashboard;
- vectorizer và bốn classifier đã khóa;
- cấu hình fusion và các bảng metric;
- mã Streamlit cùng requirements CPU.

Raw image corpus và ma trận embedding lớn không được đưa lên Git. Trang EDA đọc processed CSV. Single-Case Demo nhận ảnh upload; lần suy luận ảnh đầu tiên tải CLIP nên có cold start, còn text-only dùng ngay các model nhỏ.

Cấu hình deploy:

Repository	dafiiscoding/ml-dss
Branch	main
Main file	app/streamlit_app.py
Python	3.12
Secrets	Không yêu cầu

Các bước trên được mô tả chi tiết trong docs/DEPLOY_STREAMLIT.md.

7.6 Kiểm thử giao diện và giới hạn triển khai

Sáu endpoint Streamlit gồm trang chính và năm trang chức năng được chạy bằng AppTest trong môi trường cloud Python 3.12. GitHub Actions kiểm tra bundle, dependency và text-only inference sau mỗi lần push. Unit test kiểm tra logic dữ liệu, duplicate mask, tuning, robustness và DSS; integration test chạy một ảnh thật qua CLIP.

Những kiểm thử này chứng minh app khởi động và luồng chính không phát sinh exception. Chúng chưa chứng minh khả năng chịu tải nhiều người dùng, bảo mật upload, phân quyền, lưu audit log hoặc SLA. Nếu triển khai thực tế cần thêm API, authentication, giới hạn file, quét nội dung, logging, giám sát latency và chính sách bảo vệ dữ liệu.

Phạm vi sản phẩm

Dashboard là một prototype DSS có frontend hoàn chỉnh cho học tập và trình diễn: người dùng có thể xem bằng chứng, thử ca mới và thao tác hàng đợi. Nó chưa phải hệ thống chỉ huy production và không được dùng để tự động điều động nguồn lực.

8 Kết luận và hướng phát triển

8.1 Kết luận

Dự án xây dựng một hệ hỗ trợ quyết định đa phương thức trên 18.082 cặp tweet–ảnh Crisis-MMD. Quy trình gồm hợp nhất nhãn chính thức, kiểm soát duplicate, EDA train-only, TF-IDF, CLIP frozen embedding, so sánh sáu classifier, tuning trên dev, Late Fusion, Risk Score, Routing, Manual Review và dashboard.

Với informative, Late Fusion đạt Accuracy .6948, F1 .8025 và F2 .9045 trên canonical test. F2 chỉ hơn always-informative .0106, nên kết luận được đặt trên nhiều metric thay vì một chỉ số. Với humanitarian, fusion đạt Macro-F1 .4005, cao hơn majority baseline .0686 và từng nhánh đơn lẻ. Robust test giữ F2 .9016 và Macro-F1 .3908 mà không tune lại; bootstrap cho thấy kết luận tổng thể ổn định, nhưng lớp hiếm và biến động theo event còn lớn.

Đóng góp quan trọng nhất không phải một Accuracy cao, mà là cách chuyển kết quả mô hình thành một quyết định có giới hạn: công thức Risk công khai, routing đủ tám lớp, review theo conflict dưới capacity, và con người giữ quyền xác minh. Ranh giới giữa dự báo đã được đánh giá và Priority chưa có ground truth được trình bày rõ.

8.2 Hạn chế

- Dữ liệu chỉ phản ánh bảy thảm họa năm 2017 và chưa đại diện mạng xã hội hiện tại hoặc ngôn ngữ ngoài tiếng Anh.
- Split chứa nhiều event ở cả train và test; chưa đo tổng quát hóa tới một event hoàn toàn chưa thấy.
- Ba lớp khẩn cấp có support rất thấp; metric riêng lớp có CI rộng.
- CLIP được giữ cố định, không thích nghi riêng cho ảnh thảm họa.
- Dữ liệu thiếu vị trí đáng tin, độ xác thực nguồn và kết quả xử lý thực địa.
- Risk Score/Priority là policy giả định, không phải optimum học được.
- Cloud prototype chưa có authentication, audit log và kiểm thử tải.

8.3 Hướng phát triển

1. **Đánh giá theo event chưa thấy:** dùng leave-one-event-out hoặc group split để đo domain shift nghiêm ngặt hơn.
2. **Bổ sung dữ liệu lớp hiếm:** thu thập và thẩm định thêm case injured, missing và vehicle; cân nhắc active learning với chuyên gia.
3. **Trích xuất vị trí:** dùng Named Entity Recognition, geocoding và xác minh địa danh để biến tweet thành thông tin có thể điều phối.
4. **Hiệu chỉnh xác suất:** đánh giá reliability diagram, Brier score và calibration error trước khi dùng xác suất cho policy.
5. **Học policy từ nghiệp vụ:** thu Priority do chuyên gia gán, thời gian phản ứng và chi phí sai số để tối ưu Risk/threshold.
6. **Fusion thích nghi:** thử trọng số theo category hoặc gating model, nhưng phải giữ test độc lập và so với late-fusion tuyến tính.
7. **Giám sát production:** thêm authentication, audit log, drift monitor, latency/error telemetry và quy trình human override.

Hướng phát triển ưu tiên dữ liệu và kiểm định chính sách trước khi tăng độ phức tạp mô hình. Một DSS đáng tin không chỉ cần dự báo tốt hơn mà còn phải chứng minh được khi nào nên sử dụng, khi nào cần dừng và ai chịu trách nhiệm quyết định.

A Phụ lục

A.1 Khai báo sử dụng công cụ AI

Theo yêu cầu công khai công cụ hỗ trợ, nhóm có sử dụng Claude và OpenAI Codex để gợi ý cấu trúc, hỗ trợ rà soát mã nguồn, kiểm thử và biên tập diễn đạt. Nhóm chịu trách nhiệm lựa chọn phương pháp, chạy chương trình, kiểm tra kết quả với dữ liệu CrisisMMD, đối chiếu metric và xác nhận nội dung báo cáo. Nội dung do công cụ sinh ra không được xem là bằng chứng nếu không có kết quả thực thi hoặc nguồn tham khảo tương ứng.

A.2 Bảng tự đánh giá

Bảng A.1: Tự đánh giá theo các nhóm tiêu chí của bài tập.

Tiêu chí	Tối đa	Tự đánh giá	Căn cứ
Hiểu bài toán và quyết định	15	14	Chương 1–2, stakeholder và năm quyết định
Dữ liệu và tiền xử lý	15	15	Nhấn chính thức, feature engineering, leakage audit
EDA và insight	20	19	Train-only, event, K sweep, Apriori, ảnh, conflict
Mô hình và DSS	20	18	Sáu model, tuning, fusion, robustness, policy test
Diễn giải và khuyến nghị	15	14	Chương 6, capacity, giới hạn bằng chứng
Báo cáo và minh chứng	10	9	PDF, notebook có output, dashboard, metrics
Tổ chức nhóm	5	2	Đã có danh sách; phân công/tỷ lệ cần nhóm xác nhận
Tổng	100	91	Không tự chấm tối đa ở phần chưa hoàn tất

A.3 Cấu hình và siêu tham số chính

Thành phần	Cấu hình đã khóa
TF-IDF	2.000 đặc trưng, word n-gram (1,2), stopwords tiếng Anh, L_2 .
Text informative	Linear SVM $C = 3$, class weight balanced, sigmoid calibration 3-fold.
Text humanitarian	Logistic Regression $C = 1$, class weight balanced.
Image informative	k-NN $k = 41$, distance weighting, Euclidean trên CLIP normalized.
Image humanitarian	Logistic Regression $C = 1$, class weight balanced.
Decision Tree	max depth 20 trong vòng so sánh thuật toán.
Random Forest	200 cây, balanced subsample.
K-Means	$K = 2, \dots, 12$, $n_{init} = 10$; $K = 8$ để đối chiếu taxonomy.
Apriori	min support .005, min confidence .25 trên transaction đã lọc.
CLIP	openai/clip-vit-base-patch32, frozen, embedding 512 chiều.
Late Fusion	Informative text/image .70/.30, threshold .38; category .55/.45.
Manual Review	Conflict threshold .54, capacity dev tối đa 25%.

A.4 Tập minh chứng và khả năng tái lập

- Notebook đã thực thi: notebooks/02_edu.ipynb và 03_modeling.ipynb.
- Kiểm tra dữ liệu: reports/metrics/data_quality_summary.json và data/processed/split_integrity.csv.
- Tuning và kết quả: reports/metrics/*_tuning.csv, tuned_model_summary.json và các bảng fusion.
- Robustness: canonical/robust comparison, bootstrap, event và class stability trong reports/metrics/.
- DSS: dss_scenarios.csv, dss_threshold_sensitivity.csv.
- Kiểm thử: 41 unit test, 6 Streamlit AppTest và integration ảnh thật.
- Mã nguồn: <https://github.com/dafiiscoding/ml-dss>.

A.5 Thông tin còn cần nhóm xác nhận

Tên, MSSV, giảng viên và nhóm đã được điền ở đầu báo cáo. Trước khi nộp chính thức, nhóm cần phân công các gói công việc và điền tỷ lệ đóng góp thực tế tại `docs/team_info.json`; tổng tỷ lệ của bốn thành viên cần bằng 100%.

Tài liệu tham khảo

- [1] Daniel J. Power. *Decision Support Systems: Concepts and Resources for Managers*. Quorum Books, 2002.
- [2] Herbert A. Simon. *The New Science of Management Decision*. Harper & Brothers, 1960.
- [3] Firoj Alam, Ferda Ofli, Muhammad Imran. *CrisisMMD: Multimodal Twitter Datasets from Natural Disasters*. ICWSM, 2018. <https://crisisnlp.qcri.org/crisismmd>
- [4] Ferda Ofli, Firoj Alam, Muhammad Imran. *Analysis of Social Media Data using Multimodal Deep Learning for Disaster Response*. ISCRAM, 2020.
- [5] Alec Radford et al. *Learning Transferable Visual Models From Natural Language Supervision (CLIP)*. ICML, 2021.
- [6] Gerard Salton and Christopher Buckley. *Term-weighting approaches in automatic text retrieval*. Information Processing & Management, 24(5), 1988.
- [7] Corinna Cortes and Vladimir Vapnik. *Support-vector networks*. Machine Learning, 20, 1995.
- [8] Leo Breiman. *Random Forests*. Machine Learning, 45, 2001.
- [9] J. MacQueen. *Some Methods for Classification and Analysis of Multivariate Observations*. Proceedings of the Fifth Berkeley Symposium, 1967.
- [10] Rakesh Agrawal and Ramakrishnan Srikant. *Fast Algorithms for Mining Association Rules*. Proceedings of VLDB, 1994.
- [11] Laurens van der Maaten and Geoffrey Hinton. *Visualizing Data using t-SNE*. Journal of Machine Learning Research, 2008.
- [12] Pedregosa et al. *Scikit-learn: Machine Learning in Python*. JMLR, 2011.
- [13] Sebastian Raschka. *MLxtend: Providing machine learning and data science utilities and extensions to Python's scientific computing stack*. JOSS, 2018.
- [14] Slide bài giảng và hướng dẫn bài tập nhóm học phần Hệ hỗ trợ quyết định do TS. Lê Hải Hà cung cấp, học kỳ 2025.2.