

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN – TIN



BÁO CÁO BÀI TẬP NHÓM
HỌC PHẦN HỆ HỖ TRỢ QUYẾT ĐỊNH

HỆ HỖ TRỢ QUYẾT ĐỊNH ĐIỀU PHỐI GIAO
PIZZA

DỰA TRÊN DỰ BÁO ĐƠN GIAO TRỄ

A Decision Support System for Pizza Delivery Operations

Giảng viên: TS. Lê Hải Hà

Giảng viên giao đề tài: TS. Trịnh Đình Thắng

Nhóm thực hiện: Nhóm 29

Học kỳ: 2025–2026

Hà Nội, tháng 6 năm 2026

Bảng phân công công việc

Phân công và tỷ lệ đóng góp của các thành viên Nhóm 29

Thành viên	MSSV	Công việc chính	Tỷ lệ	Minh chứng
Đoàn Danh Long	20237354	Điều phối pipeline DSS, mô hình hóa và tổng hợp báo cáo	25%	modeling.py, NB03, model_summary.json, báo cáo
Vũ Quang Vinh	20237408	EDA, customer behavior và kiểm định giả thiết	25%	eda.py, NB02, hypothesis_tests.csv
Nguyễn Đăng Đức	20237312	Feature engineering, forecasting, recommendation và Power BI pack	25%	business_analysis.py, NB05, powerbi/
Nguyễn Tuấn Anh	20237293	Dashboard Streamlit, tối ưu vận tải, kiểm thử	25%	streamlit_app.py, transport_optimization.py, tests/

Lời mở đầu

Trong vận hành giao đồ ăn, một đơn giao trễ không chỉ là một lỗi thời gian mà còn tác động đến trải nghiệm khách hàng, chi phí chăm sóc khách hàng và khối lượng điều phối. Nếu chỉ nhìn từng đơn riêng lẻ, người quản lý khó biết đơn nào nên được theo dõi trước, ca nào cần tài xế dự phòng và thời điểm nào cần bố trí thêm nhân sự. Một hệ hỗ trợ quyết định vì vậy cần kết hợp dữ liệu, mô hình dự báo và quy tắc vận hành minh bạch để đưa ra khuyến nghị có thể kiểm tra.

Báo cáo này trình bày một nguyên mẫu DSS trên bộ dữ liệu pizza delivery của Kaggle. Do dữ liệu có nhiều dấu hiệu được sinh tự động, nhóm không xem bộ dữ liệu như log vận hành thật hoàn chỉnh. Ngược lại, điểm yếu này được đưa vào quy trình học thuật: audit leakage, reverse-engineering generator, đánh giá mô hình trên train/dev/test, sau đó chuyển kết quả dự báo thành hàng đợi ưu tiên, dashboard và kịch bản tối ưu phân công tài xế.

Tóm tắt

Báo cáo xây dựng một Hệ hỗ trợ quyết định điều phối giao pizza dựa trên dữ liệu 1.004 đơn hàng từ Kaggle. Mục tiêu là dự báo khả năng đơn hàng bị giao trễ trước khi đơn hoàn tất, đồng thời hỗ trợ phân tích hành vi khách hàng, dự báo nhu cầu minh họa, đề xuất staffing và tạo hàng đợi ưu tiên cho điều phối.

Quy trình gồm bảy phần: xác định bài toán DSS; audit dữ liệu và chống leakage; phân tích dữ liệu synthetic; EDA và kiểm định giả thiết; xây dựng mô hình dự báo; chuyển dự báo thành Risk Score, Priority và Recommended Action; cuối cùng là dashboard Streamlit, Power BI data pack và kịch bản assignment theo tình thần bài toán vận tải. Vì nguồn dữ liệu chỉ cung cấp nhãn `is_delayed` mà không mô tả SLA, nhóm suy luận ranh giới nhãn bằng cách thử các luật ngưỡng trên `delivery_duration_min`. Kết quả cho thấy các đơn đúng giờ có duration lớn nhất 30 phút, các đơn trễ có duration nhỏ nhất 35 phút; do duration nằm trên lưới 5 phút, hai luật `duration > 30` và `duration >= 35` là tương đương trên dataset. Mô hình Logistic Regression trên feature set compact được chọn theo F2 trên dev và đạt trên test: Accuracy 0,9602; Balanced Accuracy 0,9661; F1 0,9111; F2 0,9491; MCC 0,8889. Tuy vậy, vì dữ liệu có tính synthetic, các phân tích forecast, preference và brand được diễn giải như minh họa phương pháp, không phải kết luận kinh doanh sản xuất.

Từ khóa: DSS, Pizza Delivery, Supervised Learning, Data Forensics, Forecasting, Transportation Assignment, Dashboard.

Tám câu hỏi bắt buộc

Theo hướng dẫn học phần, báo cáo trả lời trực diện tám câu hỏi sau; chi tiết nằm ở các chương được dẫn chiếu.

Câu hỏi	Trả lời ngắn (chi tiết ở chương)
Bài toán thực tế là gì?	Dự báo đơn pizza có nguy cơ giao trễ <i>trước khi giao</i> để hỗ trợ điều phối (Chương 1).
Ai dùng kết quả?	Quản lý vận hành / điều phối viên của chuỗi giao pizza (Chương 1).
Người dùng cần ra quyết định gì?	Đơn nào theo dõi/ưu tiên trước, khi nào chuẩn bị tài xế dự phòng, gửi cảnh báo khách (Chương 1, 6).
Dữ liệu nào được dùng?	1.004 đơn Kaggle (37 cột sau FE); chỉ dùng feature biết trước khi giao, cấm cột leakage (Chương 3).
Xử lý & phân tích thế nào?	Audit + chống leakage + split stratified; EDA, kiểm định, forensics; so sánh 6 model + CV, chọn theo F2 (Chương 3–5).
Kết quả quan trọng nhất?	Logistic Regression compact: test F2 0,9491; MCC 0,8889 (kèm CI bootstrap); vượt cả hai baseline (Chương 5).
Đề xuất hành động nào?	Risk Score → Priority → Recommended Action + hàng đợi + gán tài xế; xem mục Khuyến nghị (Chương 6).
Hạn chế/rủi ro/điều kiện áp dụng?	Dữ liệu synthetic gần tắt định, n nhỏ; điểm cao không phản ánh năng lực dự báo thật; forecast/brand chỉ minh họa (Chương 6–7).

Bảng thuật ngữ

Thuật ngữ	Giải nghĩa
DSS	Decision Support System – Hệ hỗ trợ quyết định; hệ thống kết hợp dữ liệu, mô hình và giao diện để hỗ trợ con người ra quyết định.
Đơn trễ	Đơn có <code>is_delayed=True</code> ; trong dataset này nhân có ranh giới quan sát giữa 30 và 35 phút giao hàng.
Leakage	Rò rỉ thông tin tương lai vào feature, làm metric mô hình bị ảo.
Feature compact	Tập feature đã loại các cột công thức/trùng thông tin, chỉ giữ biến có thể biết tại thời điểm nhận đơn.
Dev set	Tập phát triển dùng để chọn mô hình/siêu tham số trước khi báo test.
Hyperparameter tuning	Dò siêu tham số bằng train/CV/dev; không dùng test để chọn cấu hình nhằm tránh leakage.
GridSearchCV	Thử toàn bộ lưới siêu tham số bằng cross-validation rồi chọn cấu hình có metric trung bình tốt nhất.
F2	Chỉ số F-score đặt trọng số Recall cao hơn Precision; phù hợp khi bỏ sót đơn trễ là lỗi quan trọng.
MCC	Matthews Correlation Coefficient; chỉ số cân bằng cho bài toán nhị phân mất cân bằng.
Data forensics	Phân tích truy ngược dấu vết sinh dữ liệu: công thức tắt định, lượng tử hóa, tính đồng đều và tín hiệu artifact.
Risk Score	Điểm rủi ro do tăng DSS tính từ xác suất mô hình và các yếu tố vận hành.
Priority	Mức ưu tiên Low/Medium/High suy từ Risk Score để sắp xếp hàng đợi.
Assignment	Bài toán gán đơn cho tài xế giả lập theo chi phí nhỏ nhất; trong dự án chỉ là kịch bản prescriptive demo.

Mục lục

Bảng phân công công việc	i
Lời mở đầu	ii
Tóm tắt	iii
Tám câu hỏi bắt buộc	iv
Bảng thuật ngữ	v
1 Giới thiệu bài toán	1
1.1 Bối cảnh và động cơ	1
1.2 Phạm vi đề tài	1
1.3 Câu hỏi nghiên cứu và quyết định	2
2 Cơ sở lý thuyết và phương pháp luận	3
2.1 Khái niệm hệ hỗ trợ quyết định	3
2.2 Pipeline phân tích dữ liệu	3
2.3 Các kỹ thuật sử dụng	3
2.3.1 Phân tích mô tả, kiểm định và data forensics	4
2.3.2 Mô hình phân loại	4
2.3.3 Forecasting, recommendation và tối ưu vận tải	4
3 Dữ liệu và kiểm soát chất lượng	5
3.1 Nguồn dữ liệu	5
3.2 Suy luận nhân trỗi, leakage và feature contract	5
3.3 Data realism và reverse-engineering	7
3.3.1 Cách phát hiện bảy công thức tắt định	7
3.4 Thiết kế split	9
4 Phân tích khám phá và bài toán kinh doanh	10
4.1 Phân bố nhãn và yếu tố vận hành	10
4.1.1 Độ trỗi và severity	10

4.2	Customer behavior	12
4.3	Phụ thuộc theo brand, location và state	15
4.4	Kiểm định giả thiết	16
4.5	Forecasting, staffing và recommendation	16
5	Mô hình dự báo đơn giao trễ	18
5.1	Thiết kế thực nghiệm	18
5.2	So sánh feature set và model	18
5.3	Dò siêu tham số sau khi chọn model	19
5.4	Kiểm soát F-beta threshold và split may mắn	19
5.5	Kết quả test và baseline	21
6	Tầng DSS, dashboard và tối ưu vận tải	23
6.1	Từ xác suất đến quyết định	23
6.2	Kịch bản assignment	25
6.3	Dashboard Streamlit và Power BI	26
7	Minh chứng tái lập và đánh giá dự án	27
7.1	Runbook và kiểm thử	27
7.2	Đối chiếu yêu cầu học phần	27
7.3	Các câu hỏi phản biện đã kiểm soát	28
7.4	Khuyến nghị ra quyết định	28
7.5	Giới hạn	29
8	Kết luận và hướng phát triển	30
A	Phụ lục: Artifact chính	31
B	Phụ lục: Bảng tự chấm điểm của nhóm	32
C	Phụ lục: Khai báo sử dụng AI	33

Danh sách hình

2.1	Quy trình logic của hệ hỗ trợ quyết định giao pizza.	3
3.1	Số mismatch khi thử các luật ngưỡng để phục dựng nhãn trễ.	6
3.2	Số lượng cảnh báo trong data realism audit.	8
3.3	Mutual information của biến categorical trước và sau khi kiểm soát distance band.	9
4.1	Phân bố đơn đúng giờ và đơn trễ.	10
4.2	Duration theo lưới 5 phút và nhãn trễ.	11
4.3	Tỷ lệ trễ theo traffic level.	12
4.4	Tỷ lệ trễ theo các yếu tố vận hành chính.	12
4.5	Tỷ lệ đơn hàng theo size.	13
4.6	Các loại pizza được đặt nhiều nhất.	13
4.7	Ma trận số đơn theo pizza type và size.	14
4.8	Phân phối độ phức tạp pizza.	14
4.9	Delay rate theo restaurant brand.	15
4.10	Cơ cấu sản phẩm theo restaurant brand.	15
4.11	Delay rate theo state code suy ra từ location.	16
4.12	Nhu cầu theo tháng và dự báo seasonal-naive.	17
4.13	Forecast share pizza size theo tháng.	17
5.1	Quét ngưỡng F-beta trên dev.	20
5.2	Phân phối F2 qua 100 lần chia lại train/dev.	21
6.1	Đóng góp trung bình của từng thành phần vào Risk Score.	24
6.2	Calibration: delay rate thực tế theo priority band.	25
6.3	Độ nhạy số đơn High priority khi thay ngưỡng.	25

1 Giới thiệu bài toán

1.1 Bối cảnh và động cơ

Các nền tảng giao đồ ăn vận hành trong môi trường có nhiều biến động: khoảng cách đơn hàng, traffic, giờ cao điểm, đặc điểm đơn, phương thức thanh toán và khả năng đáp ứng của nhân sự. Một quyết định vận hành thường không thể chỉ dựa trên trực giác từng đơn. Người quản lý cần một hệ thống giúp trả lời:

1. đơn nào có nguy cơ giao trễ trước khi đơn hoàn tất;
2. yếu tố nào đang làm tăng rủi ro trễ;
3. đơn nào cần theo dõi hoặc can thiệp trước;
4. khung giờ nào cần bố trí thêm nhân sự;
5. kết quả phân tích nên được trình bày thế nào để ra quyết định.

Dự án đặt bài toán không chỉ là “dự báo đúng/sai”, mà là xây dựng một DSS có đủ ba lớp: phân tích dữ liệu, mô hình dự báo và khuyến nghị hành động. Mô hình học máy chỉ là một thành phần tạo bằng chứng; quyết định cuối cùng vẫn thuộc về người quản lý.

1.2 Phạm vi đề tài

Dữ liệu sử dụng là bộ *Pizza Delivery Data with Enhanced Features* trên Kaggle. Dự án không kết nối hệ thống đặt hàng thật, không định vị tài xế thật, không gửi thông báo cho khách hàng và không tự động điều phối. Đầu ra trong phạm vi môn học gồm:

- bộ dữ liệu đã chuẩn hóa và split train/dev/test;
- phân tích EDA, kiểm định giả thiết, data forensics và customer behavior;
- mô hình dự báo `is_delayed`;
- Risk Score, Priority và Recommended Action;
- dashboard Streamlit và Power BI-ready data pack;
- kịch bản phân công tài xế giả lập theo chi phí.

1.3 Câu hỏi nghiên cứu và quyết định

Báo cáo được tổ chức quanh các câu hỏi sau:

1. Dataset có đủ tin cậy để dùng như log vận hành thật không?
2. Có thể phát hiện và loại bỏ leakage trong bài toán dự báo đơn trễ không?
3. Những biến trước giao hàng nào liên quan đến rủi ro trễ?
4. Mô hình nào phù hợp nhất khi chọn trên dev và báo test một lần?
5. Làm thế nào chuyển xác suất trễ thành khuyến nghị vận hành dễ hiểu?
6. Có thể minh họa forecasting, recommendation và tối ưu vận tải trong phạm vi dataset nhỏ này không?

Quan điểm xuyên suốt

Vì dữ liệu có nhiều dấu hiệu synthetic, báo cáo ưu tiên tính trung thực học thuật: kết quả mô hình và dashboard được trình bày như nguyên mẫu DSS, còn các kết luận forecast, preference và brand không được diễn giải như bằng chứng thị trường thật.

2 Cơ sở lý thuyết và phương pháp luận


2.1 Khái niệm hệ hỗ trợ quyết định

Hệ hỗ trợ quyết định là hệ thống thông tin kết hợp dữ liệu, mô hình phân tích và giao diện tương tác để hỗ trợ con người trong các bài toán bán cấu trúc hoặc khó tự động hóa hoàn toàn [1]. Trong dự án này, DSS không thay người quản lý quyết định, mà cung cấp:

- bằng chứng dữ liệu: tỷ lệ trễ, phân bố đơn, kiểm định giả thiết;
- bằng chứng dự báo: xác suất đơn bị trễ và metric đánh giá;
- chính sách hành động: Risk Score, Priority và khuyến nghị xử lý.

Theo chu trình ra quyết định của Simon [2], dự án bao phủ các pha: nhận biết vấn đề qua audit/EDA, thiết kế phương án qua model và rule DSS, lựa chọn qua Priority/Recommended Action, còn pha thực thi ngoài đời được ghi là hướng phát triển vì dataset không có phản hồi vận hành thật.

2.2 Pipeline phân tích dữ liệu



Hình 2.1: Quy trình logic của hệ hỗ trợ quyết định giao pizza.

Pipeline được thiết kế theo nguyên tắc: mọi biến dùng để dự báo phải biết trước hoặc tại thời điểm nhận đơn; mô hình được fit trên train, chọn trên dev và báo test sau khi khóa.

2.3 Các kỹ thuật sử dụng

2.3.1 Phân tích mô tả, kiểm định và data forensics

EDA trả lời dữ liệu có đặc điểm gì; kiểm định giả thiết đánh giá mối liên hệ giữa biến categorical và nhãn trễ; data forensics truy ngược dấu vết sinh dữ liệu. Ba nhóm kỹ thuật này giúp phân biệt insight có ý nghĩa vận hành với artifact do generator tạo ra.

Các kiểm định trong dự án gồm chi-square independence cho biến categorical, goodness-of-fit với phân phối đều, mutual information trước/sau khi kiểm soát distance band và ablation feature trong mô hình.

2.3.2 Mô hình phân loại

Bài toán dự báo `is_delayed` là phân loại nhị phân mất cân bằng. Dự án so sánh Logistic Regression, Decision Tree, Gaussian Naive Bayes, k-NN, SVM và Random Forest. Các biến số được chuẩn hóa, biến categorical được one-hot encoding trong pipeline scikit-learn để tránh fit transform sai split.

Metric chính là F2 vì bỏ sót đơn trễ thường bất lợi hơn cảnh báo dư. Tuy vậy, F2 được báo cùng Accuracy, Balanced Accuracy, F1 và MCC để tránh diễn giải một chiều.

2.3.3 Forecasting, recommendation và tối ưu vận tải

Forecasting được dùng để minh họa planning: dự báo tổng đơn theo tháng và share size/type bằng seasonal-naive. Recommendation dùng luật phổ biến theo context (nhà hàng, size, location, time segment). Tối ưu vận tải được mô phỏng bằng bài toán assignment chi phí nhỏ nhất trên nhóm đơn High priority; driver/fleet là giả lập vì dataset không có bảng tài xế thật.

3 Dữ liệu và kiểm soát chất lượng

3.1 Nguồn dữ liệu

Dataset được lấy từ Kaggle:

`akshaygaikwad448/pizza-delivery-data-with-enhanced-features`

File gốc là `Enhanced_pizza_sell_data_2024-25.xlsx`. Sau chuẩn hóa tên cột và feature engineering, dataset có 37 cột.

Bảng 3.1: Tóm tắt dữ liệu

Chỉ tiêu	Giá trị
Số đơn hàng	1.004
Số cột gốc	25
Số cột sau feature engineering	37
Missing value	0
Duplicate order id	0
Đơn trễ	210
Đơn đúng giờ	794
Tỷ lệ trễ	20,92%
Thời gian nhỏ nhất	2024-01-05
Thời gian lớn nhất	2026-07-07


3.2 Suy luận nhãn trễ, leakage và feature contract

Nguồn dữ liệu có cột `is_delayed` nhưng không kèm tài liệu SLA nói rõ bao nhiêu phút thì được xem là trễ. Vì vậy nhóm không giả định trước mốc 30 phút, mà suy luận từ dữ liệu: với từng luật ngưỡng đơn giản trên `delivery_duration_min`, tính số dòng mà luật dự đoán khác với nhãn gốc.

Bảng 3.2: Suy luận ranh giới nhãn `is_delayed`

Kiểm tra	Kết quả
Duration lớn nhất của nhóm on-time	30 phút
Duration nhỏ nhất của nhóm delayed	35 phút
Mismatches của luật <code>duration>30</code>	0/1.004
Mismatches của luật <code>duration>=35</code>	0/1.004

Do `duration` chỉ nhận các giá trị bội số 5, hai luật `duration>30` và `duration>=35` là không phân biệt được bằng dữ liệu quan sát. Báo cáo dùng cách viết `duration>30` như một biểu diễn ngắn gọn của ranh giới hiệu dụng nằm giữa 30 và 35 phút, không phải SLA do nhóm tự đặt.

**Hình 3.1:** Số mismatch khi thử các luật ngưỡng để phục dựng nhãn trễ.

Kết quả này dẫn đến kết luận leakage: các biến sau giao hàng bị cấm trong mô hình dự báo vì chúng chứa trực tiếp hoặc gián tiếp thông tin tạo ra nhãn:

- `delivery_time`;
- `delivery_duration_min`;
- `delivery_efficiency_min_per_km`;
- `delay_min`;
- `restaurant_avg_time`.

Feature set chính chỉ dùng biến có thể biết trước khi giao: khoảng cách, số topping, giờ đặt, size encoding, nhà hàng, địa điểm, loại pizza, traffic, payment category, peak hour, weekend và tháng đặt hàng.

3.3 Data realism và reverse-engineering

Dataset có nhiều dấu hiệu được tạo bằng hàm sinh dữ liệu hơn là log vận hành thật. Bảng 3.3 tóm tắt các phát hiện chính.

Bảng 3.3: Dấu hiệu dữ liệu synthetic

Kiểm tra	Phát hiện
Missing value	Không có ô thiếu, bất thường với dữ liệu vận hành thực tế.
Thời gian	File tên 2024–25 nhưng order_time kéo tới 2026-07-07.
Duration	Chỉ có 8 giá trị: 15, 20, 25, 30, 35, 40, 45, 50.
Công thức tắt định	7 công thức/target khớp tuyệt đối, gồm estimated duration, topping density, complexity, traffic impact, delay, efficiency và target.
Categorical artifact	Location và pizza type còn tín hiệu mạnh sau khi kiểm soát distance band.
Brand	Count từng brand 194–212 nhưng homogeneity tests không ủng hộ kết luận các brand đồng nhất thống kê.


3.3.1 Cách phát hiện bảy công thức tắt định


Các công thức tắt định không được giả định trước. Nhóm dùng quy trình phục dựng: đọc tên cột và quan hệ nghiệp vụ có khả năng xảy ra, đề xuất biểu thức ứng viên, tính biểu thức đó trên toàn bộ 1.004 dòng, sau đó đo sai số lớn nhất giữa cột gốc và biểu thức. Một công thức chỉ được xem là khớp tuyệt đối khi $\max_abs_error=0$.

Bảng 3.4: Các công thức tắt định được phục dựng

Cột	Công thức khớp	Cách tìm và kiểm chứng
estimated_duration_min	$2.4 * \text{distance_km}$	Kiểm tra tỷ lệ estimated/distance; tỷ lệ bằng 2,4 cho mọi dòng.
topping_density	$\text{toppings_count} / \text{distance_km}$	Tên cột gợi ý mật độ; kiểm tra số topping chia cho khoảng cách.
pizza_complexity	$\text{toppings_count} * \text{size_score}$	Mã hóa Small=1, Medium=2, Large=3, XL=4 rồi nhân với số topping.
traffic_impact	Low=1, Medium=2, High=3	Ba giá trị 1/2/3 khớp một-một với ba mức traffic.
delay_min	duration-estimated	Theo định nghĩa delay hậu nghiệm; kiểm tra duration trừ estimated.
delivery_efficiency	duration/distance	Tên cột là phút/km; kiểm tra duration chia khoảng cách.
is_delayed	ranh giới giữa 30 và 35 phút	Thử các luật ngưỡng duration; duration>30 và duration>=35 đều mismatch 0 dòng trên lưới 5 phút.

Kết quả này dẫn tới hai quyết định: các cột hậu nghiệm như duration, delay, efficiency không được dùng làm feature dự báo; các cột trùng thông tin như estimated duration, topping density, complexity và traffic impact chỉ dùng để giải thích/audit, còn mô hình chính dùng feature compact ít trùng lặp hơn.

**Hình 3.2:** Số lượng cảnh báo trong data realism audit.



Hình 3.3: Mutual information của biến categorical trước và sau khi kiểm soát distance band.

Ý nghĩa học thuật

Phần reverse-engineering không nhằm “sửa” dataset, mà nhằm đặt giới hạn đúng cho báo cáo: có thể dùng dữ liệu để minh họa quy trình DSS, nhưng không nên kết luận rằng brand, location hoặc preference phản ánh thị trường pizza thật.

3.4 Thiết kế split

Khi thử lấy 20% cuối theo thời gian, tập test không có mẫu delayed. Vì vậy, pipeline dùng stratified split cố định để phục vụ đánh giá học thuật.


Bảng 3.5: Split train/dev/test

Split	Số dòng	Delayed	On-time
Train	602	126	476
Dev	201	42	159
Test	201	42	159

4 Phân tích khám phá và bài toán kinh doanh

4.1 Phân bố nhãn và yếu tố vận hành


Delayed chiếm 20,92% nên Accuracy một mình có thể gây hiểu nhầm: baseline luôn dự báo on-time đã đạt Accuracy 0,7910 nhưng F2 bằng 0 vì bỏ sót toàn bộ đơn trễ.



Hình 4.1: Phân bố đơn đúng giờ và đơn trễ.

4.1.1 Độ trễ và severity

Phân tích duration được dùng để hiểu nhãn và mức độ trễ, không dùng làm feature dự báo. Nhóm on-time có duration trung bình 26,27 phút, trung vị 30 phút và giá trị lớn nhất 30 phút. Nhóm delayed có duration trung bình 41,67 phút, trung vị 40 phút và giá trị nhỏ nhất 35 phút. Vì duration chỉ có các mốc 15, 20, 25, 30, 35, 40, 45, 50, nhãn trễ có ranh giới quan sát giữa 30 và 35 phút.




Hình 4.2: Duration theo lưới 5 phút và nhãn trễ.

Bảng 4.1: Severity của đơn trễ


Bucket	Orders	Delayed	Avg distance	High traffic share
On-time ≤ 30	794	0	4,20	20,53%
Late 35	44	44	5,52	9,09%
Late 40	92	92	7,57	97,83%
Late 45–50	74	74	9,35	95,95%

Điểm đáng chú ý là nhóm Late 40 và Late 45–50 gần như luôn đi với traffic cao, trong khi Late 35 lại có high-traffic share thấp. Điều này cho thấy generator có nhiều luật khác nhau, không chỉ một quan hệ tuyến tính đơn giản.


Traffic và khoảng cách là hai biến có ý nghĩa vận hành rõ nhất. Chúng được giữ trong feature set compact và cũng được dùng trong công thức Risk Score ở tầng DSS.



Hình 4.3: Tỷ lệ trễ theo traffic level.



(a) Theo khoảng cách




(b) Theo complexity

Hình 4.4: Tỷ lệ trễ theo các yếu tố vận hành chính.


4.2 Customer behavior

Phân tích hành vi khách hàng được dùng cho reporting và recommendation rule, không dùng làm bằng chứng thị trường thật do dữ liệu synthetic.


- Size được chọn nhiều nhất: Medium.
- Pizza type được chọn nhiều nhất: Non-Veg.
- Cheese Burst ít đơn hơn Non-Veg/Veg nhưng delay rate cao hơn.
- Large và XL có delay rate cao hơn Medium/Small.
- toppings_count chỉ nằm trong 1–5, tập trung ở 2–5.
- Location có tín hiệu nhưng nhiều nhóm nhỏ, cần gộp hoặc đọc theo top-location.



Hình 4.5: Tỷ lệ đơn hàng theo size.




Hình 4.6: Các loại pizza được đặt nhiều nhất.



Hình 4.7: Ma trận số đơn theo pizza type và size.

Bảng 4.2: Một số preference và rủi ro nổi bật


Nhóm	Orders	Share	Delay rate
Non-Veg	216	21,51%	20,83%
Veg	202	20,12%	21,78%
Cheese Burst	188	18,73%	35,64%
Medium	429	42,73%	9,09%
Large	240	23,90%	35,42%
XL	203	20,22%	41,38%




Hình 4.8: Phân phối độ phức tạp pizza.

4.3 Phụ thuộc theo brand, location và state

Dataset không có cột “bang” riêng. Tuy nhiên, location thường có dạng City,ST, nên nhóm tách thêm state_code để phân tích mô tả. Đây không phải geocoding chính thức và chỉ nên đọc như thông tin trong chuỗi location của dataset.



Hình 4.9: Delay rate theo restaurant brand.




Hình 4.10: Cơ cấu sản phẩm theo restaurant brand.

Bảng 4.3: Tóm tắt brand

Brand	Orders	Delay rate	Avg distance	High traffic share
Domino's	212	29,25%	5,52	31,13%
Papa John's	204	12,75%	4,29	13,24%
Little Caesars	199	22,61%	5,09	62,31%
Marco's Pizza	195	18,46%	4,91	27,18%
Pizza Hut	194	21,13%	4,89	29,90%

Brand có khác biệt trong mix, distance và traffic. Tuy nhiên, vì phần forensics cho thấy dữ liệu mang artifact, báo cáo không kết luận brand nào vận hành tốt hơn thật sự. Brand được dùng để lọc dashboard và phân tích workload.



Hình 4.11: Delay rate theo state code suy ra từ location.


Với location/state, nguyên tắc đọc là luôn nhìn cả số đơn và tỷ lệ trễ. Ví dụ CA có 94 đơn và delay rate 37,23%, GA có 78 đơn và delay rate 5,13%, nhưng các state nhỏ như OH/IN/TN có tỷ lệ rất cao do mẫu ít. Do đó dashboard nên hiển thị count, delayed count và small-sample flag thay vì chỉ xếp hạng theo delay rate.

4.4 Kiểm định giả thiết

Chi-square independence được dùng để kiểm tra mối liên hệ giữa một số biến categorical và nhãn is_delayed. Với mức ý nghĩa 5%, các biến như traffic level, pizza type, payment method, complexity band, pizza size, top-location, restaurant name và time segment cho p-value nhỏ. Tuy nhiên, do dataset có artifact generator, kết quả được dùng như minh họa phân tích chứ không suy luận nhân quả.


4.5 Forecasting, staffing và recommendation

Monthly demand được dự báo 6 tháng tới bằng seasonal-naive prior-year. Backtest có 19 tháng, MAE 12,211 đơn và MAPE 45,7%. Sai số này đủ lớn để khẳng định forecast chỉ là demo planning.



Hình 4.12: Nhu cầu theo tháng và dự báo seasonal-naive.

Preference trend forecast được xây dựng cho share size/type theo tháng. Một số slope có p-value nhỏ, nhưng vì dữ liệu synthetic, kết quả chỉ trả lời câu hỏi “có thể thiết kế quy trình dự báo trend như thế nào”, không kết luận thị hiếu thật.



Hình 4.13: Forecast share pizza size theo tháng.

Với staffing scenario, peak hour là 19h. Bảng hourly_staffing_plan.csv minh họa cách chuyển phân bố theo giờ thành số nhân sự đề xuất trong kịch bản 100 đơn/ngày.

5 Mô hình dự báo đơn giao trễ

5.1 Thiết kế thực nghiệm

Mô hình được huấn luyện trên train, chọn trên dev theo F2 và chỉ báo test sau khi khóa. Preprocessing gồm chuẩn hóa biến số và one-hot encoding biến categorical. Pipeline scikit-learn đảm bảo scaler/encoder chỉ fit trên train.

Dự án so sánh sáu thuật toán: Logistic Regression, Decision Tree, Gaussian Naive Bayes, k-NN, SVM và Random Forest. Feature set compact có 12 feature và loại các biến công thức/trùng thông tin.

5.2 So sánh feature set và model

Bảng 5.1: So sánh feature set trên dev bằng Logistic Regression

Feature set	Số feature	Accuracy	Balanced Acc.	F2	MCC
Compact non-redundant	12	0,9701	0,9636	0,9434	0,9117
Full pre-dispatch	17	0,9701	0,9549	0,9286	0,9097

Bảng 5.2: So sánh mô hình trên dev

Model	Accuracy	Balanced Acc.	F2	MCC
Logistic Regression	0,9701	0,9636	0,9434	0,9117
SVM	0,9602	0,9398	0,9048	0,8796
Decision Tree	0,9502	0,9335	0,8962	0,8525
Random Forest	0,9652	0,9254	0,8780	0,8926
k-NN	0,9353	0,8540	0,7538	0,7970
Naive Bayes	0,6368	0,7179	0,6642	0,3544

Logistic Regression được chọn vì đạt F2 cao nhất trên dev, đồng thời có cấu trúc đơn giản và dễ giải thích hơn các mô hình phức tạp trong phạm vi dataset nhỏ. Gaussian Naive Bayes vẫn được đưa vào so sánh để có baseline xác suất, nhưng giả định feature độc lập không phù hợp

với dữ liệu này: nhiều feature là biến đổi từ distance/traffic, nên Bayes có Recall khá nhưng Precision thấp, F2 chỉ 0,6642 và MCC 0,3544.

5.3 Dò siêu tham số sau khi chọn model

Sau vòng model selection, dự án chỉ tune Logistic Regression theo nguyên tắc “select-then-tune”: chọn họ mô hình trước bằng dev/CV, rồi tinh chỉnh họ thắng. Tune cả sáu mô hình trên dataset nhỏ sẽ làm tăng số lần so sánh và dễ overfit dev. Logistic Regression cũng là model phù hợp tăng DSS vì cho xác suất ổn định và hệ số dễ giải thích hơn SVM/RF.

GridSearchCV chạy trên train với Stratified K-Fold, scoring F2, và lưới $C \in \{0.1, 0.3, 1, 3, 10\}$ quanh giá trị mặc định $C=1.0$. Kết quả CV tốt nhất là $C=0.3$, nhưng khi refit trên train và so lại trên dev, phiên bản tuned kém default rõ rệt. Vì vậy model khóa vẫn giữ default $C=1.0$; test chỉ được báo sau quyết định này.

Bảng 5.3: So sánh Logistic Regression default và tuned trên dev


Biến thể	C	CV F2 mean	Dev F2	Dev MCC	Quyết định
Default LR	1,0	0,9387	0,9434	0,9117	Giữ
Tuned LR	0,3	0,9437	0,8894	0,8779	Không dùng

5.4 Kiểm soát F-beta threshold và split may mắn

Ngoài việc chọn model theo F2, dự án kiểm tra riêng bước chọn ngưỡng xác suất. Ngưỡng 0,5 là mặc định kỹ thuật của classifier; nếu mục tiêu vận hành ưu tiên Recall mạnh hơn, có thể hạ ngưỡng. Việc quét ngưỡng chỉ dùng dev, không dùng test để chọn policy.

Bảng 5.4: Ngưỡng tốt nhất trên dev theo F1/F2/F3

Metric	Threshold	Precision	Recall	F-beta	FP	FN
F1	0,4400	0,9091	0,9524	0,9302	4	2
F2	0,1569	0,7778	1,0000	0,9459	12	0
F3	0,1569	0,7778	1,0000	0,9722	12	0



Hình 5.1: Quét ngưỡng F-beta trên dev.

Khi chuyển ngưỡng F2 tối ưu từ dev sang test, Recall đạt 1,0 và không còn FN, nhưng FP tăng từ 7 lên 22; F2 test giảm từ 0,9491 xuống 0,9052. Do đó báo cáo chính giữ ngưỡng 0,5 cho metric test, còn dashboard coi threshold là policy có thể chỉnh nếu quản lý muốn đánh đổi thêm FP để giảm FN.


Bảng 5.5: Transfer ngưỡng từ dev sang test

Policy test	Threshold	Precision	Recall	F1	F2	FP	FN
Default 0,5	0,5000	0,8542	0,9762	0,9111	0,9491	7	1
Dev-best F2	0,1569	0,6563	1,0000	0,7925	0,9052	22	0

Để kiểm soát khả năng “ăn may” do một split đẹp, dự án còn chạy 100 lần repeated stratified holdout trên pool train+dev, giữ test ngoài audit. Logistic Regression được refit ở mỗi run với threshold 0,5. Kết quả cho thấy điểm cao khá ổn định nhưng vẫn có biên dao động, nên không overclaim con số 0,95 như một đảm bảo tuyệt đối.

Bảng 5.6: Tóm tắt 100-run stability audit trên train+dev

Metric	Mean	Std	Min	P05	P95
F2	0,9419	0,0279	0,8416	0,8892	0,9770
MCC	0,9161	0,0290	0,8495	0,8687	0,9569
Recall	0,9481	0,0355	0,8095	0,8810	1,0000
Precision	0,9206	0,0367	0,8200	0,8542	0,9756



Hình 5.2: Phân phối F2 qua 100 lần chia lại train/dev.

5.5 Kết quả test và baseline

Bảng 5.7: Kết quả test của model khóa

Metric	Giá trị
Accuracy	0,9602
Balanced Accuracy	0,9661
Precision	0,8542
Recall	0,9762
F1	0,9111
F2	0,9491
MCC	0,8889
ROC-AUC	0,9961

Bảng 5.8: Confusion matrix trên test

	Predicted on-time	Predicted delayed
Actual on-time	152	7
Actual delayed	1	41

Bảng 5.9: Baseline test

Baseline	Accuracy	F2	MCC
Always on-time	0,7910	0,0000	0,0000
Always delayed	0,2090	0,5691	0,0000

Kết quả cho thấy mô hình khóa vượt hai baseline trên các metric cân bằng. Tuy nhiên, vì target được sinh từ ngưỡng duration và dữ liệu có tính synthetic, kết quả này không nên được quảng bá như hiệu năng sản xuất.

6 Tầng DSS, dashboard và tối ưu vận tải

6.1 Từ xác suất đến quyết định


Xác suất delayed không tự nó là quyết định. DSS chuyển xác suất thành Risk Score bằng cách kết hợp xác suất mô hình với traffic, distance, peak hour, complexity và weekend:

$$\begin{aligned} Risk = & 0,55S_{model} + 0,15S_{traffic} + 0,12S_{distance} \\ & + 0,08S_{peak} + 0,06S_{complexity} + 0,04S_{weekend}. \end{aligned}$$

Bảng 6.1: Chuẩn hóa từng thành phần Risk Score

Thành phần	Weight	Công thức điểm 0–100	Lý do
S_{model}	0,55	$P(delayed) \times 100$	Tín hiệu học máy là bằng chứng chính.
$S_{traffic}$	0,15	Low=20, Medium=60, High=100	Traffic là driver vận hành rõ trong EDA.
$S_{distance}$	0,12	$\min(distance/10 \times 100, 100)$	10 km là mức xa nhất trong dữ liệu.
S_{peak}	0,08	Peak=100, non-peak=20	Giờ cao điểm ảnh hưởng năng lực xử lý.
$S_{complexity}$	0,06	$\min(complexity/20 \times 100, 100)$	Complexity tối đa quan sát là 20.
$S_{weekend}$	0,04	Weekend=70, weekday=40	Tín hiệu phụ, weight nhỏ vì audit yếu.

Các trọng số cộng đúng 1,0 và được chọn như một policy minh bạch: mô hình chiếm vai trò chính, còn traffic/distance/peak/complexity/weekend là áp lực vận hành để người điều phối hiểu vì sao một đơn được đẩy lên hàng đợi. Đây không phải trọng số tối ưu thống kê; nếu cửa hàng đổi năng lực xử lý, policy có thể chỉnh.



Hình 6.1: Đóng góp trung bình của từng thành phần vào Risk Score.


Risk Score được ánh xạ thành Priority:

Bảng 6.2: Ngưỡng priority


Risk Score	Priority
0–35	Low
36–65	Medium
66–100	High

Recommended Action tương ứng:

- High: báo điều phối trưởng, chuẩn bị tài xế dự phòng, thông báo customer support.
- Medium: theo dõi tài xế/traffic, cập nhật khách hàng nếu ETA xấu đi.
- Low: giữ trong hàng đợi bình thường.



Hình 6.2: Calibration: delay rate thực tế theo priority band.



Hình 6.3: Độ nhạy số đơn High priority khi thay ngưỡng.

Calibration cho thấy delay rate tăng từ Low 0,0% sang Medium 7,3% và High 88,6%. Ngưỡng 35/65 được giữ như policy khóa vì bắt được 92,9% đơn trễ trong nhóm High, nhưng sensitivity chứng minh đây là tham số vận hành, không phải chân lý tuyệt đối.

6.2 Kịch bản assignment

Dự án lấy nhóm đơn High priority từ queue, tạo fleet tài xế giả lập có capacity và tối thiểu hóa chi phí gán đơn–tài xế. Kết quả hiện tại gán 12 đơn High priority cho 6 tài xế giả lập, mean assignment cost 32,84. Đây là minh họa tầng prescriptive DSS vì dataset Kaggle không có depot, driver logs hoặc capacity thật.

Bảng 6.3: Minh bạch công thức cost trong kịch bản assignment

Thành phần	Công thức	Nguồn/ý nghĩa
Travel minutes	$\text{distance_km} * 3.2 / \text{speed_factor}$	<code>distance_km</code> đến từ đơn thật; <code>speed_factor</code> là giả lập cho tài xế.
Priority penalty	$0.35 * (100 - \text{delay_risk_score})$	Đơn risk càng cao thì penalty càng thấp, nên được ưu tiên trong tối ưu.
High traffic penalty	$6 \text{ nếu } \text{traffic} = \text{High}$	Traffic cao cần thêm buffer vận hành.
Same-location bonus	$-8 \text{ nếu cùng } \text{location} / \text{base}$	Ưu tiên tài xế cùng khu vực trong fleet giả lập.
Cost floor	$\max(\text{total}, 0)$	Đảm bảo cost không âm khi có bonus.

Thuật toán chính là Hungarian linear-sum assignment nếu `scipy` khả dụng; greedy chỉ là fallback để pipeline vẫn chạy trong môi trường thiếu thư viện. Vì cost dùng proxy và fleet giả lập, phần này chỉ chứng minh cách biến queue thành khuyến nghị phân công, không phải claim tối ưu điều phối tài xế thật.

6.3 Dashboard Streamlit và Power BI

Dashboard Streamlit gồm tám tab: Overview, EDA, Customer Behavior, Forecast & Staffing, Model Evaluation, Single Order Demo, Delay Queue và Data Quality. Dashboard giúp người dùng xem KPI, giải thích mô hình, thử một đơn mới, xem hàng đợi ưu tiên, bóc tách Risk Score và kiểm tra kịch bản assignment.

Power BI pack gồm fact/dim CSV, DAX measures và dashboard spec. Dự án không tự sinh file `.pbix`; nếu lớp yêu cầu dashboard native, cần import các bảng CSV vào Power BI Desktop theo hướng dẫn trong thư mục `powerbi/`.

7 Minh chứng tái lập và đánh giá dự án

7.1 Runbook và kiểm thử

Runbook chính:

```
cd pizza_delivery_dss
python -m scripts.run_all
python -m unittest discover -s tests -v
streamlit run app/streamlit_app.py
```

Pipeline `scripts.run_all` gồm 18 bước, từ audit dữ liệu đến build notebook, report PDF, slide PDF, unit tests và Streamlit smoke test. Kiểm thử hiện tại gồm 30 unit tests cho schema, leakage, split, detailed EDA, forensics, brand ablation, preference forecast, model, cross-validation, bootstrap CI, DSS rules và assignment.

7.2 Đối chiếu yêu cầu học phần

Bảng 7.1: Đối chiếu nội dung học phần với dự án

Nội dung	Thể hiện trong dự án
DSS	Predictive layer, Risk Score, Priority, dashboard.
Supervised learning	Dự báo <code>is_delayed</code> .
Decision Tree, Naive Bayes, k-NN, SVM, Ensemble	Được so sánh trong Chương 5.
Evaluation	Train/dev/test, baseline, F2, Balanced Accuracy, MCC.
Hypothesis testing	Chi-square cho biến categorical.
Clustering/association	K-Means và association rules trong EDA.
Time series	Monthly demand forecast và preference share forecast.
Recommendation	Popularity/context rules.
Optimization	Assignment scenario cho đơn High priority.
BI/dashboard	Streamlit và Power BI-ready pack.

7.3 Các câu hỏi phản biện đã kiểm soát

Bảng 7.2: Câu hỏi dễ bị hỏi khi bảo vệ và câu trả lời khóa

Câu hỏi	Câu trả lời trong dự án
Sao biết đơn trễ là sau 30 phút?	Không giả định SLA trước. Nhóm suy luận từ nhãn: on-time max 30 phút, delayed min 35 phút; vì duration nằm trên lưới 5 phút nên >30 và >=35 khớp nhãn 0 mismatch.
Vì sao không dùng <code>delivery_duration_min</code> ?	Đó là thông tin sau giao hàng và phục dựng nhãn trực tiếp; dùng làm feature sẽ leakage.
Vì sao không chọn Naive Bayes?	Naive Bayes đã được thử trong 6 classifier nhưng dev F2/MCC thấp hơn rõ; giả định độc lập feature không hợp với distance, estimated duration, complexity và các biến được sinh từ nhau.
F-beta có được tối ưu không?	Có quét threshold F1/F2/F3 trên dev. Dev-best F2 bắt hết delayed nhưng transfer sang test làm FP tăng 7 lên 22 và F2 giảm, nên giữ threshold 0,5 cho báo cáo chính.
Điểm F2 cao có do may mắn split không?	100-run train+dev stability cho F2 mean 0,9419 và p05 0,8892; điểm cao tương đối ổn định, nhưng vẫn được giải thích bằng data synthetic/generator gần tất định, không overclaim production.
Risk Score và assignment có tối ưu thống kê không?	Không. Risk Score là weighted scoring policy minh bạch; assignment dùng cost proxy và fleet giả lập. Hai phần này là prototype prescriptive DSS, cần SLA, driver log và cost thật nếu triển khai.
Forecast/recommendation dùng được kinh doanh thật không?	Không claim. Forecast MAPE 45,7% và recommendation là popularity/context rule, chỉ minh họa quy trình planning và reporting trên dữ liệu synthetic.

7.4 Khuyến nghị ra quyết định

Chuyển kết quả phân tích thành hành động cụ thể cho quản lý vận hành, kèm điều kiện áp dụng:

- Ưu tiên theo Risk Score.** Dùng hàng đợi `delay_priority_queue.csv`: xử lý nhóm High trước (chuẩn bị tài xế dự phòng, thông báo khách), nhóm Medium theo dõi traffic/ETA, nhóm Low giữ luồng thường. Calibration cho thấy delay-rate thật tăng dần theo risk band nên thứ tự ưu tiên này có căn cứ dữ liệu.
- Tập trung nguồn lực vào đơn xa & giờ cao điểm.** Distance và traffic là yếu tố rủi ro mạnh

nhất (EDA + hệ số mô hình); với đơn distance lớn và traffic cao nên gán tài xế nhanh/kinh nghiệm.

3. **Bố trí nhân sự theo giờ.** Kịch bản staffing cho thấy đỉnh đơn quanh 19h; tăng ca giờ cao điểm thay vì rải đều.
4. **Ngưỡng Priority là tham số điều chỉnh được.** Đặt ngưỡng 35/65 theo năng lực xử lý thực tế (phân tích độ nhạy ở Chương 6); nâng ngưỡng khi đội mỏng để giảm số đơn phải can thiệp.
5. **Điều kiện áp dụng.** Các khuyến nghị trên là cơ chế hỗ trợ minh bạch trên dữ liệu hiện có; trước khi dùng thật cần log vận hành thật, chi phí SLA và đánh giá theo thời gian (xem Giới hạn).

7.5 Giới hạn

1. Dataset nhỏ và có tính synthetic, chưa đại diện cho mọi chuỗi pizza thật.
2. Target có ranh giới quan sát giữa 30 và 35 phút duration; nếu dùng nhầm duration/delay sẽ tạo leakage nghiêm trọng.
3. Chronological holdout không có delayed sample, nên bản học thuật dùng stratified split.
4. Forecast có MAPE 45,7%, chỉ dùng minh họa planning.
5. Brand và preference trend phản ánh artifact của generator nhiều hơn là tín hiệu thị trường thật.
6. Driver/fleet trong bài toán vận tải là mô phỏng.
7. Priority là chính sách minh bạch, chưa được tối ưu bằng dữ liệu chi phí kinh doanh thật.

8 Kết luận và hướng phát triển

Báo cáo đã xây dựng một nguyên mẫu DSS hoàn chỉnh ở phạm vi nhỏ: từ dữ liệu Kaggle, audit leakage, data forensics, EDA, kiểm định giả thiết, customer behavior, forecasting, mô hình dự báo, tăng quyết định, dashboard và kịch bản assignment. Kết quả mô hình trên test tốt hơn baseline, nhưng được diễn giải thận trọng vì dataset có nhiều dấu hiệu synthetic.

Giá trị chính của dự án không nằm ở việc tuyên bố có thể triển khai ngay trong sản xuất, mà nằm ở quy trình học thuật đầy đủ: phân biệt dữ liệu, thông tin, mô hình và quyết định; kiểm soát leakage; báo cáo baseline; công khai giới hạn; và biến kết quả dự báo thành khuyến nghị vận hành minh bạch.

Các hướng phát triển tiếp theo gồm: thu thập log vận hành thật, driver logs, SLA/cost, GPS distance; đánh giá theo thời gian; xây dựng feedback loop cho Priority; phát triển dashboard Power BI native; và kiểm thử hệ thống với người dùng vận hành thực tế.

A Phụ lục: Artifact chính

Nhóm artifact	File chính
Dữ liệu	data/raw/Enhanced_pizza_sell_data_2024-25.xlsx; data/processed/train.csv, dev.csv, test.csv.
Metrics	duration_delay_profile.csv, favorite_item_summary.csv, restaurant_dependency_summary.csv, state_dependency_summary.csv, model_test_metrics.csv, delay_threshold_inference.csv.
Forensics	generator_deterministic_formulas.csv, generator_reverse_engineering_summary.json, feature_information_audit.csv.
Figures	duration_grid_by_delay.png, top_pizza_types.png, restaurant_pizza_type_mix_heatmap.png, state_delay_rate_top15.png, monthly_demand_forecast.png.
Code	src/pizza_dss/, scripts/, tests/.
Dashboard	app/streamlit_app.py, powerbi/.
Báo cáo	reports/PIZZA_DSS_REPORT.pdf, notebooks/02_eda.ipynb, notebooks/06_data_forensics.ipynb, slides/PIZZA_DSS_SLIDE_DECK.pdf.

B Phụ lục: Bảng tự chấm điểm của nhóm

Nhóm tự rà soát theo barem 100 điểm trước khi nộp (không thay điểm giảng viên). Cột *Điểm nhóm tự chấm* do nhóm điền; minh chứng dẫn tới artifact cụ thể.

STT	Tiêu chí	Tối đa	Tự chấm	Minh chứng/Ghi chú
1	Hiểu vấn đề & xác định bài toán	15	_____	Chương 1; mục Tám câu hỏi bắt buộc.
2	Dữ liệu & tiền xử lý	15	_____	Chương 3; <code>data_loader.py</code> , NB01, <code>data_quality_summary.json</code> .
3	Phân tích & insight	20	_____	Chương 4; NB02, <code>hypothesis_tests.csv</code> , association/cluster.
4	Mô hình/hệ thống hỗ trợ quyết định	20	_____	Chương 5–6; NB03, <code>model_test_metrics.csv</code> , CV, dashboard.
5	Diễn giải kết quả & khuyến nghị	15	_____	Mục Khuyến nghị (Chương 7); calibration, độ nhạy ngưỡng.
6	Chất lượng báo cáo & hồ sơ minh chứng	10	_____	Báo cáo PDF, glossary, figures, <code>run_all</code> 18/18.
7	Tổ chức nhóm & đóng góp cá nhân	5	_____	Bảng phân công (cột Minh chứng).
Tổng cộng		100	_____	Điểm hệ 10 = tổng/10.

C Phụ lục: Khai báo sử dụng AI

Nhóm khai báo việc sử dụng công cụ AI theo yêu cầu học phần. Nhóm chịu trách nhiệm hoàn toàn về tính chính xác của nội dung, kết quả và khuyến nghị.

Công cụ	Mục đích sử dụng	Phần được hỗ trợ & cách kiểm chứng
Claude Code (Anthropic)	Hỗ trợ viết/refactor code, soạn notebook, soạn bản nháp báo cáo, gợi ý kỹ thuật phân tích	Code/notebook trong <code>src/</code> , <code>scripts/</code> , <code>notebooks/</code> ; nhóm kiểm chứng bằng <code>run_all</code> (18/18), 30 unit test, và đọc lại từng output/insight. <i>(Nhóm bổ sung công cụ khác nếu có: ChatGPT, Gemini, Copilot...)</i>

Cam kết. Mọi số liệu trong báo cáo được sinh từ dữ liệu thật qua pipeline `scripts.run_all` và lưu trong `reports/metrics/`; không có con số nào được AI bịa. Các lựa chọn phân tích (chọn F2, chống leakage, feature compact, caveat synthetic) đều được nhóm hiểu và giải thích được trong báo cáo.

Tài liệu tham khảo

- [1] Power, D. J. (2002). *Decision Support Systems: Concepts and Resources for Managers*. Quorum Books.
- [2] Simon, H. A. (1960). *The New Science of Management Decision*. Harper & Brothers.
- [3] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [4] Akshay Gaikwad. Pizza Delivery Data with Enhanced Features. Kaggle dataset. <https://www.kaggle.com/datasets/akshaygaikwad448/pizza-delivery-data-with-enhanced-features>