

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN – TIN



BÁO CÁO BÀI TẬP NHÓM
HỌC PHẦN HỆ HỖ TRỢ QUYẾT ĐỊNH

**HỆ HỖ TRỢ QUYẾT ĐỊNH ỨNG PHÓ THẢM
HỌA**

TỪ VĂN BẢN VÀ HÌNH ẢNH MẠNG XÃ HỘI

A Multimodal Decision Support System for Disaster Response

Giảng viên: TS. Lê Hải Hà

Nhóm thực hiện: Nhóm 29

Thành viên 1: Đoàn Danh Long – 20237354

Thành viên 2: Vũ Quang Vinh – 20237408

Thành viên 3: Nguyễn Đăng Đức – 20237312

Thành viên 4: Nguyễn Tuấn Anh – 20237293

Học kỳ: 2025.2

Hà Nội, tháng 6 năm 2026

Bảng phân công công việc

Thông tin còn thiếu được đánh dấu rõ; báo cáo không tự gán danh tính hoặc phần việc.

Phân công và tỷ lệ đóng góp của các thành viên Nhóm 29

Thành viên	MSSV	Công việc chính	Tỷ lệ đóng góp
Đoàn Danh Long	20237354	Chưa cung cấp	Chưa cung cấp
Vũ Quang Vinh	20237408	Chưa cung cấp	Chưa cung cấp
Nguyễn Đăng Đức	20237312	Chưa cung cấp	Chưa cung cấp
Nguyễn Tuấn Anh	20237293	Chưa cung cấp	Chưa cung cấp

Lời mở đầu

Trong thảm họa, mạng xã hội cung cấp thông tin hiện trường nhanh nhưng đồng thời tạo ra khối lượng dữ liệu lớn, nhiễu và khó xác minh. Một hệ thống hữu ích không thể dừng ở việc gán nhãn bài đăng; nó phải chuyển bằng chứng từ dữ liệu thành quyết định có thể kiểm tra: bài nào cần chú ý, mức độ ưu tiên, đội nào tiếp nhận và trường hợp nào phải có người duyệt.

Báo cáo trình bày quy trình xây dựng một DSS đa phương thức trên CrisisMMD v2.0, từ kiểm tra dữ liệu, EDA train-only, so sánh sáu thuật toán, late fusion, đến Risk Score, routing và dashboard. Mọi kết quả mô hình được chọn trên dev và báo cáo trên test đã loại ảnh/text trùng với split trước. Những phần không có ground truth, đặc biệt Risk Score và Priority, được công khai là chính sách heuristic và được kiểm tra bằng scenario/sensitivity thay vì tuyên bố tối ưu thống kê.

Lời cảm ơn

Nhóm 29 xin trân trọng cảm ơn TS. Lê Hải Hà đã cung cấp nền tảng kiến thức và định hướng cho học phần Hệ hỗ trợ quyết định. Nhóm đồng thời ghi nhận bộ dữ liệu mở CrisisMMD của QCRI, các thư viện mã nguồn mở và những công cụ hỗ trợ đã được liệt kê trong phụ lục.

Tóm tắt

Báo cáo xây dựng một DSS đa phương thức giúp trung tâm điều phối cứu nạn lụt, ưu tiên và phân luồng thông tin từ mạng xã hội. Dữ liệu sử dụng là CrisisMMD v2.0, gồm 18.082 cặp tweet–ảnh. Sáu thuật toán cổ điển được so sánh trên TF–IDF và đặc trưng ảnh 512 chiều do mô hình CLIP tiền huấn luyện trích xuất. Quá trình kiểm tra dữ liệu phát hiện 2.649 nhãn informative sẽ sai nếu suy diễn từ humanitarian và 305 hàng ảnh trùng theo SHA-256; hệ thống vì vậy ghép nhãn informative chính thức và đánh giá trên 2.189 mẫu dev, 2.169 mẫu test leakage-safe. Với informative, Late Fusion đạt Accuracy 0,6948, F1 0,8025 và F2 0,9045; tuy nhiên baseline luôn dự báo informative đã đạt F2 0,8939, nên F2 không được diễn giải độc lập. Với tám lớp humanitarian, fusion đạt Macro-F1 0,4005 so với majority baseline 0,0686. Hậu kiểm robust không tune lại đạt F2 0,9016 và Macro-F1 0,3908; bootstrap/event analysis cho thấy lợi thế humanitarian rõ nhưng lớp hiếm và domain shift vẫn là giới hạn. Tầng quyết định cung cấp Risk Score, Priority, routing và Manual Review; các trọng số ưu tiên được xem là chính sách minh bạch, không phải ground truth học được.

Từ khóa: DSS, CrisisMMD, Text Mining, CLIP, Late Fusion, Human-in-the-loop.

Bảng thuật ngữ

Bảng này giải nghĩa ngắn gọn các thuật ngữ dùng trong báo cáo. Mỗi khái niệm được trình bày kỹ hơn (định nghĩa → trực giác → ví dụ → vai trò → giới hạn) tại chương tương ứng.

Thuật ngữ	Giải nghĩa
<i>Dữ liệu và bài toán</i>	
Tweet	Một bài đăng ngắn trên Twitter/X, trong dự án luôn kèm một ảnh.
CrisisMMD	Bộ dữ liệu nghiên cứu đã lưu trữ: tweet, ảnh và nhãn của bảy thảm họa 2017.
Annotation	Dữ liệu gán nhãn do con người tạo (nhãn, văn bản, định danh) đi kèm bộ dữ liệu.
Nhãn chuẩn	Nhãn chính thức dùng để học và chấm điểm (informative, humanitarian).
Train/Dev/Test	Tập huấn luyện / tập phát triển (dev) / tập kiểm tra; học trên train, chọn tham số trên dev, báo cáo một lần trên test.
<i>Đặc trưng văn bản</i>	
Feature	Đặc trưng: một con số mô tả mẫu mà mô hình đọc được.
Feature engineering	Thiết kế đặc trưng: biến dữ liệu thô thành vector số.
Vector thưa	Vector hầu hết phần tử bằng 0 (ví dụ TF-IDF).
Vector đặc	Vector mà mọi phần tử đều có giá trị (ví dụ embedding CLIP).
TF-IDF	Term Frequency-Inverse Document Frequency: trọng số từ theo độ phổ biến trong một văn bản và độ hiếm trên toàn tập.
TF / IDF	Tần suất từ trong một văn bản / nghịch đảo số văn bản chứa từ đó.
Unigram / Bigram	Một từ đơn / cặp hai từ liên nhau (“power outage”).
Stopword	Từ quá phổ biến, ít thông tin (“the”, “is”) thường bị loại.
Từ ngoài từ vựng (OOV)	Từ không có trong từ điển đã học từ train.
<i>Đặc trưng ảnh</i>	
Pixel	Điểm ảnh, đơn vị màu nhỏ nhất của một bức ảnh.

Thuật ngữ	Giải nghĩa
Patch	Một ô vuông nhỏ của ảnh (ViT chia ảnh thành lưới patch).
Token ảnh	Vector biểu diễn một patch, đưa vào Transformer.
Transformer	Kiến trúc mạng học quan hệ giữa các token.
CLIP / ViT-B/32	Mô hình tiền huấn luyện trích đặc trưng ảnh; dùng <i>frozen</i> , không fine-tune.
Embedding	Vector số biểu diễn nội dung của văn bản hoặc ảnh.
Chuẩn hóa L2	Đưa vector về độ dài 1 để so sánh theo hướng, không theo độ lớn.
Trùng lặp và rò rỉ	
SHA-256	Hàm băm: cho file ảnh một “vân tay” 256 bit; phát hiện ảnh giống hệt.
Perceptual hash	Băm tri giác: ảnh <i>trông giống</i> cho hash gần nhau.
Khoảng cách Hamming	Số bit khác nhau giữa hai hash.
Near-duplicate	Ảnh gần trùng (resize/crop nhẹ) chứ không giống hệt byte.
Robustness mask	Mặt nạ đánh giá độ bền: loại thêm near-duplicate khi kiểm tra độ nhạy.
Mô hình và đánh giá	
Baseline	Mốc đối chứng đơn giản (dummy/majority) để biết mô hình có thật sự hơn không.
Hyperparameter	Siêu tham số: tham số đặt trước khi học (ví dụ C , k).
Tuning	Dò siêu tham số trên lưới hữu hạn, chọn theo dev.
Calibration	Hiệu chỉnh score thành xác suất đáng tin hơn.
Accuracy	Tỷ lệ dự báo đúng trên tổng số mẫu.
Precision / Recall	Độ chính xác (đoán dương đúng bao nhiêu) / độ phủ (bắt được bao nhiêu ca dương thật).
F1 / F2	Trung bình điều hòa của Precision–Recall; F2 nghiêng về Recall.
Macro-F1	F1 trung bình đều trên các lớp, phù hợp dữ liệu mất cân bằng.
Weighted-F1	F1 trung bình có trọng số theo số mẫu mỗi lớp.
MCC	Matthews Correlation Coefficient; đo tương quan của dự báo nhị phân.

Thuật ngữ	Giải nghĩa
<i>Hợp nhất và độ bền</i>	
Late Fusion	Kết hợp xác suất của các mô hình sau khi từng nhánh đã dự báo.
Threshold	Ngưỡng quyết định để chuyển xác suất thành nhãn.
Conflict score	Mức bất đồng giữa dự báo văn bản và ảnh.
Bootstrap	Lấy mẫu lại có hoàn lại để ước lượng độ ổn định của metric.
Confidence interval	Khoảng tin cậy của một đại lượng ước lượng.
Domain shift	Lệch phân bố giữa dữ liệu học và dữ liệu mới (ví dụ thảm họa mới).
<i>Tầng quyết định</i>	
Risk Score	Điểm rủi ro do DSS tính bằng chính sách trọng số minh bạch.
Priority	Mức ưu tiên (Low/Medium/High) suy từ Risk Score.
Routing	Phân luồng: gợi ý đội tiếp nhận hồ sơ.
Manual Review	Kiểm tra thủ công: chuyển ca bất đồng cho con người xác minh.
Policy	Chính sách: quy tắc thiết kế, không phải kết quả học từ nhãn.
Human-in-the-loop	Thiết kế giữ con người tại các điểm quyết định rủi ro.
DSS	Decision Support System – Hệ hỗ trợ quyết định.
EDA	Exploratory Data Analysis – Phân tích khám phá dữ liệu.

Mục lục

Bảng phân công công việc	i
Lời mở đầu	ii
Lời cảm ơn	iii
Tóm tắt	iv
Bảng thuật ngữ	v
1 Giới thiệu bài toán	1
1.1 Bối cảnh thực tế	1
1.2 Dữ liệu đến từ đâu và dự án làm gì với nó	1
1.3 Vì sao không thay đường dây nóng?	2
1.4 Bài toán ra quyết định	3
1.5 Người sử dụng và nhu cầu thông tin	4
1.6 Ví dụ xuyên suốt	5
1.7 Các tình huống thực tế cần xử lý	5
1.8 Mục tiêu của dự án	6
1.9 Câu hỏi nghiên cứu	7
1.10 Phạm vi và giới hạn	7
1.11 Cấu trúc báo cáo	8
2 Nền tảng hệ hỗ trợ quyết định	9
2.1 Từ dữ liệu đến hành động	9
2.2 Khái niệm hệ hỗ trợ quyết định	9
2.3 Mức độ cấu trúc của quyết định	10
2.4 Chu trình ra quyết định	10
2.5 Ba nhóm năng lực của hệ thống	10
2.5.1 Phân tích mô tả và chẩn đoán	10
2.5.2 Phân tích dự báo	11
2.5.3 Phân tích định hướng hành động	11
2.6 Kiến trúc DSS của dự án	11
2.7 Vai trò của con người trong hệ thống	12
2.8 Nguyên tắc phân biệt bằng chứng và chính sách	13
2.9 Bản đồ kiến thức học phần	13

2.9.1	Vai trò của các công cụ tính toán	14
3	Dữ liệu, tiền xử lý và biểu diễn đặc trưng	16
3.1	Vai trò của dữ liệu trong bài toán	16
3.2	Bộ dữ liệu CrisisMMD v2.0	16
3.2.1	Nguồn, đơn vị quan sát và phạm vi	16
3.2.2	Hai nhiệm vụ dự báo	17
3.3	Hợp nhất annotation và bảo toàn split	17
3.3.1	Vấn đề khác partition giữa hai task	17
3.3.2	Kích thước và phân bố	18
3.4	Kiểm soát trùng lặp và rò rỉ dữ liệu	19
3.4.1	Rò rỉ dữ liệu là gì?	19
3.4.2	Hai loại “vân tay” ảnh: SHA-256 và perceptual hash	19
3.4.3	Hai mặt nạ đánh giá	20
3.5	Tiền xử lý và feature engineering văn bản	20
3.5.1	Làm sạch tweet	20
3.5.2	TF-IDF	21
3.6	Tiền xử lý và feature engineering ảnh	23
3.6.1	Từ pixel đến vector đặc trưng	23
3.6.2	Quy trình trích xuất thực tế	24
3.6.3	Lý do giữ CLIP cố định	25
3.7	Tổng hợp đặc trưng đầu vào mô hình	26
4	Phân tích khám phá dữ liệu	27
4.1	Mục đích và nguyên tắc EDA	27
4.2	Phân bố nhãn và hệ quả	27
4.3	Khác biệt theo sự kiện	28
4.4	Khám phá văn bản	29
4.5	K-Means cho khám phá chủ đề	29
4.5.1	Khái niệm và hàm mục tiêu	29
4.5.2	Silhouette và kết quả	30
4.6	Apriori và luật kết hợp	31
4.6.1	Từ tweet thành transaction	31
4.6.2	Kết quả và cách diễn giải	32
4.7	EDA ảnh và không gian embedding	32
4.7.1	PCA: vì sao 512 chiều khó nhìn	32
4.8	Bất đồng đa phương thức	34
4.9	Từ bằng chứng EDA đến quyết định thiết kế	35

5	Mô hình dự báo, hợp nhất và chính sách DSS	36
5.1	Bài toán học có giám sát	36
5.2	Sáu thuật toán phân lớp	36
5.2.1	Logistic Regression	36
5.2.2	Decision Tree	36
5.2.3	Naive Bayes	37
5.2.4	k-Nearest Neighbors	37
5.2.5	Support Vector Machine	37
5.2.6	Random Forest	38
5.2.7	Vì sao không dùng XGBoost hay mạng sâu?	38
5.3	Mất cân bằng lớp và trọng số	39
5.4	Các chỉ số đánh giá	39
5.4.1	Nhị phân informative	39
5.4.2	Tám lớp humanitarian	40
5.5	Thiết kế thực nghiệm	40
5.5.1	Vai trò của train, dev và test	40
5.6	Vòng 1: so sánh sáu thuật toán	41
5.7	Vòng 2: tuning classifier	42
5.8	Vòng 3: xác suất, Late Fusion và conflict	43
5.8.1	Căn chỉnh xác suất	43
5.8.2	Conflict score và Manual Review	44
5.9	Kết quả cuối trên canonical test	44
5.9.1	Informative và đối chứng hằng	45
5.9.2	Humanitarian tám lớp	45
5.10	Hậu kiểm robustness và độ bất định	46
5.11	Từ dự báo đến chính sách DSS	47
5.11.1	Risk Score	47
5.11.2	Routing, override và sensitivity	48
6	Diễn giải kết quả và khuyến nghị	49
6.1	Kết quả end-to-end	49
6.2	Ý nghĩa của kết quả mô hình	49
6.2.1	Sàng lọc informative	49
6.2.2	Phân loại nhu cầu humanitarian	50
6.2.3	Giá trị của nhánh ảnh	50
6.3	Ý nghĩa của Manual Review	51
6.4	Một số ca minh họa end-to-end	51
6.5	Khuyến nghị vận hành	52
6.6	Trả lời tám câu hỏi của bài tập	53

6.7	Điều đã chứng minh và chưa chứng minh	54
7	Sản phẩm: Dashboard hỗ trợ điều phối	55
7.1	Vai trò của giao diện trong DSS	55
7.2	Năm trang chức năng	55
7.3	Kiến trúc dữ liệu của dashboard	56
7.3.1	Vì sao lưu CSV thay vì cơ sở dữ liệu?	57
7.4	Công nghệ và lý do lựa chọn	57
7.5	Chạy local và triển khai Streamlit Community Cloud	57
7.5.1	Chạy local đầy đủ	58
7.5.2	Bundle cloud	58
7.6	Kiểm thử giao diện và giới hạn triển khai	59
8	Kết luận và hướng phát triển	60
8.1	Kết luận	60
8.2	Hạn chế	60
8.3	Hướng phát triển	61
A	Phụ lục	62
A.1	Khai báo sử dụng công cụ AI	62
A.2	Bảng tự đánh giá	62
A.3	Cấu hình và siêu tham số chính	63
A.4	Tập minh chứng và khả năng tái lập	63
A.5	Thông tin cần cần nhóm xác nhận	64
	Tài liệu tham khảo	65

Danh sách hình

1.1	Ranh giới hệ thống. Hộp tô xám, viền đứt là phần <i>ngoài phạm vi</i> dự án: việc tweet được tạo ra ngoài đời và việc điều động lực lượng ở cuối luồng. Dự án bắt đầu từ bản lưu CrisisMMD và kết thúc ở hàng đợi mà con người xem. . . .	2
2.1	Chuỗi chuyển đổi từ dữ liệu thô tới khuyến nghị hành động.	9
2.2	Kiến trúc logic của hệ hỗ trợ quyết định đa phương thức.	11
2.3	Quy trình Manual Review: hệ thống chỉ nêu lý do, con người mới là người xác minh và quyết định.	12
3.1	Hai lớp phát hiện trùng lặp. SHA-256 chỉ bắt ảnh giống hệt từng byte; pHash bắt ảnh gần giống qua khoảng cách Hamming nhỏ.	20
3.2	Cách CLIP biến ảnh thành vector và cách nó được huấn luyện tương phản. . . .	23
3.3	Hai ảnh train cho mỗi lớp trong tám lớp humanitarian, lấy mẫu xác định bằng seed 42 (<i>không</i> chọn tay theo ảnh “đẹp”), nên gallery không bị thiên lệch chủ quan.	25
4.1	Phân bố informative và humanitarian trên train.	27
4.2	Số mẫu và cơ cấu humanitarian theo sự kiện trên train.	28
4.3	Chia chính thức: mọi sự kiện có mặt ở cả train/dev/test. Leave-one-event-out: toàn bộ một sự kiện bị giữ ngoài train để đo domain shift thật.	29
4.4	Phân bố độ dài và token nổi bật trên train.	29
4.5	Một vòng lặp K-Means trên ví dụ 2D: gán điểm theo tâm gần nhất rồi cập nhật tâm. Ngôi sao là centroid.	30
4.6	Phân cụm TF-IDF trên train.	30
4.7	Trái: phương sai tích lũy theo số thành phần PCA (đường ngang 80% chưa đạt trong 50 thành phần). Phải: hình chiếu PCA 2D tuyến tính của embedding train, tô màu theo nhãn – các lớp chồng lấn vì 2 trục chỉ giữ 12,4% phương sai. . . .	33
4.8	t-SNE của CLIP embedding train, tô màu theo ground truth chung.	33
4.9	Tỷ lệ nhãn category text và image bất đồng trên train.	34
5.1	Trực giác hình dạng ranh giới quyết định của sáu họ trên cùng một dữ liệu hai lớp (sơ đồ minh họa): tuyến tính (LR, SVM), bậc thang theo trục (Cây, Rừng), cong (Naive Bayes) và cục bộ gồ ghề (k-NN).	38

6.1	Mức tăng của Late Fusion so với baseline always-informative theo từng metric (canonical test). F2 gần như không nhúc nhích, nhưng các metric cân bằng (Balanced Accuracy, MCC) tăng rõ – đây mới là giá trị thật của fusion.	49
6.2	Tiến triển Macro-F1 humanitarian qua các mốc đối chứng trên canonical test: mỗi bước thêm thông tin đều nhích lên, fusion cao nhất.	50
6.3	Ba ca thật từ test. A: tin đồng thuận, Risk 87,5 → High, không cần review. B: xung đột cao (conflict 0,92) nên bật Manual Review dù vẫn ưu tiên. C: tweet “no missing child” – một câu <i>phủ định</i> thật, lớp missing/found hiếm, hệ thống chuyển review thay vì tin tuyệt đối. Ca C cho thấy đúng điểm yếu phủ định của TF-IDF đã nêu ở Chương 5.	52
7.1	Tổng quan vận hành và căn cứ dữ liệu.	56
7.2	Từ bằng chứng mô hình tới hàng đợi quyết định.	56

1 Giới thiệu bài toán

1.1 Bối cảnh thực tế

Trong những giờ đầu của một trận lũ, bão, động đất hoặc cháy rừng, thông tin thường xuất hiện trên mạng xã hội trước khi được tổng hợp đầy đủ trong các báo cáo chính thức. Trên nền tảng Twitter (nay là X), người dân có thể đăng một *tweet* – một bài viết ngắn, thường kèm ảnh – để nói về đường bị chặn, công trình sập, mất điện, nhu cầu lương thực hoặc hoạt động tình nguyện. Nguồn dữ liệu này có giá trị vì nhanh và gần hiện trường, nhưng đồng thời rất khó sử dụng trực tiếp:

- số lượng tweet tăng nhanh hơn khả năng đọc thủ công của một trung tâm điều phối;
- văn bản ngắn, có đường dẫn (URL), thẻ chủ đề (hashtag), viết tắt và rất nhiều nội dung không liên quan đến cứu trợ;
- một tweet có thể chứa cả văn bản và ảnh, nhưng hai nguồn bằng chứng này không nhất thiết nói cùng một nội dung;
- thông tin thường thiếu vị trí chính xác, có thể được đăng lại hoặc dùng lại một tấm ảnh cũ;
- chi phí của các loại sai khác nhau: bỏ sót một lời kêu cứu nguy hiểm hơn nhiều so với việc chuyển nhầm một tweet ít khẩn cấp cho người kiểm tra.

Vấn đề của trung tâm điều phối không đơn thuần là “gán nhãn đúng cho một tweet”. Người điều phối cần quyết định *tweet nào phải được chú ý trước, nội dung thuộc nhóm nhu cầu nào, đội nào nên tiếp nhận và trường hợp nào cần con người xác minh*. Vì vậy, sản phẩm phù hợp phải là một **hệ hỗ trợ quyết định** (Decision Support System – DSS), trong đó mô hình học máy chỉ là một thành phần tạo bằng chứng đầu vào cho quyết định, không phải bộ phận ra lệnh.

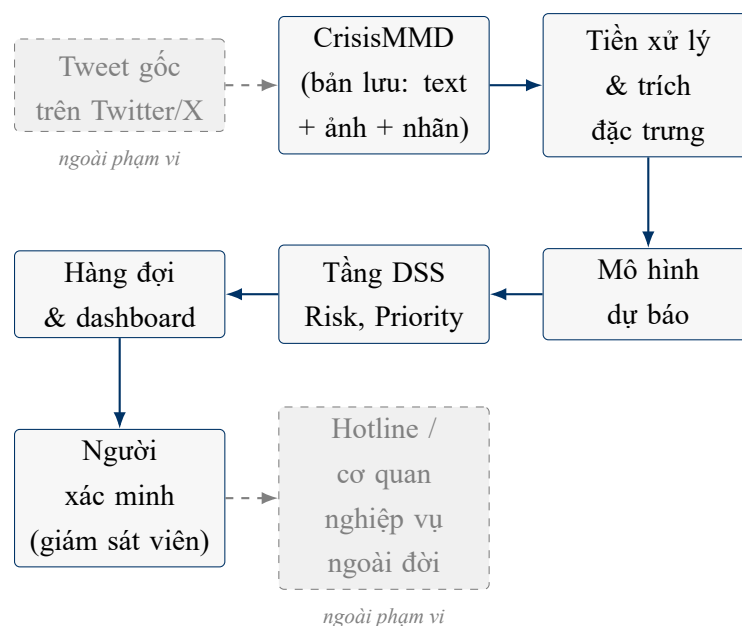
1.2 Dữ liệu đến từ đâu và dự án làm gì với nó

Một hiểu lầm cần loại bỏ ngay từ đầu: dự án này **không** thu thập tweet trực tiếp từ Internet. Toàn bộ thực nghiệm chạy trên **CrisisMMD v2.0**, một *bộ dữ liệu nghiên cứu đã được lưu trữ* do nhóm QCRI (Qatar Computing Research Institute) công bố. Để tránh nhầm lẫn, cần phân biệt ba lớp tách rời nhau:

1. **Nguồn ngoài đời:** người dùng thật đăng tweet và ảnh lên Twitter trong bảy thảm họa năm 2017. Đây là việc đã xảy ra trong quá khứ, dự án không tham gia.

2. **Bộ dữ liệu nghiên cứu:** QCRI thu thập một phần các tweet đó, tải ảnh đính kèm về, thuê người gán nhãn và đóng gói thành CrisisMMD — gồm các file văn bản (annotation) và các file ảnh đã tải sẵn.
3. **Dự án (phần chúng tôi làm):** đọc bản lưu CrisisMMD, làm sạch văn bản, trích đặc trưng ảnh, huấn luyện mô hình, rồi tạo dự báo và một hàng đợi hỗ trợ quyết định.

Nói cách khác, đầu vào của dự án là *văn bản tweet và file ảnh đã có sẵn trên đĩa*, kèm nhãn do con người gán. Pipeline hiện tại **không** gọi Twitter/X API, **không** đi theo các URL bên trong tweet để tải nội dung mới, và **không** thu thập bài đăng theo thời gian thực. Khi báo cáo nói “đọc và lấy ảnh, văn bản đưa vào mô hình”, điều đó nghĩa là đọc các file ảnh và file annotation *đã nằm trong bộ dữ liệu*, không phải truy cập mạng.



Hình 1.1: Ranh giới hệ thống. Hộp tô xám, viền đứt là phần *ngoài phạm vi* dự án: việc tweet được tạo ra ngoài đời và việc điều động lực lượng ở cuối luồng. Dự án bắt đầu từ bản lưu CrisisMMD và kết thúc ở hàng đợi mà con người xem.

Một hệ thống *thời gian thực* trong tương lai sẽ là một kiến trúc khác: nguồn dữ liệu được cấp quyền hoặc API chính thức → hàng đợi nạp (ingest) → lưu vào cơ sở dữ liệu → mô hình → con người xác minh. Báo cáo mô tả kiến trúc đó như một *hướng phát triển* ở Chương 8, chứ không tuyên bố phiên bản hiện tại đã có chức năng thu thập trực tuyến.

1.3 Vì sao không thay đường dây nóng?

Một câu hỏi hợp lý là: nếu cần cứu trợ, vì sao người dân không gọi thẳng đường dây nóng (hotline) mà lại lên mạng xã hội, và một hệ thống đọc tweet có thực sự hữu ích? Câu trả lời là hotline và mạng xã hội phục vụ hai vai trò khác nhau, và dự án này **bổ sung** chứ không thay thế hotline.

Đường dây nóng vẫn là *kênh chính* cho yêu cầu cứu trợ trực tiếp: nó cho phép trao đổi hai chiều, người trực có thể hỏi lại để xác minh danh tính và vị trí, và mỗi cuộc gọi tương ứng với một người cần giúp cụ thể. Mạng xã hội chỉ là *kênh bổ sung*, có ích ở những việc hotline khó làm:

- phát hiện tín hiệu gián tiếp: ảnh đường bị chặn, khu vực mất điện, mức nước dâng – thông tin mà người đăng không chủ đích báo nạn;
- tổng hợp bức tranh cộng đồng: nhiều tweet cùng một khu vực cho thấy quy mô ảnh hưởng;
- phát hiện nội dung lan truyền rộng nhưng chưa đi vào kênh chính thức;
- hỗ trợ *thứ tự đọc*: giúp người phân tích đọc cái quan trọng trước, không thay quy trình tiếp nhận báo nạn.

Bảng 1.1: So sánh ba thành phần theo vai trò. DSS không cạnh tranh với hotline mà xử lý phần mạng xã hội mà con người không đọc xuể.

Tiêu chí	Hotline	Tweet (mạng xã hội)	DSS của dự án
Tốc độ đến hiện trường	Trung bình	Rất nhanh	Nhanh (xử lý hàng loạt)
Độ xác thực	Cao (hỏi trực tiếp)	Thấp, cần kiểm chứng	Không tự xác thực
Hai chiều	Có	Hầu như không	Không
Độ phủ	Một ca mỗi cuộc gọi	Rất rộng	Rộng nhưng chỉ trong dữ liệu có
Rủi ro chính	Quá tải tổng đài	Tin giả, trùng lặp, thiếu vị trí	Sai dự báo, bỏ sót lớp hiểm

Điểm kiểm soát bắt buộc

Mọi trường hợp có hậu quả cao (nghi ngờ thương vong, người mất tích) phải được kiểm tra lại qua hotline, cơ quan địa phương hoặc nguồn chính thức trước khi hành động. DSS chỉ đề xuất *thứ tự chú ý*; nó không xác nhận một lời kêu cứu là thật.

1.4 Bài toán ra quyết định

Đơn vị phân tích của dự án là một tweet gồm nội dung văn bản và một ảnh đính kèm. Với mỗi tweet, hệ thống hỗ trợ năm quyết định liên tiếp. Để tránh hiểu nhầm rằng hệ thống “tự hành động”, mỗi quyết định được mô tả kèm thao tác cụ thể mà nó thực sự thực hiện:

1. **Sàng lọc** – chọn tweet nào đáng đọc. Thao tác: lọc bỏ nội dung không liên quan để người phân tích không phải đọc tuần tự từng bài.
2. **Gợi ý loại nhu cầu** – đoán nội dung thuộc nhóm thương vong, hạ tầng, cứu trợ, v.v. Thao tác: gán nhãn gợi ý, *không* khẳng định.
3. **Xếp mức ưu tiên** – “xếp High” nghĩa là *đưa tweet lên đầu hàng đợi để người xem trước*, hoàn toàn không phải tự điều xe cứu hộ.
4. **Phân luồng (routing)** – “routing Emergency Team” nghĩa là *gợi ý nhóm hồ sơ phù hợp*, không gửi lệnh điều động cho đội nào.
5. **Đánh dấu kiểm duyệt** – “review” nghĩa là *mở một ca xác minh có checklist* cho con người, khi bằng chứng hai phương thức mâu thuẫn hoặc thiếu tin cậy.

Năm quyết định có quan hệ phụ thuộc. Nếu một tweet bị đánh giá là không hữu ích, việc phân luồng không còn nhiều ý nghĩa. Nếu một tweet được xếp vào nhóm thương vong nhưng hai phương thức mâu thuẫn mạnh, hệ thống vẫn phải đưa lên đầu hàng đợi *đồng thời* yêu cầu người giám sát kiểm tra; nó không tự động hạ mức ưu tiên chỉ vì mô hình chưa chắc chắn.

1.5 Người sử dụng và nhu cầu thông tin

Bảng 1.2: Người sử dụng, quyết định và thông tin cần thiết.

Người sử dụng	Quyết định cần hỗ trợ	Thông tin hệ thống cung cấp
Ban điều phối	Ưu tiên nguồn lực và theo dõi khối lượng sự vụ	Số tweet theo mức ưu tiên, sự kiện, nhóm nhu cầu và đội tiếp nhận
Đội khẩn cấp	Xác định trường hợp liên quan sinh mạng cần kiểm tra trước	Nhãn thương vong/mất tích, điểm rủi ro, nội dung gốc và cảnh báo mâu thuẫn
Đội hạ tầng	Lập danh sách đường, cầu, điện nước hoặc phương tiện bị hư hỏng	Nhãn hạ tầng/phương tiện, thứ tự ưu tiên và tweet gốc
Đội cứu trợ	Điều phối lương thực, nơi trú ẩn, tình nguyện và quyên góp	Nhãn người bị ảnh hưởng/cứu trợ, mức ưu tiên và khối lượng theo sự kiện
Giám sát viên	Xác minh trường hợp không nhất quán hoặc thiếu tin cậy	Xác suất từng nhánh, conflict score, ảnh, văn bản và lý do cần review

Bảng trên cho thấy cùng một dự báo phải được trình bày khác nhau tùy người dùng. Một nhà nghiên cứu quan tâm đến F1 hoặc confusion matrix, trong khi điều phối viên cần một hàng đợi có thể sắp xếp và một hành động đề xuất. DSS phải nối được hai góc nhìn này.

1.6 Ví dụ xuyên suốt

Giả sử hệ thống nhận được tweet:

“Urgent! People are trapped after the bridge collapsed in rising flood water. Need rescue now.”

kèm một ảnh đường ngập. Hệ thống không đi thẳng từ câu chữ tới lệnh điều động. Quá trình xử lý được chia thành các bước có thể kiểm tra:

1. làm sạch văn bản và chuyển văn bản thành vector TF-IDF;
2. dùng CLIP tiền huấn luyện, với trọng số giữ nguyên, để chuyển ảnh thành vector đặc trưng 512 chiều;
3. các bộ phân loại riêng cho văn bản và ảnh tạo xác suất informative và xác suất của tám nhóm humanitarian;
4. Late Fusion kết hợp hai tập xác suất bằng trọng số được chọn trên tập dev;
5. tầng DSS kết hợp các tín hiệu thành một điểm rủi ro (Risk Score);
6. Risk Score và nhóm humanitarian được chuyển thành Priority, đội tiếp nhận gợi ý và chờ Manual Review.

Ví dụ này thể hiện ranh giới quan trọng: mô hình dự báo cung cấp bằng chứng, còn quy tắc DSS chuyển bằng chứng thành một *đề xuất* hành động. Quyết định cuối cùng vẫn thuộc về con người.

1.7 Các tình huống thực tế cần xử lý

Câu hỏi nghiên cứu sẽ ít giá trị nếu chỉ coi mỗi tweet là một dòng dữ liệu sạch. Trên thực tế, nhiều tình huống khó xảy ra thường xuyên. Bảng 1.3 liệt kê các tình huống mà thiết kế hệ thống phải tính đến; các chương sau sẽ quay lại từng tình huống.

Bảng 1.3: Tình huống thực tế và cách hệ thống được kỳ vọng phản ứng.

Tình huống	Phản ứng mong muốn của hệ thống
Văn bản khẩn cấp nhưng ảnh không liên quan	Hai phương thức bất đồng → giữ ưu tiên cao và bắt cò review.
Ảnh thiệt hại rõ nhưng văn bản chỉ là tiêu đề chung	Tin nhánh ảnh, không vội kết luận nhóm từ riêng văn bản.
Ảnh cũ được đăng lại trong sự kiện mới	Bộ lọc trùng lặp (hash) đánh dấu; không tính như bằng chứng mới.
Tweet thiếu vị trí	Vẫn xếp ưu tiên nhưng nhắc người xác minh phải tìm vị trí trước khi hành động.
Tweet châm biếm hoặc phủ định (“thank god nobody died”)	Là điểm yếu đã biết của TF-IDF; đưa vào cò review thay vì tin tuyệt đối.
Hàng review vượt công suất	Ngưỡng conflict được khóa dưới một giới hạn công suất; chỉ giữ ca bất đồng nhất.
Lớp hiểm có xác suất cao nhưng ít bằng chứng	Không tự động hóa; luôn chuyển con người kiểm tra.
Thảm họa mới chưa từng xuất hiện trong train	EDA cảnh báo nguy cơ; dashboard cho lọc theo sự kiện để theo dõi độ ổn định.

1.8 Mục tiêu của dự án

Mục tiêu tổng quát là xây dựng và đánh giá một nguyên mẫu DSS đa phương thức có khả năng chuyển dữ liệu tweet–ảnh đã lưu trữ thành thông tin hỗ trợ điều phối cứu trợ. Các mục tiêu cụ thể gồm:

1. sử dụng toàn bộ dữ liệu CrisisMMD v2.0, gồm 18.082 cặp tweet–ảnh; bảo toàn cách chia train/dev/test thống nhất;
2. mô tả, làm sạch và kiểm soát chất lượng dữ liệu, đặc biệt là nhãn sai khi join, mất cân bằng và bản sao xuyên split;
3. so sánh sáu thuật toán phân lớp cổ điển trên hai phương thức và hai nhiệm vụ dự báo;
4. đánh giá việc kết hợp văn bản–ảnh so với từng phương thức đơn lẻ và so với baseline đơn giản;
5. xây dựng tầng quyết định gồm Risk Score, Priority, Routing và Manual Review với giả định được công khai;

6. cung cấp dashboard để người sử dụng xem tổng quan, kiểm tra mô hình, thử một trường hợp và xử lý hàng đợi ưu tiên.

1.9 Câu hỏi nghiên cứu

Nhóm câu hỏi thứ nhất mang tính *phương pháp*, kiểm tra bằng metric:

1. Văn bản và hình ảnh đóng góp khác nhau như thế nào khi dự báo cùng ground truth đa phương thức?
2. Late Fusion có cải thiện chất lượng so với text-only, image-only và dummy baseline hay không?
3. Mất cân bằng lớp và sự khác biệt giữa các thảm họa ảnh hưởng thế nào tới khả năng nhận diện các nhóm hiếm?
4. Có thể dùng bất đồng text–ảnh để tạo một hàng đợi kiểm duyệt nằm trong năng lực xử lý của con người hay không?

Nhóm câu hỏi thứ hai mang tính *vận hành*, kiểm tra bằng kịch bản và quy tắc thiết kế:

5. Khi tweet thiếu vị trí, kết quả được phép dùng đến đâu trước khi bắt buộc con người xác minh?
6. Khi văn bản và ảnh xung đột, ai là người xem lại và họ cần xem gì?
7. Khi công suất review đã đầy, hệ thống ưu tiên giữ lại loại ca nào?
8. Kết quả thay đổi ra sao trên một sự kiện thảm họa mới?
9. Hệ thống có thực sự giúp ích hơn việc đọc tuần tự hoặc luôn dự báo lớp đa số hay không?

1.10 Phạm vi và giới hạn

Dự án sử dụng dữ liệu tiếng Anh của bảy thảm họa trong năm 2017. Như đã nêu ở Mục 1.2, hệ thống **không** thu thập tweet thời gian thực, **không** gọi Twitter/X API, **không** đi theo URL trong tweet, không xác minh danh tính người đăng, không trích xuất chính xác tọa độ và không tự động điều động lực lượng ngoài đời. Risk Score và Priority không có ground truth tương ứng trong CrisisMMD; do đó chúng được xem là **chính sách vận hành thử nghiệm**, được kiểm tra bằng kịch bản và phân tích độ nhạy chứ không được tuyên bố là tối ưu thống kê.

Sản phẩm hướng tới sàng lọc và tổ chức thông tin. Các nhóm có số mẫu rất thấp, đặc biệt người mất tích và hư hỏng phương tiện, luôn cần con người kiểm tra trước khi dùng cho quyết định có hậu quả lớn.


1.11 Cấu trúc báo cáo

Các chương tiếp theo lần lượt trình bày nền tảng DSS và bản đồ kiến thức học phần; dữ liệu và cách tạo đặc trưng; EDA; thiết kế thực nghiệm và kết quả mô hình; Late Fusion và tầng quyết định; dashboard; khuyến nghị, giới hạn và hướng phát triển. Phụ lục chứa phân công, khai báo sử dụng công cụ hỗ trợ, siêu tham số và bảng tự đánh giá theo hướng dẫn học phần.

2 Nền tảng hệ hỗ trợ quyết định

2.1 Từ dữ liệu đến hành động

Dữ liệu là các quan sát thô, chẳng hạn nội dung một tweet, một ảnh, thời điểm đăng và tên sự kiện. Khi dữ liệu được làm sạch, đặt trong bối cảnh và tổng hợp, nó trở thành *thông tin*: bài đăng có khả năng hữu ích, liên quan đến hạ tầng và có mức bất đồng text–ảnh cao. Khi thông tin được kết hợp với quy tắc nghiệp vụ, giới hạn nguồn lực và trách nhiệm của người sử dụng, hệ thống mới có thể tạo *khuyến nghị hành động*: chuyển bài đăng tới đội hạ tầng, xếp Medium và yêu cầu giám sát viên kiểm tra.



Hình 2.1: Chuỗi chuyển đổi từ dữ liệu thô tới khuyến nghị hành động.

Việc phân biệt bốn mức trên giúp tránh một sai lầm phổ biến: một xác suất dự báo cao không tự nó là quyết định. Ví dụ, xác suất 0,82 cho lớp hạ tầng chưa cho biết đội nào tiếp nhận hoặc trường hợp đó có khẩn cấp hơn một lời kêu cứu khác hay không. Những câu hỏi đó cần thêm chính sách và bối cảnh vận hành.

2.2 Khái niệm hệ hỗ trợ quyết định

Hệ hỗ trợ quyết định là hệ thống thông tin kết hợp dữ liệu, mô hình phân tích và giao diện tương tác để giúp con người giải quyết các vấn đề mà việc lựa chọn không thể được tự động hóa hoàn toàn [1, 14]. DSS không nhất thiết phải đưa ra một đáp án duy nhất. Giá trị của nó có thể nằm ở việc:

- giảm khối lượng thông tin con người phải đọc;
- cung cấp nhiều góc nhìn và chỉ số có thể kiểm tra;
- sắp xếp các phương án theo tiêu chí rõ ràng;
- cảnh báo trường hợp bất thường hoặc thiếu chắc chắn;
- ghi lại lý do của khuyến nghị để người sử dụng chịu trách nhiệm cuối.

Trong dự án này, DSS không thay thế trung tâm điều phối. Nó biến hàng nghìn bài đăng thành một hàng đợi có cấu trúc, nhưng con người vẫn kiểm tra vị trí, độ xác thực và điều kiện hiện trường trước khi triển khai nguồn lực.

2.3 Mức độ cấu trúc của quyết định

Một **quyết định có cấu trúc** có quy tắc và đầu vào rõ ràng, có thể thực hiện lặp lại. Ví dụ, nếu một bài đăng đã được xác nhận thuộc nhóm hư hỏng hạ tầng thì chuyển về Infrastructure Team là một quy tắc tương đối có cấu trúc.

Một **quyết định bán cấu trúc** có một phần được mô hình hoặc quy tắc hỗ trợ nhưng vẫn cần phán đoán con người. Xếp mức ưu tiên cho bài đăng là quyết định bán cấu trúc: Risk Score tạo thứ tự ban đầu, nhưng điều phối viên có thể thay đổi khi biết bệnh viện nào đang quá tải hoặc tuyến đường nào đã được xử lý.

Một **quyết định phi cấu trúc** phụ thuộc mạnh vào kinh nghiệm và bối cảnh khó biểu diễn thành quy tắc cố định, chẳng hạn quyết định điều động lực lượng ngoài đời trong một thảm họa đang diễn biến. Phạm vi dự án dừng ở mức hỗ trợ cho loại quyết định này, không tự động thực thi.

2.4 Chu trình ra quyết định

Theo mô hình của Simon, quá trình ra quyết định có thể được mô tả qua các pha nhận biết vấn đề, thiết kế phương án, lựa chọn và thực thi [2]. Áp dụng vào dự án:

1. **Nhận biết (Intelligence):** thu nhận bài đăng, loại dữ liệu lỗi, phát hiện bài informative và nhận diện loại nhu cầu.
2. **Thiết kế (Design):** tạo các phương án xử lý như Emergency, Relief, Infrastructure, Coordination hoặc Manual Review.
3. **Lựa chọn (Choice):** dùng Risk Score, Priority và routing để đề xuất phương án phù hợp.
4. **Thực thi và phản hồi:** người điều phối xác nhận, thực hiện và ghi nhận kết quả để sau này hiệu chỉnh chính sách.

Dữ liệu CrisisMMD chỉ cung cấp ground truth cho informative và humanitarian, không có phản hồi thực tế về Priority hoặc đội được điều động. Vì vậy dự án thực hiện tốt ba pha đầu ở mức nguyên mẫu; pha phản hồi vận hành được xác định là hướng phát triển.

2.5 Ba nhóm năng lực của hệ thống

2.5.1 Phân tích mô tả và chẩn đoán

Phân tích mô tả trả lời “dữ liệu đang có đặc điểm gì?”: bao nhiêu bài theo sự kiện, tỷ lệ informative, phân bố tám lớp và độ dài tweet. Phân tích chẩn đoán đi thêm một bước để tìm lý do hoặc mối quan hệ: lớp hiếm, sự kiện có phân bố khác nhau, text và ảnh bất đồng ở nhóm nào. EDA, K-Means và Apriori thuộc nhóm này.

2.5.2 Phân tích dự báo

Phân tích dự báo trả lời “mẫu mới có khả năng thuộc lớp nào?”. Các classifier văn bản và ảnh tạo ra xác suất informative và xác suất của tám nhóm humanitarian. Kết quả này được đánh giá bằng nhãn chính thức, confusion matrix và các chỉ số phù hợp với dữ liệu mất cân bằng.


2.5.3 Phân tích định hướng hành động

Phân tích định hướng hành động trả lời “nên làm gì với dự báo?”. Tầng DSS dùng xác suất, mức nghiêm trọng, từ khóa và conflict score để đề xuất thứ tự ưu tiên, đội tiếp nhận và nhu cầu kiểm duyệt. Vì CrisisMMD không có nhãn Priority, đây là chính sách minh bạch chứ không phải một mô hình được chứng minh tối ưu.

Bảng 2.1: Phân biệt các nhóm năng lực phân tích trong dự án.

Nhóm	Câu hỏi	Đầu ra	Thành phần
Mô tả/chẩn đoán	Dữ liệu có đặc điểm và vấn đề gì?	Phân bố, insight, cụm, luật kết hợp	EDA, K-Means, Apriori
Dự báo	Bài đăng có khả năng thuộc lớp nào?	Xác suất informative và humanitarian	Sáu classifier, Late Fusion
Định hướng hành động	Nên xử lý bài đăng như thế nào?	Risk, Priority, Routing, Review	Rule engine và dashboard

2.6 Kiến trúc DSS của dự án



Hình 2.2: Kiến trúc logic của hệ hỗ trợ quyết định đa phương thức.

Đường nét đứt biểu diễn vòng phản hồi dự kiến: quyết định của người vận hành và kết quả xác minh có thể được lưu lại để theo dõi sai lệch, cập nhật chính sách hoặc tái huấn luyện mô hình ở các phiên bản sau.

Kiến trúc gồm bốn khối:

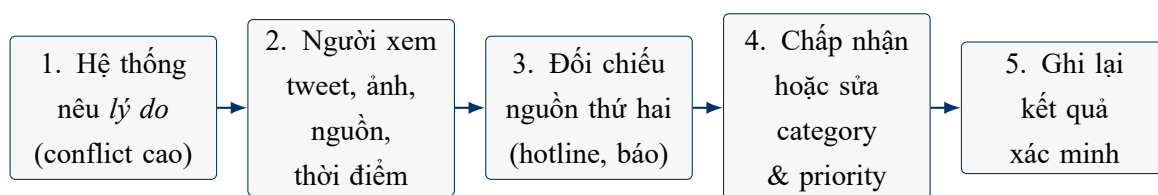
1. **Dữ liệu và biểu diễn:** làm sạch tweet, tạo TF-IDF; chuẩn hóa ảnh và dùng CLIP tiền huấn luyện với trọng số giữ nguyên để tạo vector.
2. **Mô hình dự báo:** các classifier cổ điển được huấn luyện trên CrisisMMD cho hai nhiệm vụ informative và humanitarian.
3. **Hợp nhất và chính sách:** xác suất hai phương thức được căn chỉnh, kết hợp và chuyển thành khuyến nghị.
4. **Giao diện:** người dùng xem KPI, lọc theo sự kiện, kiểm tra một ca và tải hàng đợi xử lý.

2.7 Vai trò của con người trong hệ thống

Human-in-the-loop là thiết kế trong đó con người được đưa vào những điểm mà mô hình không đủ dữ liệu, thiếu chắc chắn hoặc quyết định có hậu quả lớn. Với dự án này, con người xuất hiện ở ba mức:

- **xác minh dữ liệu:** kiểm tra bài đăng, ảnh, vị trí và nguồn;
- **xác nhận khuyến nghị:** chấp nhận hoặc thay đổi Priority và Routing theo tình hình thực tế;
- **giám sát hệ thống:** theo dõi sai lệch theo sự kiện, công suất hàng review và hiệu quả sau triển khai.

Manual Review (kiểm tra thủ công) có một quy trình cụ thể chứ không chỉ là một cái cờ bật/tắt. Khi hệ thống đánh dấu một tweet cần review, năm bước sau được thực hiện bởi con người:



Hình 2.3: Quy trình Manual Review: hệ thống chỉ nêu lý do, con người mới là người xác minh và quyết định.

Manual Review vì vậy không chỉ là một “nhân lỗi”. Nó là một cơ chế quản trị rủi ro: hệ thống chủ động chuyển các trường hợp bất đồng mạnh cho người có trách nhiệm. Tuy nhiên, công suất con người là hữu hạn. Nếu ngưỡng quá thấp, gần như mọi bài đăng đều bị chuyển review và DSS không còn giảm tải. Vì vậy ngưỡng conflict được chọn trên dev dưới một giới hạn công suất, sau đó mới khóa để đánh giá.

2.8 Nguyên tắc phân biệt bằng chứng và chính sách

Ba mức khẳng định trong báo cáo

Bằng chứng dữ liệu là đại lượng đo được, chẳng hạn số mẫu, phân bố nhãn, metric hoặc tỷ lệ bất đồng. **Suy luận phân tích** là cách diễn giải có giới hạn từ bằng chứng, chẳng hạn “mất cân bằng có thể làm Accuracy che giấu lỗi lớp hiếm”. **Chính sách vận hành** là lựa chọn của tổ chức khi dữ liệu không có ground truth, chẳng hạn trọng số severity hoặc ngưỡng Priority. Ba mức này phải được trình bày tách biệt.

Nguyên tắc trên đặc biệt quan trọng với Risk Score. Dự án có thể chứng minh classifier được đánh giá trên nhãn informative/humanitarian, nhưng không thể chứng minh Priority là tối ưu khi chưa có nhãn Priority. Thay vào đó, báo cáo phải công khai công thức, thử nhiều ngưỡng và mô tả điều kiện cần để xác nhận chính sách trong tương lai.

Bảng 2.2 áp dụng nguyên tắc này cho một ca cụ thể, tách rõ đâu là số đo, đâu là suy luận, đâu là lựa chọn của tổ chức và đâu là việc nằm ngoài hệ thống.

Bảng 2.2: Bốn mức khẳng định cho một tweet “cầu sập, người mắc kẹt”.

Mức	Ví dụ trên ca này
Bằng chứng dữ liệu	Xác suất informative 0,93; nhánh ảnh và văn bản cùng cho nhóm hạ tầng; conflict score thấp.
Suy luận phân tích	“Hai phương thức đồng thuận và xác suất cao nên ca này ít khả năng là báo động giả.”
Chính sách vận hành	Trọng số severity của nhóm hạ tầng và ngưỡng Priority do nhóm chọn → xếp High.
Hành động ngoài hệ thống	Điều xe, gọi đội cứu hộ: <i>không</i> thuộc hệ thống; do con người và cơ quan nghiệp vụ thực hiện sau khi xác minh.

2.9 Bản đồ kiến thức học phần

Báo cáo dùng nhiều kỹ thuật, nhưng không phải kỹ thuật nào cũng là *trọng tâm* của học phần Hệ hỗ trợ quyết định. Bảng 2.3 phân biệt phần thuộc nội dung môn học (trung tâm) với phần công cụ hỗ trợ nằm ngoài slide.

Bảng 2.3: Bản đồ kiến thức: nội dung học phần và vai trò trong dự án.

Nhóm	Nội dung học phần	Vai trò trong dự án
Trung tâm	DSS, quy trình ra quyết định	Từ dự báo tới hàng đợi hành động
Trung tâm	Học máy và đánh giá	Train/dev/test, metric, baseline
Trung tâm	Decision Tree, NB, k-NN, SVM, Ensemble	Sáu mô hình so sánh
Trung tâm	Text Mining, Social Media Mining	Làm sạch tweet, TF-IDF
Trung tâm	Phân cụm (Clustering)	K-Means khám phá chủ đề
Trung tâm	Phân tích luật kết hợp	Apriori trên từ khóa/hashtag
Trung tâm	BI/Dashboard	Streamlit trình bày và thao tác hàng đợi
Bổ trợ	CLIP/ViT	Trích đặc trưng ảnh cố định (frozen)
Bổ trợ	SHA/pHash, t-SNE, bootstrap	Kiểm soát rò rỉ và độ bền

Nội dung học phần thể hiện ở đâu?

Phần *trung tâm* của bài tập là tầng DSS (Chương 5) và sáu classifier cùng cách đánh giá (Chương 5), dựa trên Text Mining, Clustering và Association Analysis ở Chương 4. CLIP *không* được coi là đóng góp thuật toán chính: nó chỉ là một bộ trích đặc trưng ảnh dùng sẵn. Điều được chú trọng trong học phần là cách chọn mô hình, đánh giá trung thực và biến kết quả thành quyết định, không phải việc gọi một mô hình ảnh có sẵn.

2.9.1 Vai trò của các công cụ tính toán

Một số người đọc có thể thắc mắc vì sao một dự án “khá lớn” lại không dùng các framework học sâu hay xử lý phân tán. Lý do nằm ở *quy mô và mục tiêu*:

- **PyTorch** chỉ đóng vai trò *runtime* để nạp và chạy CLIP đã huấn luyện sẵn. Dự án không tự xây dựng hay fine-tune mạng nơ-ron sâu nào; mọi phần học máy “của dự án” nằm ở các classifier cổ điển trên scikit-learn.
- **PySpark** không được dùng vì 18.082 dòng và embedding 512 chiều vừa khít bộ nhớ một máy. Spark giải quyết bài toán dữ liệu phân tán hàng triệu đến hàng tỷ bản ghi; với quy mô này nó chỉ thêm chi phí vận hành mà không gỡ được nút thắt nào. Spark sẽ cần thiết nếu sau này dữ liệu chảy liên tục, đạt hàng triệu bản ghi hoặc phải xử lý phân tán nhiều nguồn.
- **scikit-learn**, **pandas** là phần lõi cho mô hình hóa và xử lý bảng; **Streamlit** dựng dashboard. Vai trò chi tiết của từng thư viện nằm ở bảng công nghệ Chương 7.

Tóm lại, lựa chọn công cụ bám theo nguyên tắc tối thiểu cần thiết: chỉ thêm một công nghệ khi nó giải quyết một nút thắt thật, không thêm để “cho oai”.

3 Dữ liệu, tiền xử lý và biểu diễn đặc trưng

3.1 Vai trò của dữ liệu trong bài toán

Một mô hình học máy không trực tiếp “hiểu” tweet hay ảnh. Nó học quan hệ thống kê giữa một biểu diễn số của đầu vào và nhãn mục tiêu. Vì vậy, chất lượng của dự án phụ thuộc vào ba điều kiện trước khi lựa chọn thuật toán:

1. **đúng đối tượng:** mỗi dòng phải thực sự mô tả một cặp tweet–ảnh và mang đúng nhãn chính thức;
2. **đúng ranh giới đánh giá:** thông tin của dev/test không được đi vào quá trình fit đặc trưng hoặc huấn luyện;
3. **đúng biểu diễn:** văn bản và ảnh phải được chuyển thành các vector có ý nghĩa đối với classifier.

Trong chương này, *tiền xử lý* là các thao tác làm đầu vào nhất quán hơn, chẳng hạn bỏ URL hoặc chuyển ảnh sang RGB. *Biểu diễn đặc trưng* là bước chuyển đầu vào thành vector số. *Feature engineering* là toàn bộ quá trình lựa chọn, tạo và kiểm soát các đặc trưng để mô hình sử dụng. Theo nghĩa đó, dự án có hai nhánh feature engineering: TF–IDF cho văn bản và embedding CLIP cho ảnh.

3.2 Bộ dữ liệu CrisisMMD v2.0

3.2.1 Nguồn, đơn vị quan sát và phạm vi

CrisisMMD là bộ dữ liệu đa phương thức do Qatar Computing Research Institute công bố cho nghiên cứu ứng phó thảm họa [3]. Phiên bản sử dụng trong dự án gồm **18.082 cặp tweet–ảnh** thuộc bảy sự kiện năm 2017: ba cơn bão Harvey, Irma, Maria; cháy rừng California; động đất Mexico; động đất Iraq–Iran; và lũ Sri Lanka.

Đơn vị quan sát của dự án là **một cặp tweet–ảnh**, không phải một người dùng hay một sự kiện. Một tweet có thể xuất hiện với nhiều ảnh, do đó `tweet_id` không nhất thiết duy nhất trong tập train; cặp `tweet_id`, `image_id` mới là khóa của một quan sát. Sự phân biệt này quan trọng khi kiểm tra trùng lặp và khi căn thứ tự embedding với annotation.

3.2.2 Hai nhiệm vụ dự báo

Dự án sử dụng hai bộ nhãn chung do CrisisMMD cung cấp:

Informativeness Bài đăng có chứa thông tin hữu ích cho hoạt động ứng phó thảm họa hay không. Đây là bài toán nhị phân gồm `informative` và `not_informative`.

Humanitarian category

Nếu xét nội dung nhân đạo, bài đăng thuộc nhóm nhu cầu hoặc thiệt hại nào. Đây là bài toán tám lớp: người bị ảnh hưởng; người bị thương hoặc tử vong; người mất tích hoặc được tìm thấy; thiệt hại hạ tầng và tiện ích; thiệt hại phương tiện; cứu hộ, tình nguyện hoặc quyên góp; thông tin liên quan khác; và nội dung không mang tính nhân đạo.

Ngoài nhãn chung của cặp, dữ liệu còn có nhãn riêng do người gán nhãn quan sát văn bản và ảnh. Các nhãn riêng này được dùng để chẩn đoán sự bất đồng giữa hai phương thức, không thay thế ground truth chung khi huấn luyện mô hình vận hành.

Bảng 3.1: Các trường dữ liệu được sử dụng trong pipeline.

Trường	Ý nghĩa và cách sử dụng
<code>event_name</code>	Tên thảm họa; dùng cho EDA và kiểm tra độ ổn định theo sự kiện.
<code>tweet_id, image_id</code>	Khóa nhận dạng, căn thứ tự cache và kiểm tra giao nhau giữa split.
<code>tweet_text, image</code>	Văn bản gốc và đường dẫn ảnh đầu vào.
<code>label</code>	Nhãn chung chính thức của nhiệm vụ informative.
<code>label_top</code>	Nhãn chung chính thức của nhiệm vụ humanitarian tám lớp.
<code>label_text_*</code>	Nhãn chỉ dựa trên văn bản; dùng cho phân tích bất đồng.
<code>label_image_*</code>	Nhãn chỉ dựa trên ảnh; dùng cho phân tích bất đồng.
<code>multimodal_agree</code>	Cờ đồng thuận category giữa người gán nhãn text và image.

3.3 Hợp nhất annotation và bảo toàn split

3.3.1 Vấn đề khác partition giữa hai task

CrisisMMD phát hành các file train/dev/test riêng cho từng nhiệm vụ. Partition của informative và humanitarian không giống nhau. Nếu chỉ inner join hai file cùng tên, nhiều cặp sẽ bị loại vì một mẫu có thể nằm ở train của task này nhưng nằm ở dev của task kia. Nếu suy diễn nhãn

informative chung từ nhãn humanitarian chung, **2.649/18.082 mẫu** sẽ bị gán sai, tương đương 14,65%.

Pipeline giải quyết theo ba bước:

1. chọn partition humanitarian làm ranh giới train/dev/test thống nhất;
2. ghép toàn bộ annotation informative thành bảng tra cứu theo cặp tweet_id, image_id;
3. left join nhãn informative chính thức vào từng partition humanitarian và yêu cầu quan hệ khóa là one-to-one.

Cách làm này giữ đủ 18.082 dòng, đồng thời hai nhiệm vụ dùng chung một ranh giới đánh giá. Quan hệ “khác not_humanitarian thì informative” chỉ đúng với nhãn riêng từng phương thức trong dữ liệu này; dự án không dùng quan hệ đó để tạo ground truth chung.

3.3.2 Kích thước và phân bố

Bảng 3.2: Kích thước và chất lượng cơ bản sau khi hợp nhất.

Chỉ số	Train	Dev	Test
Số cặp tweet–ảnh	13.608	2.237	2.237
Giá trị thiếu	0	0	0
Trùng cặp tweet–ảnh trong split	0	0	0
Đường dẫn ảnh thiếu	0	0	0
Số lớp humanitarian quan sát được	8	8	8
Hàng qua bộ lọc exact-duplicate	13.608	2.189	2.169
Hàng qua bộ lọc robustness	13.608	2.078	2.032

Trong train, informative có 8.338 mẫu và not-informative có 5.270 mẫu. Độ mất cân bằng nghiêm trọng hơn ở task tám lớp: not_humanitarian có 5.260 mẫu, trong khi missing_or_found_people chỉ có 24 mẫu, chênh lệch khoảng **219:1**. Hiểu trực giác, cứ **219** bài thuộc nhóm phổ biến mới có **1** bài thuộc nhóm hiếm. Accuracy vì vậy không đủ phản ánh khả năng phát hiện lớp hiếm; thiết kế đánh giá phải bổ sung Macro-F1, F2 và kết quả theo từng lớp.

Vì sao Accuracy đánh lừa khi dữ liệu lệch

Xét một lớp hiếm có 24 mẫu trên tổng 5.284 mẫu (lớp này + nhóm phổ biến). *Mô hình A* bỏ qua hoàn toàn lớp hiếm, đoán mọi bài là nhóm phổ biến: nó sai cả 24 bài hiếm nhưng vẫn đạt Accuracy $5.260/5.284 \approx 99,5\%$. *Mô hình B* bắt đúng 18/24 bài hiếm (Recall lớp hiếm = 0,75) và chỉ lỡ vài bài phổ biến, Accuracy cũng quanh 99%. Hai mô hình gần như

cùng Accuracy nhưng giá trị cứu hộ khác hẳn nhau: A bỏ sót toàn bộ người mất tích, B thì không. Đây là lý do dự án khóa Macro-F1 và Recall lớp hiểm thay vì nhìn Accuracy.

3.4 Kiểm soát trùng lặp và rò rỉ dữ liệu

3.4.1 Rò rỉ dữ liệu là gì?

Rò rỉ dữ liệu xảy ra khi quá trình huấn luyện tiếp cận thông tin mà trong sử dụng thực tế chỉ xuất hiện ở tương lai hoặc thuộc tập đánh giá. Khi đó, chỉ số test có thể cao nhưng không phản ánh khả năng tổng quát hóa. Với mạng xã hội, chỉ kiểm tra ID là chưa đủ: hai bài đăng khác ID vẫn có thể dùng cùng một ảnh hoặc cùng nội dung sau khi bỏ URL và mention.

Dự án kiểm tra bốn mức:

1. giao nhau của `tweet_id`, `image_id` và cặp ID;
2. trùng ảnh chính xác bằng SHA-256;
3. trùng văn bản sau bước làm sạch;
4. gần trùng bằng perceptual hash cho ảnh và độ tương tự ngữ nghĩa/từ vựng cho văn bản.

Không có ID hoặc cặp ID giao nhau giữa các split. Tuy nhiên, SHA-256 phát hiện 43 hash ảnh chung train–dev, 46 hash chung train–test và 21 hash chung dev–test. Có một văn bản sau làm sạch trùng giữa train với dev và một văn bản trùng giữa train với test. Trên toàn bộ corpus, 18.082 dòng chỉ tạo ra 17.777 hash ảnh duy nhất, tức 305 lần lặp ngoài ảnh đại diện đầu tiên.


3.4.2 Hai loại “vân tay” ảnh: SHA-256 và perceptual hash

Để phát hiện ảnh trùng mà không phải so từng cặp ảnh (rất tốn kém), dự án dùng hai loại hàm băm (hash) bổ sung cho nhau. Một *hàm băm* biến một đầu vào thành một chuỗi bit ngắn cố định, gọi là “vân tay”.

SHA-256 Đọc *toàn bộ byte* của file ảnh và tạo một vân tay 256 bit. Cùng một file (từng byte giống nhau) luôn cho cùng hash; chỉ cần đổi một byte, hash đã khác hẳn. SHA-256 vì vậy phát hiện ảnh *giống hệt*, nhưng *không* biết hai ảnh “trông giống nhau”.

Perceptual hash (pHash)

Rút đặc trưng thị giác tần số thấp (bỏ cục sáng/tối tổng thể) rồi tạo một vân tay 64 bit. Ảnh bị resize hoặc crop nhẹ vẫn cho hash *gần* nhau. Mức “gần” đo bằng *khoảng cách Hamming* – số bit khác nhau giữa hai hash.



Hình 3.1: Hai lớp phát hiện trùng lặp. SHA-256 chỉ bắt ảnh giống hệt từng byte; pHash bắt ảnh gần giống qua khoảng cách Hamming nhỏ.

3.4.3 Hai mặt nạ đánh giá

- Canonical mask** Loại một dòng dev/test nếu ảnh SHA-256 hoặc văn bản đã làm sạch của nó đã xuất hiện ở split trước. Đây là bộ lọc tự động có tiêu chí xác định và được dùng trong quy trình chọn mô hình ban đầu.
- Robustness mask** Bắt đầu từ canonical mask, sau đó loại thêm các cặp gần trùng đã được duyệt theo từng cặp. Ảnh ứng viên dùng pHash DCT 64-bit với khoảng cách Hamming không quá 4; văn bản dùng kết hợp cosine của CLIP text embedding và TF-IDF ký tự/từ. Mặt nạ này dùng để kiểm tra độ bền của kết luận, không tự động coi mọi ứng viên là bản sao.

Sau duyệt cặp, robustness mask loại thêm 111 dòng dev và 137 dòng test so với canonical mask. Việc báo cáo cả kết quả canonical và robustness giúp phân biệt hai câu hỏi: mô hình hoạt động thế nào trên split đã làm sạch bản sao chính xác, và kết luận còn giữ được hay không khi loại cả những bản sao gần.

3.5 Tiền xử lý và feature engineering văn bản

3.5.1 Làm sạch tweet

Tweet chứa nhiều token phục vụ nền tảng hơn là nội dung: URL rút gọn, mention, HTML entity và dấu câu. Hàm làm sạch thực hiện lần lượt:

1. chuyển chữ thường;
2. bỏ HTML entity, URL và @mention;
3. bỏ ký hiệu # nhưng giữ từ khóa hashtag;
4. chỉ giữ chữ cái Latin, chữ số và khoảng trắng;
5. gộp nhiều khoảng trắng liên tiếp.

Ví dụ:

Trước	URGENT:\Flood\waters\rising!\@Police\https://t.co/x\ #Harvey
Sau	urgent\flood\waters\rising\harvey

Giữ nội dung hashtag là quyết định có chủ đích vì tên thảm họa hoặc chủ đề cứu trợ thường nằm trong hashtag. Ngược lại, bỏ URL và mention giúp giảm số token chỉ xuất hiện một lần.

Một câu hỏi quan trọng: *còn loại rác nào không nằm trong các bước làm sạch ở trên thì sao?* Một bộ quy tắc regex **không thể** liệt kê mọi dạng nhiễu của ngôn ngữ mạng xã hội. Vì vậy báo cáo phân loại rõ ba mức xử lý ở Bảng 3.3 thay vì tuyên bố dữ liệu đã “sạch hoàn toàn”.

Bảng 3.3: Ba mức xử lý nhiễu trong văn bản tweet.

Mức xử lý	Loại nhiễu
Đã xử lý trực tiếp	URL, @mention, HTML entity, ký hiệu #, ký tự không phải chữ/số.
Giảm tác động (không loại hẳn)	Token quá hiếm bị cắt bởi giới hạn 2.000 đặc trưng và min_df; stopword tiếng Anh bị bỏ trọng số.
Chưa xử lý tốt	Emoji, mĩa mai và phủ định, lỗi chính tả, văn bản đa ngôn ngữ, tweet chỉ có URL (rỗng sau làm sạch), spam lặp từ.

Một audit định lượng trên dữ liệu thật (lưu ở `text_cleaning_audit.json`) cho thấy: trung bình **40%** ký tự mỗi tweet bị loại khi làm sạch – phần lớn là URL và mention; **không có** tweet nào trở thành chuỗi rỗng sau làm sạch (mọi tweet vẫn còn nội dung), nên cơ chế “tweet chỉ có URL thành rỗng” là một rủi ro lý thuyết chứ không xảy ra trong corpus này; và khi chuyển sang dev/test, tỷ lệ token nằm ngoài từ vựng train (OOV) là **7,6%** và **7,8%** – đủ thấp để TF-IDF vẫn phủ phần lớn nội dung.

Phần rác còn lại chủ yếu mang tính ngữ nghĩa: một tweet mĩa mai (“great, another flood”) có thể bị TF-IDF hiểu sai. Đây là lý do các ca như vậy được đẩy sang Manual Review thay vì tin tuyệt đối vào dự báo (xem Mục 1.7). Việc loại emoji, dấu tiếng nước ngoài và không xử lý mĩa mai là một đánh đổi có chủ đích để giữ pipeline đơn giản, kiểm tra được và phù hợp corpus chủ yếu tiếng Anh.

3.5.2 TF-IDF

Classifier không nhận chuỗi ký tự trực tiếp. TF-IDF chuyển mỗi văn bản thành vector thưa, trong đó một chiều tương ứng với một từ hoặc cặp từ. Trọng số của term t trong document d được mô tả bởi:

$$\text{tfidf}(t, d) = \text{tf}(t, d) \times \log \left(\frac{N + 1}{\text{df}(t) + 1} \right) + 1,$$

trong đó $tf(t, d)$ phản ánh số lần term xuất hiện, $df(t)$ là số văn bản chứa term và N là số văn bản train. Trực giác là một từ xuất hiện nhiều trong một tweet nhưng hiếm trên toàn corpus sẽ mang nhiều thông tin phân biệt hơn từ phổ biến ở mọi tweet.

Các cấu hình thực tế của vectorizer là:

- tối đa 2.000 đặc trưng có thứ tự theo thống kê của tập train;
- unigram và bigram, tức một từ và hai từ liên tiếp;
- stopwords tiếng Anh của scikit-learn;
- chuẩn hóa L_2 mặc định cho từng vector.

Bigram giúp phân biệt các cụm như power\outage, missing\people hoặc need\shelter, trong khi unigram giữ độ phủ khi câu ngắn. Giới hạn 2.000 chiều giảm chi phí và nhiễu so với giữ toàn bộ từ vựng, nhưng có thể bỏ sót term hiếm. Vectorizer **chỉ fit trên train**; dev và test chỉ gọi transform. Nếu fit trên toàn corpus, tần suất tài liệu của dev/test sẽ đi vào IDF và gây rò rỉ nhẹ nhưng có thật.

Ví dụ tính tay. Xét ba tweet đồ chơi đã làm sạch ($N = 3$): $d_1 = \text{“flood rescue now”}$, $d_2 = \text{“flood power outage”}$, $d_3 = \text{“donation drive”}$. Từ *flood* xuất hiện ở 2 văn bản ($df = 2$), còn *rescue* chỉ ở 1 ($df = 1$). Theo công thức (dạng smooth của scikit-learn):

$$\text{idf}(\text{flood}) = \ln \frac{1+3}{1+2} + 1 = 1,288, \quad \text{idf}(\text{rescue}) = \ln \frac{1+3}{1+1} + 1 = 1,693.$$

Mỗi từ xuất hiện một lần trong d_1 nên $tf = 1$, suy ra $tfidf(\text{flood}, d_1) = 1,288$ và $tfidf(\text{rescue}, d_1) = 1,693$. Như vậy *rescue* (hiếm hơn) được trọng số cao hơn *flood* (phổ biến hơn) – đúng trực giác: từ hiếm phân biệt tốt hơn. Sau chuẩn hóa L_2 cho vector d_1 (ba từ flood/rescue/now), trọng số flood là $1,288/2,719 = 0,47$ và rescue là $1,693/2,719 = 0,62$. Ma trận document-term tương ứng (chưa chuẩn hóa) là một ma trận thưa:

Bảng 3.4: Ma trận document-term TF-IDF của ba tweet đồ chơi (ô trống = 0).

	flood	rescue	now	power	outage	donation	drive
d_1	1,29	1,69	1,69				
d_2	1,29			1,69	1,69		
d_3						1,69	1,69

Điểm yếu cần nhớ: TF-IDF chỉ đếm từ và cặp từ, *không* hiểu thứ tự xa, phủ định (“no rescue needed”) hay mỉa mai, và xem các từ là độc lập. Đây là lý do nhánh văn bản cần được bổ sung bằng ảnh và bằng Manual Review cho ca mơ hồ.

3.6 Tiền xử lý và feature engineering ảnh

3.6.1 Từ pixel đến vector đặc trưng

Ảnh có hàng trăm nghìn giá trị pixel, quá nhiều để các classifier cổ điển học trực tiếp trên 13.608 mẫu train. Dự án sử dụng CLIP ViT-B/32 [5] như một **bộ trích đặc trưng tiền huấn luyện**. Các khái niệm cần phân biệt:


Tiền huấn luyện Mô hình CLIP đã được tác giả gốc học trước trên lượng lớn cặp ảnh–văn bản, trước khi dự án này sử dụng nó.

Transfer learning Tri thức hình ảnh đã học được chuyển sang bài toán CrisisMMD thay vì huấn luyện mạng sâu từ đầu.

Frozen feature extractor Trọng số CLIP được giữ nguyên; dự án chỉ chạy forward pass để lấy vector. Không có gradient và không cập nhật CLIP.

Fine-tuning Là cập nhật một phần hoặc toàn bộ trọng số mô hình tiền huấn luyện bằng dữ liệu đích. **Dự án không fine-tune CLIP.**

Trong ViT-B/32, ảnh 224×224 được chia thành lưới 7×7 gồm 49 patch kích thước 32×32 . Mỗi patch được biến thành một token và đi qua Transformer để tổng hợp quan hệ giữa các vùng ảnh, cuối cùng thu về một vector 512 chiều (Hình 3.2a). CLIP được học bằng *mục tiêu tương phản* (contrastive): trong một lô ảnh–caption, vector của mỗi ảnh được kéo gần caption đúng của nó và đẩy xa các caption còn lại (Hình 3.2b). Nhờ vậy embedding chứa thông tin ngữ nghĩa cao hơn màu sắc hay histogram đơn giản.



Hình 3.2: Cách CLIP biến ảnh thành vector và cách nó được huấn luyện tương phản.


Một ví dụ trực giác về lân cận: trong không gian CLIP, vector của một ảnh *đường ngập* thường gần vector của một ảnh ngập khác hơn là gần ảnh *thùng quỳên góp*. Cần nhấn mạnh: embedding **không phải** là xác suất hay nhãn; nó chỉ là tọa độ ngữ nghĩa. Chính classifier phía sau (Chương 5) mới học ranh giới giữa các lớp CrisisMMD trên không gian đó. Và như đã nêu, CLIP luôn được giữ **frozen, không fine-tune**.

3.6.2 Quy trình trích xuất thực tế

Mỗi ảnh được:

1. mở bằng Pillow, chuyển về ba kênh RGB và resize 224×224 ;
2. đưa qua bộ xử lý chính thức của CLIP và forward pass ở chế độ eval trong `torch.no_grad()`;
3. lấy projected image embedding 512 chiều;
4. chuẩn hóa L_2 : $\hat{\mathbf{x}} = \mathbf{x} / \|\mathbf{x}\|_2$;
5. lưu cache theo đúng thứ tự `tweet_id, image_id`.

Chuẩn hóa L_2 đưa mọi vector lên mặt cầu đơn vị, giúp khoảng cách và tích vô hướng phản ánh hướng ngữ nghĩa thay vì độ lớn tùy ý. Cache có shape (13.608, 512), (2.237, 512), (2.237, 512) cho train/dev/test. Audit cho thấy norm trung bình bằng 1, độ lệch chuẩn toàn ma trận khoảng 0,04418, không có vector zero và metadata khớp thứ tự annotation.



Hình 3.3: Hai ảnh train cho mỗi lớp trong tám lớp humanitarian, lấy mẫu xác định bằng seed 42 (không chọn tay theo ảnh “đẹp”), nên gallery không bị thiên lệch chủ quan.

3.6.3 Lý do giữ CLIP cố định

Giữ CLIP cố định phù hợp với phạm vi dự án vì:

- mục tiêu học phần là so sánh các thuật toán phân lớp và xây dựng DSS, không phải thiết kế mạng sâu;
- 13.608 mẫu train và các lớp hiếm rất nhỏ làm fine-tuning toàn mạng có nguy cơ overfit;
- embedding được tính một lần, sau đó cùng một không gian đặc trưng được dùng để so sánh công bằng sáu classifier;
- chi phí huấn luyện và triển khai thấp hơn, kết quả dễ tái lập hơn.

Đánh đổi là đặc trưng không được điều chỉnh riêng cho ảnh thảm họa. Kết quả của nhánh ảnh vì vậy phải được hiểu là “classifier trên đặc trưng CLIP cố định”, không phải thành tích của một CLIP đã được huấn luyện cho CrisisMMD.

3.7 Tổng hợp đặc trưng đầu vào mô hình

Bảng 3.5: Đặc trưng được tạo và nơi chúng được sử dụng.

Nguồn	Biểu diễn	Kích thước	Vai trò
Tweet	TF-IDF word 1–2 gram	2.000, vector thưa	Đầu vào sáu classifier văn bản cho hai task.
Ảnh	CLIP ViT-B/32 frozen embedding	512, vector đặc	Đầu vào sáu classifier ảnh cho hai task.
Xác suất mô hình	Vector xác suất đã căn lớp	2 hoặc 8	Đầu vào Late Fusion và conflict score.
Từ khóa nghiệp vụ	Cờ xuất hiện trong tweet đã làm sạch	một số cờ nhị phân	Tín hiệu bổ sung cho Risk Score, không dùng để thay đổi ground truth.

Như vậy, feature engineering của dự án không phải là một bước trang trí trước mô hình. Nó quyết định loại thông tin mà classifier có thể nhìn thấy, chi phí tính toán, nguy cơ rò rỉ và khả năng giải thích. Chương tiếp theo sử dụng chính các biểu diễn này để phân tích cấu trúc dữ liệu trước khi huấn luyện.

4 Phân tích khám phá dữ liệu


4.1 Mục đích và nguyên tắc EDA

Exploratory Data Analysis (EDA) là quá trình dùng thống kê mô tả và trực quan để hiểu cấu trúc dữ liệu trước khi xây mô hình. EDA không chỉ nhằm tạo biểu đồ; nó phải trả lời các câu hỏi có ảnh hưởng tới thiết kế:

- nhãn có mất cân bằng hay không;
- phân bố có thay đổi giữa các sự kiện hay không;
- văn bản và ảnh có chứa tín hiệu quan sát được nào;
- có cấu trúc cụm hoặc luật đồng xuất hiện nào;
- hai phương thức thường đồng thuận hay mâu thuẫn;
- các quan sát trên dẫn tới quyết định kỹ thuật nào.

EDA phục vụ lựa chọn phương pháp chỉ sử dụng **13.608 mẫu train**. Nếu xem phân bố nhãn hoặc pattern của test rồi điều chỉnh model, test sẽ tham gia gián tiếp vào thiết kế. Kiểm kê file và kiểm tra duplicate được phép bao phủ toàn corpus vì đó là kiểm soát tính toàn vẹn đầu vào, không phải tìm pattern để tối ưu model.

4.2 Phân bố nhãn và hệ quả




Hình 4.1: Phân bố informative và humanitarian trên train.

Informative chiếm 61,27% train. Đây là mức lệch vừa phải nhưng đủ làm always-informative có Recall và F2 cao. Ở task humanitarian, lớp not-humanitarian có 5.260 mẫu trong khi missing/found chỉ có 24 mẫu, chênh **219:1**. Ba hệ quả trực tiếp là:

1. không chọn model chỉ bằng Accuracy;
2. sử dụng class weight khi thuật toán hỗ trợ;
3. báo cáo Macro-F1, confusion matrix và F1 theo lớp.

Từ phân bố không thể kết luận lớp hiếm sẽ dự báo kém trong mọi trường hợp, nhưng có thể kết luận ước lượng metric của lớp đó có độ bất định lớn và một vài dự báo có thể làm F1 thay đổi mạnh.


4.3 Khác biệt theo sự kiện



Hình 4.2: Số mẫu và cơ cấu humanitarian theo sự kiện trên train.

Sri Lanka floods có 69,29% not-humanitarian, trong khi Iraq–Iran earthquake chỉ 22,76%. Mexico earthquake có 27,95% rescue/donation; Iraq–Iran có 13,57% injured/dead, cao hơn rõ rệt các cơn bão. Đây là *distribution shift theo sự kiện*: quan hệ giữa event và tỷ lệ nhãn không đồng nhất.

EDA chưa chứng minh model sẽ thất bại trên event mới, vì tất cả event vẫn xuất hiện trong train/dev/test. Tuy nhiên, nó chỉ ra rằng metric gộp có thể che khác biệt từng thảm họa. Vì vậy dashboard có bộ lọc event và phần đánh giá sau này báo cáo độ ổn định theo event. Một đánh giá nghiêm ngặt hơn trong tương lai là *leave-one-event-out*: giữ toàn bộ một thảm họa ngoài train (Hình 4.3). Cách chia chính thức hiện tại cho mỗi event xuất hiện ở cả ba split, nên mô hình luôn “đã thấy” kiểu dữ liệu của mọi sự kiện – một điều kiện dễ hơn thực tế triển khai.




Hình 4.3: Chia chính thức: mọi sự kiện có mặt ở cả train/dev/test. Leave-one-event-out: toàn bộ một sự kiện bị giữ ngoài train để đo domain shift thật.

4.4 Khám phá văn bản

Phần này không nhảy thẳng vào con số. Quy trình EDA văn bản đi theo bảy bước để mỗi biểu đồ trả lời một câu hỏi cụ thể: (1) đặt câu hỏi (độ dài có phân biệt được nhãn không?); (2) tạo biến độ dài ký tự và số token; (3) phân nhóm theo nhãn và sự kiện; (4) so sánh phân bố; (5) xem top token nổi bật; (6) kiểm tra nhiễu còn sót; (7) rút kết luận có giới hạn. Cần phân biệt rõ *thống kê mô tả* (dữ liệu trông thế nào) với *bằng chứng dự báo* (đặc trưng có giúp phân loại không) – EDA chỉ cho cái thứ nhất.

Áp dụng bước (2)–(4): tweet có trung bình 117,48 ký tự và 11,72 từ sau làm sạch. Số từ trung bình của informative là 11,75, gần như bằng 11,68 của not-informative.



Hình 4.4: Phân bố độ dài và token nổi bật trên train.

Sự gần nhau của độ dài cho thấy một rule kiểu “tweet dài thì informative” không có cơ sở. Nội dung từ và cụm từ mới là tín hiệu phù hợp cho TF-IDF. Các token nổi bật còn phản ánh tên địa điểm, cứu trợ, thiệt hại và bối cảnh sự kiện; vì thế khi clustering theo chủ đề, dự án loại thêm tên event và token nền tảng như rt, amp, http để tránh cụm chỉ tái hiện nguồn dữ liệu.

4.5 K-Means cho khám phá chủ đề

4.5.1 Khái niệm và hàm mục tiêu

Clustering là học không giám sát: thuật toán không nhìn nhãn humanitarian mà nhóm các điểm giống nhau. K-Means tìm K tâm cụm $\mu_1, \dots, \mu_K$ để tối thiểu hóa tổng bình phương

khoảng cách trong cụm:

$$J = \sum_{i=1}^n \|\mathbf{x}_i - \boldsymbol{\mu}_{c_i}\|_2^2.$$

Thuật toán lặp hai bước (Hình 4.5): gán mỗi điểm vào tâm gần nhất, rồi cập nhật tâm bằng trung bình các điểm được gán; lặp tới khi tâm không đổi. K-Means nhanh và dễ đọc top term từ centroid, nhưng phải chọn K , nhạy với khởi tạo và giả định cụm gần *dạng cầu* trong không gian khoảng cách [9]. Giả định dạng cầu này yếu khi không gian là TF-IDF nhiều nghìn chiều và thừa, một lý do khiến silhouette dưới đây rất thấp.

1. Gán điểm vào tâm gần nhất rồi cập nhật tâm về trung bình cụm



Hình 4.5: Một vòng lặp K-Means trên ví dụ 2D: gán điểm theo tâm gần nhất rồi cập nhật tâm. Ngôi sao là centroid.


Dự án dùng TF-IDF tối đa 2.000 unigram/bigram, $\text{min_df}=3$, mười lần khởi tạo và random seed 42. Sweep $K = 2, \dots, 12$ được thực hiện trên cùng một mẫu 8.000 dòng train để các giá trị so sánh được.

4.5.2 Silhouette và kết quả


Silhouette của điểm i là:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

trong đó $a(i)$ là khoảng cách trung bình tới điểm cùng cụm và $b(i)$ là khoảng cách trung bình nhỏ nhất tới một cụm khác. Giá trị gần 1 cho thấy điểm nằm gọn trong cụm; gần 0 cho thấy các cụm chồng lấn; âm cho thấy có thể gán sai.



(a) Silhouette với $K = 2, \dots, 12$.



(b) Crosstab $K = 8$ với nhãn thật.

Hình 4.6: Phân cụm TF-IDF trên train.

Silhouette chỉ khoảng 0,014–0,024 và tăng nhẹ tới biên khảo sát, không có điểm gãy rõ. Với

$K = 8$, silhouette là 0,021. $K = 8$ được giữ để đối chiếu với taxonomy tám lớp, **không phải** vì dữ liệu chứng minh tám cụm là tối ưu.

Top term cho thấy một số chủ đề có nghĩa như storm/surge, relief effort, help victims, Puerto Rico/power và rescue. Tuy nhiên, mỗi cụm vẫn chứa nhiều nhãn humanitarian. Kết luận hợp lệ là K-Means hữu ích để duyệt chủ đề và phát hiện nhóm nội dung; nó không đủ ổn định để thay classifier hoặc routing.

4.6 Apriori và luật kết hợp

4.6.1 Từ tweet thành transaction

Association analysis tìm các item thường xuất hiện cùng nhau. Mỗi tweet được chuyển thành một “giỏ” (transaction) gồm từ khóa khủng hoảng và hashtag. Ví dụ cụ thể: tweet “#iran #earthquake rescue teams searching” sau khi tách trở thành giỏ $\{\#iran, \#earthquake, rescue\}$, rồi được biểu diễn thành một hàng one-hot (giá trị 1 ở các cột item có mặt, 0 ở các cột còn lại):

Bảng 4.1: Một tweet biến thành transaction one-hot.

	#iran	#earthquake	rescue	flood	...
transaction	1	1	1	0	...

Chỉ transaction có *ít nhất hai item* được giữ, vì một luật cần cả tiền đề và kết quả. Nếu một từ đã xuất hiện dưới dạng hashtag, phiên bản không có dấu # bị bỏ để tránh luật hiển nhiên như $\{\#earthquake\} \Rightarrow \{earthquake\}$. Một điểm dễ nhầm: **mẫu số của support là số transaction đã giữ**, không phải toàn bộ 13.608 tweet train.

Apriori dựa trên tính chất: nếu một itemset không đủ phổ biến, mọi superset của nó cũng không thể đủ phổ biến. Nhờ vậy thuật toán loại sớm nhiều ứng viên [10]. Ba đại lượng chính là:

$$\text{support}(A \Rightarrow B) = P(A \cup B),$$

$$\text{confidence}(A \Rightarrow B) = P(B | A) = \frac{P(A \cup B)}{P(A)},$$

$$\text{lift}(A \Rightarrow B) = \frac{P(A \cup B)}{P(A)P(B)}.$$

Lift bằng 1 tương ứng đồng xuất hiện như kỳ vọng nếu độc lập; lớn hơn 1 cho thấy liên kết dương. Support trong phân tích này được tính trên tập transaction đã giữ, không phải toàn bộ 13.608 tweet. Ngưỡng dùng là support 0,005 và confidence 0,25; 20 luật lift cao nhất được lưu.

4.6.2 Kết quả và cách diễn giải

Bảng 4.2: Một số luật Apriori trên train.

Tiền đề	Kết quả	Support	Confidence	Lift
#floods1	#lka	.010	.539	40.013
#iraq	#iran	.006	.659	25.672
#wildfires	#california	.007	.508	25.541
#iran	#earthquake	.018	.717	18.507
#puertorico	#hurricanemaria	.025	.627	7.045

Đọc một dòng cụ thể: luật $\{\#iran\} \Rightarrow \{\#earthquake\}$ có support 0,018 (1,8% giỏ chứa cả hai), confidence 0,717 (trong các giỏ có #iran, 71,7% cũng có #earthquake) và lift 18,5 (cặp này đi cùng nhau cao gấp khoảng 18,5 lần so với khi hai hashtag độc lập).

Các luật chủ yếu nổi địa danh với sự kiện, phù hợp cho filter và drill-down. Lift cao không có nghĩa tiền đề gây ra kết quả; nó cũng có thể cao vì hai hashtag cùng được dùng trong một chiến dịch truyền thông nhỏ. Association rules vì vậy không dùng để dự báo Priority hay thay classifier.

4.7 EDA ảnh và không gian embedding

Kiểm kê toàn corpus xác nhận 18.082 ảnh annotation hợp lệ, nhiều kích thước và mode màu; toàn bộ được chuyển RGB trước CLIP. Gallery theo lớp được lấy từ train để kiểm tra trực quan rằng dữ liệu là ảnh thẩm họa thật, không phải ô màu hay placeholder.


Gallery theo lớp (lấy mẫu xác định bằng seed) đã trình bày ở Chương 3; ở đây tập trung vào *không gian embedding*.

4.7.1 PCA: vì sao 512 chiều khó nhìn

Embedding CLIP đã có sẵn 512 chiều. Vì vậy để trực quan hóa phải *giảm* chiều, không phải “tăng chiều”. PCA (Principal Component Analysis) tìm các trục giữ nhiều phương sai nhất rồi chiếu dữ liệu xuống vài trục đó. Trên 13.608 embedding train, kết quả định lượng cho thấy không gian rất “trải”:


- thành phần chính thứ nhất (PC1) chỉ giữ **7,5%** phương sai, PC2 giữ **4,8%**; hai trục đầu cộng lại chỉ **12,4%**;
- cần tới **32** thành phần mới đạt 50% phương sai tích lũy.

Con số này giải thích vì sao một hình 2D bất kỳ (PCA hay t-SNE) chỉ thấy một lát rất mỏng của thông tin, và vì sao các lớp trông chồng lấn dù classifier vẫn phân biệt được trên đủ 512 chiều.



Hình 4.7: Trái: phương sai tích lũy theo số thành phần PCA (đường ngang 80% chưa đạt trong 50 thành phần). Phải: hình chiếu PCA 2D tuyến tính của embedding train, tô màu theo nhãn – các lớp chồng lấn vì 2 trục chỉ giữ 12,4% phương sai.

t-SNE là phương pháp giảm chiều phi tuyến, cố gắng bảo toàn lân cận cục bộ khi chiếu vector 512 chiều xuống hai chiều [11]. Khác PCA tuyến tính, t-SNE giữ *lân cận cục bộ* nhưng *không* bảo toàn khoảng cách toàn cục, nên không dùng để chấm điểm mô hình. Hình t-SNE được tạo từ 3.000 embedding train, perplexity 30, khởi tạo PCA và seed 42.




Hình 4.8: t-SNE của CLIP embedding train, tô màu theo ground truth chung.

Một số vùng cục bộ xuất hiện nhưng các lớp chồng lấn mạnh. t-SNE có thể thay đổi theo

tham số và làm biến dạng khoảng cách toàn cục, nên hình này không chứng minh khả năng phân lớp. Giá trị của CLIP phải được xác nhận bằng dev/test ở Chương 5.

4.8 Bất đồng đa phương thức



Hình 4.9: Tỷ lệ nhãn category text và image bất đồng trên train.

55,0% mẫu train có nhãn category text và ảnh khác nhau. Theo từng lớp, tỷ lệ bất đồng là 91,7% ở missing/found, 91,0% ở injured/dead, 88,9% ở affected và 87,3% ở vehicle damage. Not-humanitarian thấp hơn nhưng vẫn đạt 38,2%.

Các con số không chứng minh text đúng và ảnh sai, vì nhãn riêng chỉ phản ánh nội dung nhìn thấy ở từng phương thức. Một tweet có thể nhắc người mất tích nhưng dùng ảnh phong cảnh, hoặc ảnh có thiệt hại mà câu chữ chỉ nêu địa danh. Suy luận hợp lệ là hai phương thức mang bằng chứng không đồng nhất. Vì vậy:

1. fusion phải được tune trên nhãn chung chính thức;
2. không dùng phép “nếu text khác image thì một bên sai”;
3. conflict cao là tín hiệu yêu cầu người kiểm tra, không tự động hạ độ tin cậy của mọi dự báo.

4.9 Từ bằng chứng EDA đến quyết định thiết kế

Bảng 4.3: Chuỗi bằng chứng, suy luận và quyết định.

Bằng chứng train	Suy luận có giới hạn	Quyết định
Mất cân bằng 219:1	Accuracy che khuất lớp hiếm	F2, Macro-F1, class weight
Event profile khác nhau	Có nguy cơ domain shift	Filter và metric theo event
Độ dài hai lớp gần nhau	Length không đủ phân loại	TF-IDF nội dung
Silhouette rất thấp	Cụm không đủ ổn định cho quyết định	K-Means chỉ cho khám phá
Luật hashtag lift cao	Context sự kiện có cấu trúc	Drill-down phụ trợ
55% modality bất đồng	Không tin tuyệt đối một nhánh	Tune fusion, Manual Review
Ảnh lặp xuyên split	Metric có thể lạc quan	Canonical/robust mask

EDA vì vậy có giá trị khi nó thay đổi cách đánh giá và kiến trúc. Các kết luận trên đều dừng ở mức dữ liệu cho phép; tương quan, hình chiếu hai chiều và luật đồng xuất hiện không được diễn giải thành quan hệ nhân quả.

5 Mô hình dự báo, hợp nhất và chính sách DSS

5.1 Bài toán học có giám sát

Học có giám sát sử dụng các cặp $(\mathbf{x}_i, y_i)$, trong đó $\mathbf{x}_i$ là vector đặc trưng và y_i là nhãn đã biết, để học hàm $f(\mathbf{x})$ dự báo nhãn cho mẫu mới. Dự án có bốn bài toán con:

1. TF-IDF $\rightarrow$ informative;
2. TF-IDF $\rightarrow$ humanitarian category;
3. CLIP image embedding $\rightarrow$ informative;
4. CLIP image embedding $\rightarrow$ humanitarian category.

Cùng sáu họ thuật toán được so sánh ở cả hai phương thức. Cách làm này tách hai câu hỏi: biểu diễn nào chứa tín hiệu hữu ích, và thuật toán nào khai thác biểu diễn đó tốt hơn. Nó cũng tránh quy toàn bộ kết quả nhánh ảnh cho CLIP: CLIP chỉ tạo đặc trưng; classifier phía sau mới được huấn luyện trên CrisisMMD.

5.2 Sáu thuật toán phân lớp

5.2.1 Logistic Regression

Mặc dù có tên “regression”, Logistic Regression là mô hình phân lớp. Với bài toán nhị phân, mô hình tính:

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Vector trọng số $\mathbf{w}$ cho biết mỗi đặc trưng đẩy log-odds về lớp nào. Với tám lớp, phiên bản đa lớp dùng softmax để tạo một phân bố xác suất tổng bằng 1. Logistic Regression phù hợp với TF-IDF và embedding vì học biên quyết định tuyến tính, huấn luyện nhanh và xuất xác suất trực tiếp. Giới hạn là quan hệ giữa đặc trưng và log-odds bị giả định tuyến tính; tương tác phức tạp không được tự động khám phá.

5.2.2 Decision Tree

Decision Tree chia không gian đặc trưng bằng chuỗi điều kiện dạng “đặc trưng j có lớn hơn ngưỡng c hay không”. Mỗi phép chia được chọn để giảm độ hỗn tạp, thường đo bằng Gini:

$$G = 1 - \sum_{k=1}^K p_k^2,$$

với p_k là tỷ lệ lớp k trong một nút. Cây dễ giải thích bằng đường đi từ gốc tới lá và có thể mô tả quan hệ phi tuyến. Tuy nhiên, cây đơn lẻ có phương sai cao, dễ học chi tiết ngẫu nhiên; trên TF-IDF 2.000 chiều, nhiều phép chia trên term hiếm làm cây đặc biệt dễ overfit. Dự án giới hạn `max_depth=20` ở vòng so sánh ban đầu.

5.2.3 Naive Bayes

Naive Bayes áp dụng định lý Bayes:

$$P(y \mid \mathbf{x}) \propto P(y) \prod_j P(x_j \mid y),$$

và giả định các đặc trưng độc lập có điều kiện khi biết lớp. Giả định này “ngây thơ” nhưng thường hiệu quả với văn bản. Multinomial Naive Bayes được dùng cho TF-IDF không âm; Gaussian Naive Bayes được dùng cho embedding đặc, với giả định mỗi chiều gần phân phối chuẩn trong từng lớp. Ưu điểm là nhanh, ổn định ở dữ liệu nhiều chiều. Nhược điểm là giả định độc lập/chuẩn hóa hiếm khi đúng hoàn toàn và xác suất có thể quá tự tin.

5.2.4 k-Nearest Neighbors

k-NN không học một công thức tham số. Khi có mẫu mới, thuật toán tìm k mẫu train gần nhất rồi bỏ phiếu. Với distance weighting, láng giềng gần có trọng số lớn hơn. Trên embedding ảnh đã chuẩn hóa L_2 , khoảng cách Euclidean và cosine có quan hệ đơn điệu:

$$\|\hat{\mathbf{x}} - \hat{\mathbf{z}}\|_2^2 = 2 - 2 \cos(\hat{\mathbf{x}}, \hat{\mathbf{z}}).$$

k-NN phù hợp để kiểm tra cấu trúc lân cận trong không gian CLIP. Trên TF-IDF thưa, “lời nguyên số chiều” làm nhiều điểm có khoảng cách gần tương tự nhau, dẫn đến kết quả yếu. Chi phí dự báo cũng cao vì phải so sánh với tập train và model phải lưu đặc trưng train.

5.2.5 Support Vector Machine


SVM tuyến tính tìm siêu phẳng $\mathbf{w}^T \mathbf{x} + b = 0$ có biên lớn giữa các lớp. Trục góc của biên lớn là không chỉ phân đúng mẫu train mà còn giữ khoảng cách với các mẫu gần ranh giới. Tham số C điều khiển đánh đổi: C lớn phạt lỗi train mạnh hơn, còn C nhỏ chấp nhận thêm lỗi để có biên đều hơn [7].

SVM tuyến tính thường mạnh trên TF-IDF vì xử lý tốt không gian nhiều chiều và thưa. Bản thân LinearSVC tạo decision score, không tạo xác suất. Dự án bọc mô hình bằng lớp

CalibratedClassifierCV với sigmoid và ba fold nội bộ để tạo `predict_proba` cho Late Fusion. Calibration này chỉ dùng dữ liệu train, không dùng dev/test.

5.2.6 Random Forest

Random Forest là ensemble của nhiều Decision Tree. Mỗi cây học trên một bootstrap sample và chỉ xét một tập con đặc trưng ở mỗi nút; dự báo cuối là bỏ phiếu hoặc trung bình xác suất [8]. Hai nguồn ngẫu nhiên làm các cây bớt tương quan, từ đó giảm phương sai so với một cây đơn. Dự án dùng 200 cây và `balanced_subsample`. Đánh đổi là model lớn hơn, giải thích khó hơn cây đơn và có thể không tận dụng không gian TF-IDF tuyến tính tốt bằng SVM.



Hình 5.1: Trục giác hình dạng ranh giới quyết định của sáu họ trên cùng một dữ liệu hai lớp (sơ đồ minh họa): tuyến tính (LR, SVM), bậc thang theo trục (Cây, Rừng), cong (Naive Bayes) và cục bộ gồ ghề (k-NN).

5.2.7 Vì sao không dùng XGBoost hay mạng sâu?

Một câu hỏi tự nhiên là vì sao không thêm XGBoost hoặc một classifier sâu. Lý do không phải vì các mô hình đó “kém” – mà vì chúng *chưa cần* để trả lời câu hỏi hiện tại:

- mục tiêu học phần là *bao phủ* các họ thuật toán trong chương trình và so sánh chúng *có kiểm soát* trên cùng đặc trưng, không phải săn Accuracy cao nhất bằng mọi giá;
- trên TF-IDF tuyến tính, SVM/LR tuyến tính thường đã là baseline rất mạnh; lợi ích biên của boosting trên đặc trưng thưa này thường nhỏ;
- các lớp hiếm (5–24 mẫu) quá nhỏ, mô hình càng phức tạp càng dễ overfit và càng khó đánh giá đáng tin;
- thêm một họ mô hình mới chỉ hợp lệ nếu kèm một protocol tuning công bằng như các họ còn lại; thêm tùy tiện sẽ làm so sánh thiên lệch.

XGBoost và mô hình sâu vì vậy được đặt ở hướng phát triển, gắn với điều kiện có thêm dữ liệu lớp hiếm và một quy trình đánh giá tương xứng.

5.3 Mất cân bằng lớp và trọng số

Với K lớp, scikit-learn đặt trọng số cân bằng xấp xỉ:

$$w_k = \frac{n}{K n_k},$$

trong đó n_k là số mẫu lớp k . Lớp hiếm nhận trọng số lỗi lớn hơn trong hàm mục tiêu. Logistic Regression, Decision Tree, SVM và Random Forest sử dụng class weight tương ứng; Naive Bayes và k-NN giữ cơ chế gốc.

Class weight không tạo thêm thông tin. Nó chỉ thay đổi chi phí sai số, thường tăng Recall lớp hiếm nhưng có thể giảm Precision. Với lớp missing chỉ có 24 mẫu train, không thể suy luận rằng class weight đã giải quyết thiếu dữ liệu; kết quả theo lớp vẫn phải được báo cáo.

5.4 Các chỉ số đánh giá

5.4.1 Nhị phân informative

Trước khi định nghĩa metric cần có *confusion matrix* – bảng đếm bốn loại kết quả. Gọi TP là informative dự báo đúng, FP là not-informative bị báo nhầm, FN là informative bị bỏ sót và TN là not-informative dự báo đúng:

Bảng 5.1: Confusion matrix nhị phân với một ví dụ số (100 mẫu).

		Dự báo	
		informative	not-informative
Thực tế	informative	TP = 55	FN = 5
	not-informative	FP = 15	TN = 25

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$

Với ví dụ trên: Accuracy = $(55 + 25)/100 = 0,80$; Precision = $55/(55 + 15) = 0,79$; Recall = $55/(55 + 5) = 0,92$; $F1 = 2 \cdot \frac{0,79 \cdot 0,92}{0,79 + 0,92} = 0,85$. Recall cao hơn Precision nghĩa là mô hình bắt được hầu hết ca informative nhưng đổi lại nhận nhầm một số ca không liên quan.

F1 là trung bình điều hòa của Precision và Recall. F_β tổng quát:

$$F_\beta = (1 + \beta^2) \frac{\text{Precision Recall}}{\beta^2 \text{Precision} + \text{Recall}}.$$

Dự án dùng F_2 , tức Recall có trọng số lớn hơn Precision vì bỏ sót thông tin khẩn cấp được xem là tốn kém hơn chuyển nhầm một bài cho bước kiểm tra. Tuy nhiên, khi informative chiếm

đa số, classifier luôn dự báo informative cũng có F2 cao. Vì vậy F2 phải đi cùng Accuracy, Balanced Accuracy, F1 và Matthews Correlation Coefficient (MCC). Balanced Accuracy lấy trung bình Recall của hai lớp; MCC bằng 0 với dự báo hằng và chỉ cao khi cả bốn ô confusion matrix hợp lý.

5.4.2 Tám lớp humanitarian

Accuracy bị chi phối bởi lớp lớn. Macro-F1 tính F1 riêng cho từng lớp rồi lấy trung bình không trọng số:

$$\text{MacroF1} = \frac{1}{K} \sum_{k=1}^K F1_k.$$

Do đó mỗi lớp hiếm có tiếng nói ngang lớp lớn. Weighted-F1 bổ sung góc nhìn theo tần suất thực tế. Tiêu chí chọn model là Macro-F1; báo cáo đồng thời Accuracy, Weighted-F1 và bảng từng lớp.

5.5 Thiết kế thực nghiệm

5.5.1 Vai trò của train, dev và test

Bảng 5.2: Ranh giới sử dụng dữ liệu trong thực nghiệm.

Split	Số hàng sạch	Mục đích
Train	13.608	Fit TF-IDF, classifier và calibration nội bộ.
Dev	2.189	Chọn họ model, siêu tham số, trọng số fusion và threshold.
Test	2.169	Đánh giá cuối sau khi mọi lựa chọn đã khóa.

“Model parameter” là trọng số học từ train, chẳng hạn $\mathbf{w}$ của Logistic Regression. “Hyperparameter” là cấu hình do người thiết kế chọn, chẳng hạn C , k , độ sâu cây hoặc số cây. Dùng test để chọn hyperparameter sẽ biến test thành dev và làm kết quả lạc quan. Dự án vì vậy dùng quy trình ba vòng:

1. so sánh sáu họ thuật toán trên dev với cấu hình chung;
2. chỉ tune họ thắng của mỗi bài toán trên dev;
3. khóa model, tune fusion trên dev và đánh giá đúng một lần trên test.

Đây không phải nested cross-validation đầy đủ; vì vậy vẫn có rủi ro thích nghi với một dev split. Để giảm rủi ro, lưới tuning nhỏ, được xác định trước và kết quả còn được hậu kiểm trên robust test không tune lại.

5.6 Vòng 1: so sánh sáu thuật toán

Bảng 5.3: Text informative trên dev, chọn theo F2.

Model	Acc.	Prec.	Recall	F1	F2
Logistic Regression	.7085	.7816	.7368	.7585	.7453
Decision Tree	.6044	.7546	.5382	.6283	.5710
Naive Bayes	.7177	.7265	.8750	.7939	.8406
k-NN	.4523	.7193	.1941	.3057	.2273
Linear SVM	.7204	.7234	.8904	.7983	.8511
Random Forest	.7195	.7457	.8324	.7867	.8135

Bảng 5.4: Text humanitarian trên dev, chọn theo Macro-F1.

Model	Acc.	Macro-P	Macro-R	Macro-F1	Weighted-F1
Logistic Regression	.4641	.3145	.4095	.3297	.4875
Decision Tree	.2810	.2118	.2346	.1302	.1747
Naive Bayes	.5263	.2677	.2429	.2446	.4982
k-NN	.4079	.3940	.1449	.1195	.2871
Linear SVM	.5112	.3019	.2697	.2787	.4856
Random Forest	.4947	.2921	.2571	.2626	.4734

Bảng 5.5: Image informative trên embedding CLIP, chọn theo F2.

Model	Acc.	Prec.	Recall	F1	F2
Logistic Regression	.7579	.8529	.7375	.7910	.7580
Decision Tree	.6807	.7487	.7316	.7401	.7350
Naive Bayes	.7177	.8681	.6434	.7390	.6785
k-NN	.7542	.7915	.8206	.8058	.8146
Linear SVM	.7593	.8078	.8037	.8058	.8045
Random Forest	.7478	.7949	.8007	.7978	.7996

Bảng 5.6: Image humanitarian trên embedding CLIP, chọn theo Macro-F1.

Model	Acc.	Macro-P	Macro-R	Macro-F1	Weighted-F1
Logistic Regression	.5354	.3603	.4768	.3637	.5653
Decision Tree	.4079	.2288	.2406	.2323	.4163
Naive Bayes	.5477	.3462	.4028	.3362	.5590
k-NN	.5943	.4101	.3530	.3563	.5851
Linear SVM	.6190	.4889	.3586	.3631	.5970
Random Forest	.5706	.5433	.2760	.2795	.5262

k-NN yếu rõ trên TF-IDF nhưng cạnh tranh trên CLIP embedding, phù hợp với phân tích về khoảng cách ở trên. Ở bài toán tám lớp, model có Accuracy cao nhất không nhất thiết có Macro-F1 cao nhất. Việc định nghĩa tiêu chí trước khi xem kết quả ngăn lựa chọn metric thuận lợi sau thực nghiệm.

5.7 Vòng 2: tuning classifier

Tuning là tìm hyperparameter trong một lưới hữu hạn, không phải cập nhật CLIP. Chỉ bốn họ thắng vòng 1 được tune để hạn chế số phép thử. Với task đa lớp, Macro-F1 chênh không quá 0,001 được coi là hòa; khi đó ưu tiên Weighted-F1 rồi Accuracy. Quy tắc này tránh chọn một cấu hình chỉ vì vài dự báo lớp cực hiếm làm Macro-F1 dao động.

Bảng 5.7: Không gian tuning và cấu hình được chọn trên dev.

Task	Họ model	Lưới	Kết quả
Text informative	Linear SVM	$C \in \{0,05; 0,1; 0,3; 1; 3\}$	$C = 3$, F2=.8548
Text humanitarian	Logistic Regression	$C \in \{0,05; 0,1; 0,3; 1; 3; 10\}$	$C = 1$, Macro-F1=.3297
Image informative	k-NN	$k \in \{5, 9, 15, 25, 41\}$, uniform/distance	$k = 41$, distance, F2=.8216
Image humanitarian	Logistic Regression	$C \in \{0,05; 0,1; 0,3; 1; 3; 10\}$	$C = 1$, Macro-F1=.3637

Các con số trong lưới không phải ngẫu nhiên; mỗi tham số có một ý nghĩa và một hệ quả khi tăng:

Bảng 5.8: Ý nghĩa các siêu tham số được dò.

Tham số	Ý nghĩa	Khi tăng giá trị
C (SVM, LR)	Mức phạt lỗi trên train (nghịch đảo regularization)	Bám train sát hơn, biên hẹp hơn, dễ overfit hơn.
k (k-NN)	Số láng giềng tham gia bỏ phiếu	Dự báo mượt hơn, ít nhiễu nhưng có thể bỏ chi tiết cục bộ.
distance weighting	Cho láng giềng gần trọng số lớn hơn	Láng giềng rất gần chi phối, giảm ảnh hưởng của điểm xa.

Bảng 5.9: Metric chọn model trên dev: trước và sau tuning.

Task	Model	Metric	Trước	Sau	Chênh
Text informative	Linear SVM (C : mặc định $\rightarrow 3$)	F2	.8511	.8548	+0.0037
Image informative	k-NN (k : 15 $\rightarrow$ 41, distance)	F2	.8146	.8216	+0.0070
Text humanitarian	Logistic Reg. ($C=1$, giữ)	Macro-F1	.3297	.3297	.0000
Image humanitarian	Logistic Reg. ($C=1$, giữ)	Macro-F1	.3637	.3637	.0000

Hai task informative nhích nhẹ; hai task tám lớp *không đổi* vì lưới tuning đã chạy nhưng không cấu hình nào vượt $C = 1$ đủ rõ (chênh Macro-F1 dưới ngưỡng hòa 0,001). Đây là kết quả hợp lệ và *bình thường*: tuning là kiểm định lựa chọn, không bảo đảm luôn tạo cải thiện, và việc hai task không nhúc nhích không phải là tuning “thất bại”.

5.8 Vòng 3: xác suất, Late Fusion và conflict

5.8.1 Căn chỉnh xác suất

Cơ sở lý thuyết của bước này là *trung bình có trọng số* (weighted average), trong thống kê gọi là *linear opinion pool*: khi có hai nguồn cùng ước lượng xác suất cho một biến cố, ta trộn chúng bằng trọng số không âm cộng lại bằng 1. Kết quả vẫn là một xác suất hợp lệ trong khoảng $[0, 1]$. Với informative:

$$p_{\text{fused}} = \alpha p_{\text{text}} + (1 - \alpha) p_{\text{image}}, \quad \hat{y} = \mathbb{I}[p_{\text{fused}} \geq \tau].$$

Ví dụ số. Giả sử nhánh văn bản tự tin $p_{\text{text}} = 0,80$ còn nhánh ảnh dè dặt $p_{\text{image}} = 0,40$, với $\alpha = 0,70$:

$$p_{\text{fused}} = 0,70 \times 0,80 + 0,30 \times 0,40 = 0,68.$$

So với ngưỡng $\tau = 0,38$, vì $0,68 \geq 0,38$ nên tweet được phân loại *informative*. Trọng số α lớn hơn cho text phản ánh việc nhánh văn bản mạnh hơn trên dev, nhưng ảnh vẫn kéo kết quả xuống một chút so với khi chỉ nghe text.

Với humanitarian, mỗi model tạo vector tám xác suất. Trước khi viết công thức tám lớp, xét một ví dụ *rút gọn ba lớp* cho dễ hình dung. Giả sử nhánh văn bản cho $\mathbf{q}_{\text{text}} = [0,60; 0,30; 0,10]$, nhánh ảnh cho $\mathbf{q}_{\text{image}} = [0,20; 0,50; 0,30]$, với $\beta = 0,55$:

$$\mathbf{q}_{\text{fused}} = 0,55 \mathbf{q}_{\text{text}} + 0,45 \mathbf{q}_{\text{image}} = [0,42; 0,39; 0,19].$$

Tổng vẫn bằng 1; lớp được chọn là lớp có xác suất lớn nhất (ở đây lớp 1, 0,42). Mở rộng nguyên xi cho tám lớp: pipeline căn cột theo cùng thứ tự lớp, điền 0 nếu một model thiếu lớp, rồi tính:

$$\mathbf{q}_{\text{fused}} = \beta \mathbf{q}_{\text{text}} + (1 - \beta) \mathbf{q}_{\text{image}}.$$

Trên dev, grid search chọn $\alpha = 0,70$, $\tau = 0,38$ cho *informative* và $\beta = 0,55$ cho *humanitarian*. Text nhận trọng số lớn hơn nhưng ảnh vẫn đóng góp 30–45%. Fusion là late fusion, không phải nối raw feature; ưu điểm là hai nhánh có thể dùng classifier khác nhau và dễ quan sát đóng góp từng nhánh. Nhược điểm là trung bình tuyến tính không học tương tác phức tạp.

5.8.2 Conflict score và Manual Review

Mức bất đồng *informative* là $|p_{\text{text}} - p_{\text{image}}|$. Với category, dự án dùng total variation distance:

$$C_{\text{cat}} = \frac{1}{2} \sum_{k=1}^8 |q_{\text{text},k} - q_{\text{image},k}|.$$

Conflict score là giá trị lớn hơn giữa hai đại lượng. Ngưỡng 0,54 được chọn trên dev để tối đa F1 phát hiện cờ bất đồng trong khi tỷ lệ review không vượt 25%. Đây là tối ưu có ràng buộc công suất: ngưỡng quá thấp tăng Recall nhưng làm hàng review quá tải; ngưỡng quá cao bỏ qua nhiều xung đột.

5.9 Kết quả cuối trên canonical test

5.9.1 Informative và đối chứng hằng

Bảng 5.10: Informative trên 2.169 hàng test sạch.

Hệ thống	Thr.	Acc.	Bal. Acc.	Prec.	Recall	F1	F2	MCC
Always informative	–	.6275	.5000	.6275	1.0000	.7711	.8939	.0000
Text-only	.38	.6823	.5792	.6675	.9838	.7954	.8987	.2904
Image-only	.20	.6773	.5759	.6662	.9735	.7910	.8913	.2660
Late Fusion	.38	.6948	.5944	.6755	.9882	.8025	.9045	.3325

Always-informative đạt F2 .8939 vì Recall bằng 1. Fusion chỉ tăng F2 thêm .0106, nhưng đồng thời tăng Accuracy .0673, F1 .0314, Balanced Accuracy và MCC. Do đó giá trị của fusion không được trình bày chỉ bằng F2. Image-only có Average Precision .8999, cao hơn text .7968, nhưng threshold ưu tiên Recall làm Accuracy hai nhánh gần nhau; điều này cho thấy chất lượng xếp hạng và quyết định tại một ngưỡng là hai khái niệm khác nhau.

5.9.2 Humanitarian tám lớp

Bảng 5.11: Humanitarian trên 2.169 hàng test sạch.

Hệ thống	Accuracy	Macro-F1	Weighted-F1
Majority baseline	.3785	.0686	.2079
Text-only	.4481	.3260	.4693
Image-only	.5440	.3646	.5695
Late Fusion	.5569	.4005	.5776

Ảnh mạnh hơn text ở task tám lớp, và fusion tiếp tục tăng Macro-F1 .0359 so với image-only. Điều này là bằng chứng thực nghiệm để giữ nhánh ảnh, nhưng không có nghĩa ảnh luôn đáng tin hơn text ở mọi lớp hoặc mọi sự kiện.

Bảng 5.12: Late Fusion humanitarian theo lớp trên canonical test.

Lớp	Precision	Recall	F1	Support
injured/dead	.2202	.6316	.3265	38
missing/found	.0435	.2000	.0714	5
rescue/donation	.5262	.5468	.5363	331
infrastructure	.4925	.5305	.5108	311
affected	.2124	.5000	.2982	82
vehicle damage	.1385	.5000	.2169	18
other relevant	.6588	.4938	.5645	563
not humanitarian	.7507	.6200	.6791	821

F1 của missing/found chỉ .0714 với 5 mẫu; vehicle damage chỉ .2169 với 18 mẫu. Các lớp này chưa đủ bằng chứng để tự động điều động nguồn lực. Recall tương đối cao ở vài lớp hiếm đi cùng Precision rất thấp, nghĩa là hệ thống bắt được thêm ca thật bằng cách tạo nhiều cảnh báo nhầm.

5.10 Hậu kiểm robustness và độ bất định

Robustness mask loại thêm 137 hàng test gần trùng đã duyệt, còn 2.032 hàng. Model, fusion và threshold được giữ nguyên, không tune lại.

Bảng 5.13: Độ nhạy khi chuyển từ canonical sang robust test.

Metric	Canonical	Robust	Chênh lệch
Informative Accuracy	.6948	.6900	-.0048
Informative F1	.8025	.7978	-.0047
Informative F2	.9045	.9016	-.0029
Informative MCC	.3325	.3340	+.0015
Humanitarian Macro-F1	.4005	.3908	-.0097
Humanitarian Weighted-F1	.5776	.5789	+.0013
Manual Review F1	.4585	.4558	-.0027

Kết luận tổng thể không phụ thuộc mạnh vào các near-duplicate đã xác nhận. Macro-F1 nhạy hơn vì robust test chỉ còn 28 injured/dead, 4 missing/found và 15 vehicle damage.

Bootstrap phân tầng 2.000 lần trên robust test cho:

Bảng 5.14: Khoảng tin cậy percentile 95%, cấu hình đã khóa.

Đại lượng	Ước lượng	CI thấp	CI cao
Informative F2	.9016	.8960	.9070
F2 gain so với always-informative	.0110	.0054	.0163
Humanitarian Macro-F1	.3908	.3636	.4208
Macro-F1 gain so với majority	.3208	.2936	.3508
Manual Review F1	.4558	.4251	.4868

CI của gain không chứa 0 dưới giả định lấy mẫu độc lập theo hàng. Tuy nhiên, row-bootstrap không mô phỏng một thảm họa hoàn toàn mới và nhiều tweet trong cùng event có thể tương quan. Informative F2 theo event nằm trong .8205–.9243; humanitarian Macro-F1 trên các lớp hiện diện nằm trong .3458–.4615. Đây là bằng chứng về domain shift còn lại.

5.11 Từ dự báo đến chính sách DSS

5.11.1 Risk Score

Classifier tạo xác suất và category, nhưng dữ liệu không có nhãn Priority. Vì vậy Risk Score được xây như một *weighted scoring model* – một công cụ kinh điển của DSS: liệt kê vài tiêu chí, cho mỗi tiêu chí một trọng số do tổ chức chọn, rồi cộng lại thành một điểm tổng để xếp hạng. Nó là một chính sách minh bạch, **không** phải một model đã được chứng minh tối ưu. Công thức không “rơi từ trên trời”: mỗi số hạng tương ứng một câu hỏi nghiệp vụ:

$$\begin{aligned} \text{Risk} = & 0,40S_{\text{informative}} + 0,25S_{\text{severity}} \\ & + 0,20S_{\text{keyword}} + 0,15(S_{\text{severity}} \times C_{\text{category}}). \end{aligned}$$

$S_{\text{informative}}$ là xác suất fusion theo thang 0–100; S_{severity} đến từ bảng trọng số category công khai; S_{keyword} phản ánh từ khóa khẩn cấp; và C_{category} là độ tin cậy category. Nhân confidence với severity tránh trường hợp rất chắc chắn rằng bài đăng là not-humanitarian lại làm tăng risk. Các ngưỡng 0–39, 40–69 và 70–100 tạo Low, Medium, High.

Ví dụ tính tay. Một tweet “bridge collapsed, people trapped” kèm ảnh hạ tầng hư hỏng. Giả sử $S_{\text{informative}} = 88$, $S_{\text{severity}} = 80$ (nhóm hạ tầng), $S_{\text{keyword}} = 70$ (có từ “trapped”), $C_{\text{category}} = 0,9$. Khi đó:

$$\text{Risk} = 0,40(88) + 0,25(80) + 0,20(70) + 0,15(80 \times 0,9) = 35,2 + 20 + 14 + 10,8 = 80,0,$$

roi vào dải 70–100 nên Priority = High. Lưu ý đây là điểm ưu tiên *đọc trước*, không phải lệnh điều động.

Ba phản ví dụ. Công thức trọng số có những điểm mù cần con người:

1. **Từ khóa trong câu phủ định:** “thank god, nobody *dead*” vẫn kích hoạt S_{keyword} dù ý nghĩa ngược lại; TF-IDF không hiểu phủ định.
2. **Not-humanitarian nhưng conflict cao:** ảnh và text mâu thuẫn mạnh khiến độ tin cậy thấp; điểm severity nhỏ nhưng ca này vẫn nên được review thay vì bỏ qua.
3. **Lớp hiếm xác suất cao nhưng ít bằng chứng:** một dự báo missing/found rất tự tin chỉ dựa trên vài mẫu train; Risk cao không đồng nghĩa đáng tin, nên luôn chuyển con người.

Đây chính là lý do Risk Score luôn đi kèm cờ Manual Review, và vì sao trọng số được công khai để có thể tranh luận và hiệu chỉnh.

5.11.2 Routing, override và sensitivity

Tám category đều có một đội nhận mặc định. Khi conflict vượt 0,54, Supervisor được thêm song song. Một case High không bị hạ mức hoặc chặn phản ứng chỉ vì cần review; ví dụ critical conflict được chuyển Supervisor+EmergencyTeam.

Bảng 5.15: Độ nhạy của Priority theo ngưỡng trên 2.169 hàng test sạch.

Policy	Low max	Medium max	Low	Medium	High
Sensitive	29	59	651	1.186	332
Current	39	69	769	1.351	49
Strict	49	79	1.212	955	2

Sau override conflict, cấu hình hiện tại có 624 Low, 1.496 Medium và 49 High; 539 case được Manual Review, tương đương 24,85%. Chênh lệch lớn giữa ba policy cho thấy Priority phụ thuộc mạnh vào lựa chọn tổ chức. Muốn xác nhận trọng số và ngưỡng cần dữ liệu nghiệp vụ như mức ưu tiên do chuyên gia gán, thời gian phản ứng và chi phí của false negative/false positive.

Phạm vi kết luận

Các classifier, fusion và conflict detector đã được đánh giá trên nhãn có sẵn. Risk Score, Priority và Routing là nguyên mẫu chính sách có công thức, scenario test và sensitivity analysis, nhưng chưa có ground truth để khẳng định tối ưu. Hệ thống phù hợp hỗ trợ sàng lọc và điều phối sơ bộ; chưa phù hợp tự động ra quyết định sinh tử.

6 Diễn giải kết quả và khuyến nghị

6.1 Kết quả end-to-end

Hệ thống hoàn chỉnh chuyển một cặp tweet–ảnh qua chuỗi:

dữ liệu → đặc trưng → xác suất → fusion → chính sách DSS → hàng đợi.


Integration test sử dụng một bài đăng Hurricane Harvey về hoạt động cứu trợ. Hệ thống dự báo đúng nhóm rescue/donation, tạo Risk Score 54,3, Priority Medium và định tuyến Relief Team. Kiểm thử này chứng minh các module có thể phối hợp trên một ảnh thật; nó không thay thế đánh giá thống kê trên toàn test.

Dashboard vận hành trên 2.237 dòng test để người dùng có đủ batch quan sát: 50 case High và 571 case Manual Review. Các metric khoa học chỉ tính trên 2.169 dòng canonical test; trong tập này có 49 High và 539 Manual Review. Việc tách hai con số tránh nhằm dashboard workload với tập đánh giá đã lọc duplicate.

6.2 Ý nghĩa của kết quả mô hình

6.2.1 Sàng lọc informative

Fusion đạt F2 .9045, nhưng baseline luôn dự báo informative đã đạt .8939. Mức tăng .0106 là nhỏ về độ lớn thực tiễn dù CI bootstrap của gain không chứa 0. Giá trị bổ sung rõ hơn ở Accuracy (.6948 so với .6275), F1 (.8025 so với .7711), Balanced Accuracy (.5944 so với .5000) và MCC (.3325 so với 0).



Hình 6.1: Mức tăng của Late Fusion so với baseline always-informative theo từng metric (canonical test). F2 gần như không nhúc nhích, nhưng các metric cân bằng (Balanced Accuracy, MCC) tăng rõ – đây mới là giá trị thật của fusion.

Hình 6.1 cho thấy ngay vì sao không được khoe F2 đơn độc: cột F2 thấp nhất, còn MCC tăng từ 0 lên .3325 mới là bằng chứng mô hình phân biệt hai lớp hơn hẳn dự báo hằng.

Điều này có nghĩa hệ thống phân biệt hai lớp tốt hơn dự báo hăng, nhưng ưu tiên Recall khiến nhiều not-informative vẫn bị chuyển tiếp. Trong bối cảnh cứu trợ, đó có thể là đánh đổi chấp nhận được ở tầng sàng lọc đầu tiên, miễn là tầng sau có hàng đợi và con người kiểm tra. Không nên mô tả informative model là bộ lọc chính xác cao hoặc dùng nó để tự động loại bỏ mọi bài có xác suất thấp.

6.2.2 Phân loại nhu cầu humanitarian

Humanitarian fusion đạt Macro-F1 .4005, cao hơn image-only .3646, text-only .3260 và majority baseline .0686. Mức tăng so với baseline rõ hơn task informative vì model thực sự phân biệt nhiều lớp thay vì chỉ tận dụng tỷ lệ lớp dương.

Tuy nhiên, kết quả không đồng đều. F1 là .6791 ở not-humanitarian, .5645 ở other-relevant và .5363 ở rescue/donation, nhưng chỉ .0714 ở missing/found. Do đó hệ thống có giá trị cho tổ chức hàng đợi tổng thể, chưa đủ tin cậy để một nhân lớp hiếm tự kích hoạt điều động sinh tử.



Hình 6.2: Tiến triển Macro-F1 humanitarian qua các mốc đối chứng trên canonical test: mỗi bước thêm thông tin đều nhích lên, fusion cao nhất.

Hình 6.2 cho thấy điều mà một bảng số khó truyền tải ngay: khoảng cách lớn nhất là từ majority lên các mô hình thật, và fusion vượt cả hai nhánh đơn lẻ. Người đọc không cần tự trừ các con số trong bảng.

6.2.3 Giá trị của nhánh ảnh

Image-only tốt hơn text-only ở humanitarian Macro-F1 (.3646 so với .3260), và fusion tốt hơn cả hai. Đây là bằng chứng ảnh cung cấp thông tin bổ sung. EDA lại cho thấy nhãn text–image bất đồng cao ở lớp khẩn cấp. Hai kết quả không mâu thuẫn: ảnh có thể hữu ích trên trung bình nhưng vẫn không khớp văn bản ở nhiều case cụ thể.

Kết luận vận hành là giữ ảnh như một nguồn bằng chứng độc lập, không gán cho nó vai trò “xác nhận chân lý”. Khi hai nhánh bất đồng mạnh, hệ thống tăng nhu cầu xác minh thay vì tự chọn một nhánh.

6.3 Ý nghĩa của Manual Review

Với giới hạn công suất dev 25%, ngưỡng conflict 0,54 tạo review rate 24,85% trên canonical test. Diễn giải bằng *số ca* dễ hình dung hơn tỷ lệ: trên 2.169 dòng test, hệ thống đẩy khoảng 539 ca vào hàng review. Precision .7532 nghĩa là trong 539 ca đó có khoảng 406 ca thực sự bất đồng theo annotation và khoảng 133 ca là báo nhầm. Recall .3295 nghĩa là hệ thống chỉ thu hồi khoảng một phần ba *toàn bộ* ca bất đồng – phần còn lại lọt qua. Đây là một đánh đổi công suất: muốn bắt nhiều hơn phải hạ ngưỡng và chấp nhận hàng review dài hơn.

Đây là cơ chế *triage*, không phải detector toàn diện. Nếu trung tâm có thêm người, có thể hạ threshold để tăng Recall. Nếu hàng đợi quá tải, cần tăng threshold hoặc ưu tiên conflict đi cùng category nghiêm trọng. Thay đổi threshold phải được giám sát bằng cả review rate và chất lượng review, không chỉ một metric.

6.4 Một số ca minh họa end-to-end

Để thấy hệ thống “chạy” chứ không chỉ là bảng số, Bảng 6.1 theo dõi ba kịch bản minh họa đi hết luồng: xác suất hai nhánh → fusion → conflict → Risk/Priority → đề xuất → bước con người phải làm. Các số mang tính minh họa cho cơ chế, phù hợp với các tình huống đã nêu ở Mục 1.7.

Bảng 6.1: Ba ca minh họa đi hết luồng quyết định.

Ca	p_{text}	p_{img}	Conflict	Luồng và bước con người
A. “Bridge collapsed, people trapped” + ảnh hạ tầng hỏng	0,92	0,88	thấp	Fusion cao, đồng thuận → Risk High, route Emergency Team. Người xác minh <i>vị trí</i> qua hotline trước khi điều lực lượng.
B. “Urgent help needed!” + ảnh selfie không liên quan	0,85	0,30	cao	Bất đồng mạnh → giữ ưu tiên nhưng bật Manual Review. Người xem ảnh và văn bản, đối chiếu nguồn thứ hai.
C. Dự báo missing/found rất tự tin nhưng lớp chỉ có ít mẫu train	–	–	–	Xác suất cao <i>không</i> đồng nghĩa đáng tin → bắt buộc xác minh trước mọi hành động (xem lớp hiếm ở Chương 5).

Điểm chung của ba ca: hệ thống chỉ *đề xuất thứ tự và đội phụ trách*; mọi hành động có hậu quả đều có một bước con người chen vào trước.

Hình 6.3 lấy *ba ca thật* từ test (ảnh và số liệu do hệ thống sinh ra, không dàn dựng) minh họa đúng ba tình huống trên:



Hình 6.3: Ba ca thật từ test. A: tin đồng thuận, Risk 87,5 → High, không cần review. B: xung đột cao (conflict 0,92) nên bật Manual Review dù vẫn ưu tiên. C: tweet “no missing child” – một câu *phủ định* thật, lớp missing/found hiếm, hệ thống chuyển review thay vì tin tuyệt đối. Ca C cho thấy đúng điểm yếu phủ định của TF-IDF đã nêu ở Chương 5.

6.5 Khuyến nghị vận hành

- Dùng hệ thống để sàng lọc, không tự động điều động.** Priority và Routing là đề xuất ban đầu; người điều phối xác minh nguồn, vị trí và tình trạng hiện trường trước khi phân bổ nguồn lực.
- Xử lý High trước nhưng vẫn phân tầng trong High.** Case injured/missing, có từ khóa khẩn cấp và địa điểm rõ nên được xem trước case thiệt hại tài sản.
- Review song song, không chặn phản ứng khẩn cấp.** Khi case High có conflict, Supervisor và đội phản ứng gốc cùng nhận; không chờ xác minh xong mới gửi tín hiệu cho Emergency Team.
- Quản lý công suất Manual Review.** Theo dõi số case theo ca trực. Capacity thấp hơn 25% cần tăng ngưỡng; capacity cao hơn có thể hạ ngưỡng sau khi kiểm tra Precision/Recall.
- Không tự động hóa lớp support rất thấp.** Missing/found và vehicle damage cần xác minh bắt buộc cho tới khi có thêm dữ liệu và đánh giá ngoài mẫu.
- Theo dõi drift theo sự kiện.** Dùng event filter, so sánh phân bố và metric. Không áp dụng nguyên threshold từ dữ liệu năm 2017 cho một thảm họa mới mà không hiệu chỉnh.

7. **Phê duyệt Risk policy bằng dữ liệu nghiệp vụ.** Cần chuyên gia gán Priority, chi phí bỏ sót, thời gian xử lý và kết quả thực tế để kiểm định trọng số Risk Score.

6.6 Trả lời tám câu hỏi của bài tập

1. Bài toán thực tế mà nhóm giải quyết là gì?

Trong thảm họa, lượng bài đăng mạng xã hội vượt khả năng đọc thủ công, nội dung nhiều và hai nguồn text-image có thể không đồng nhất. Bài toán là chuyển dòng dữ liệu này thành một hàng đợi có cấu trúc để giảm thời gian sàng lọc và hỗ trợ điều phối.

2. Ai là người sử dụng hệ thống?

Người dùng chính là ban điều phối và các Emergency, Relief, Infrastructure, Coordination Team. Supervisor xử lý case mâu thuẫn. Người dân không trực tiếp nhận quyết định từ model.

3. Hệ thống hỗ trợ những quyết định nào?

Năm quyết định gồm: bài có đáng chú ý hay không; thuộc nhóm nhu cầu nào; Priority Low/Medium/High; đội nào tiếp nhận; và có cần Manual Review hay không. Hệ thống đề xuất, con người chịu trách nhiệm quyết định cuối.

4. Dữ liệu nào được sử dụng?

18.082 cặp tweet-ảnh CrisisMMD v2.0 từ bảy thảm họa năm 2017, gồm nhãn informative, tám lớp humanitarian, nhãn riêng text/image và cờ đồng thuận. Nhãn informative chính thức được join theo cặp ID; duplicate chính xác và gần trùng được kiểm tra trước đánh giá.

5. Dữ liệu được xử lý và phân tích như thế nào?

Văn bản được làm sạch và biểu diễn bằng TF-IDF 2.000 chiều. Ảnh được chuyển thành CLIP embedding 512 chiều với trọng số CLIP giữ nguyên. EDA dùng thống kê, K-Means, Apriori, t-SNE và conflict analysis. Sáu classifier được so sánh; họ thắng được tune trên dev rồi Late Fusion kết hợp xác suất.

6. Kết quả quan trọng nhất là gì?

Informative fusion đạt Accuracy .6948, F1 .8025, F2 .9045; F2 chỉ hơn always-informative .0106. Humanitarian fusion đạt Macro-F1 .4005 so với majority .0686. Trên robust test không tune lại, F2 còn .9016 và Macro-F1 .3908. Lớp hiếm vẫn là điểm yếu lớn nhất.

7. Hành động nào được đề xuất từ kết quả?

Dùng Priority Queue, routing theo category, review song song khi conflict, bắt buộc xác minh lớp hiếm và hiệu chỉnh ngưỡng theo công suất. Giám sát kết quả theo event để phát hiện domain shift.

8. Hạn chế và rủi ro là gì?

Dữ liệu chỉ từ năm 2017, thiếu GPS và xác minh hiện trường, lớp hiểm rất nhỏ, còn tương quan trong cùng event, có duplicate, CLIP không được thích nghi riêng cho miền, và Priority không có ground truth. Prototype chưa được kiểm thử tải production hoặc tác động thực địa.

6.7 Điều đã chứng minh và chưa chứng minh

Bảng 6.2: Biên giới của kết luận.

Đã có bằng chứng	Chưa có bằng chứng
Fusion hơn dummy về nhiều metric và hơn từng nhánh ở humanitarian	F2 gain khoảng .01 tạo lợi ích vận hành lớn
Classifier đã được so sánh và tune chỉ trên dev	Một cấu hình sẽ tổng quát hóa sang thảm họa chưa thấy
Conflict rule có Precision .7532 dưới capacity 25%	Manual Review thu hồi được mọi xung đột quan trọng
Routing phủ đủ tám category và qua scenario test	Priority threshold và severity weight là tối ưu thực tế
Robustness/CI không đảo ngược kết luận tổng thể	Lớp missing đủ tin cậy để tự động điều động
Dashboard chạy với model và cache đã khóa	Hệ thống đáp ứng bảo mật, tải và độ trễ production

Giá trị chính của dự án nằm ở sự kết hợp giữa dự báo và quản trị quyết định: model giảm khối lượng thông tin, còn chính sách minh bạch, capacity constraint, scenario test và human-in-the-loop giới hạn cách kết quả được sử dụng.

7

Sản phẩm: Dashboard hỗ trợ điều phối

7.1 Vai trò của giao diện trong DSS

Một DSS chỉ có model nhưng không có giao diện quyết định sẽ khó được sử dụng. Dashboard là lớp tương tác giữa dữ liệu, mô hình và người điều phối. Nó không chỉ hiển thị Accuracy; nó phải cho phép người dùng:

- quan sát workload và phân bố Priority;
- truy vết từ khuyến nghị về xác suất, category và conflict;
- lọc theo event, đội nhận và nhu cầu review;
- thử một trường hợp mới;
- xuất hàng đợi để tiếp tục xử lý.


Streamlit là frontend của prototype. Đây là framework Python tạo giao diện web từ widget, biểu đồ và state; trình duyệt là phía hiển thị, còn mã Python chạy ở server. Vì vậy dự án không cần thêm React hoặc một frontend riêng để đáp ứng luồng sử dụng học thuật. Frontend tách rời chỉ cần khi có API độc lập, phân quyền phức tạp, nhiều người dùng đồng thời hoặc yêu cầu giao diện cao hơn.

7.2 Năm trang chức năng

Overview	Hiển thị số case, Priority, Manual Review, routing team, category và phân bố Risk Score. Bộ lọc event giúp quan sát thay đổi workload giữa các thảm họa.
EDA	Trình bày thống kê train-only, phân bố nhãn, K-Means, Apriori, kiểm kê ảnh và bất đồng đa phương thức. Trang này giải thích căn cứ thiết kế, không dùng test để khám phá.
Model Evaluation	Hiển thị so sánh sáu model trên dev, tuning, baseline, fusion, robust test và metric từng lớp. Người đọc có thể thấy cả điểm mạnh lẫn lớp yếu.
Single-Case Demo	Nhận tweet và ảnh upload. Chế độ text-only cho kết quả nhanh; chế độ text+image chạy CLIP rồi toàn bộ fusion-DSS. Kết quả gồm xác suất, category, conflict, Risk, Priority, team và action.

Priority Queue

Cho phép lọc theo Priority, team, event và Manual Review; xem chi tiết từng hàng và tải CSV để bàn giao.

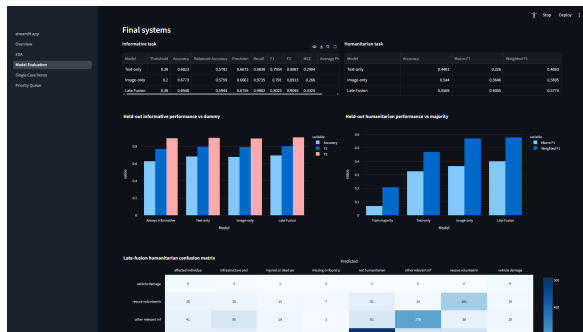


(a) Overview và workload.

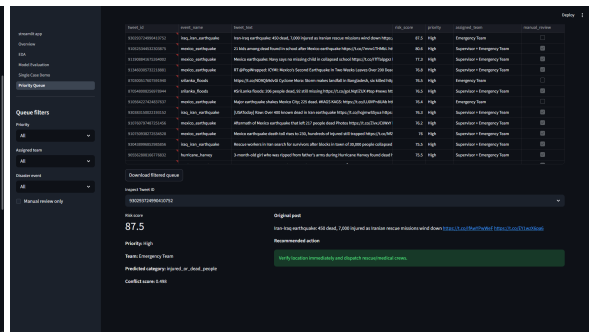


(b) EDA train-only.

Hình 7.1: Tổng quan vận hành và căn cứ dữ liệu.



(a) Đánh giá mô hình.



(b) Priority Queue.

Hình 7.2: Từ bằng chứng mô hình tới hàng đợi quyết định.

7.3 Kiến trúc dữ liệu của dashboard

Dashboard không huấn luyện lại model khi người dùng mở trang. Batch test đã được xử lý thành `dashboard_test_predictions.csv`, gồm xác suất fusion, category, Risk Score, Priority, routing và cờ review. Cách cache này:

- giảm thời gian tải trang;
- bảo đảm biểu đồ dùng đúng model đã khóa;
- tách đánh giá hàng loạt khỏi suy luận một trường hợp.

Single-Case Demo tải vectorizer và bốn classifier. Model ảnh được lazy-load: chỉ khi người dùng upload ảnh thì PyTorch/Transformers và CLIP mới được nạp. Nhờ vậy chế độ text-only khởi động nhanh và cloud không phải tải CLIP ở mọi trang.

7.3.1 Vì sao lưu CSV thay vì cơ sở dữ liệu?

Một câu hỏi hợp lý là vì sao dùng file CSV chứ không phải một cơ sở dữ liệu (database). Với một *prototype học thuật chạy offline*, CSV là lựa chọn phù hợp: dữ liệu nhỏ, bất biến (chỉ đọc sau khi tính), dễ mở bằng bất kỳ công cụ nào, dễ đưa vào Git để version và tái lập, và không cần dựng server. Cả pipeline là *read-mostly*: tính một lần, sau đó dashboard chỉ đọc.

CSV *không* phù hợp khi lên production thật, vì nó thiếu: ghi đồng thời (concurrent write) an toàn, giao dịch (transaction), chỉ mục (index) để truy vấn nhanh, phân quyền truy cập và audit log. Khi đó cần chuyển sang PostgreSQL hoặc object storage cho dữ liệu lớn, kèm một hàng đợi (queue) cho luồng nạp thời gian thực. Việc giữ CSV ở phiên bản này là quyết định có chủ đích theo phạm vi, không phải thiếu sót kỹ thuật.

7.4 Công nghệ và lý do lựa chọn

Bảng 7.1: Vai trò của các công nghệ chính.

Công nghệ	Định nghĩa/vai trò	Lý do sử dụng
Python	Ngôn ngữ thực thi pipeline	Hệ sinh thái dữ liệu/ML thống nhất, dễ tái lập.
pandas/NumPy	Bảng dữ liệu và đại số mảng	Join annotation, audit, cache và tính metric.
scikit-learn	Thư viện ML cổ điển	Cung cấp TF-IDF, sáu classifier, metric và API nhất quán.
PyTorch + Transformers	Runtime mô hình tiên huấn luyện	Nạp CLIP và chạy forward pass ảnh.
Streamlit	Framework web bằng Python	Tạo frontend trực tiếp trên cùng logic dự án.
Plotly/Matplotlib	Thư viện trực quan	Biểu đồ tương tác trên app và hình tĩnh cho báo cáo.
Jupyter	Notebook thực thi	Lưu code, output và hình EDA/model trong một tài liệu.
XeLaTeX	Hệ dàn trang báo cáo	Hỗ trợ tiếng Việt, công thức, bảng và PDF nhất quán.

Việc dùng một stack Python giảm nguy cơ giao diện tính lại metric khác backend. Đánh đổi là Streamlit không tối ưu cho ứng dụng giao dịch thời gian thực hoặc UI tùy biến sâu.

7.5 Chạy local và triển khai Streamlit Community Cloud

7.5.1 Chạy local đầy đủ

```
pip install -r requirements.txt
streamlit run app/streamlit_app.py
```

Nếu cần tái tạo toàn bộ dữ liệu, embedding và mô hình:

```
python -m scripts.run_all
```

Lệnh tái tạo đầy đủ cần corpus ảnh CrisisMMD khoảng 1,8 GB và thời gian chạy CLIP. Khi model/cache đã có, không cần chạy lại pipeline trước khi mở dashboard.

7.5.2 Bundle cloud

Repository cloud chứa:

- processed train/test cần cho EDA và dashboard;
- vectorizer và bốn classifier đã khóa;
- cấu hình fusion và các bảng metric;
- mã Streamlit cùng requirements CPU.

Raw image corpus và ma trận embedding lớn không được đưa lên Git. Trang EDA đọc processed CSV. Single-Case Demo nhận ảnh upload; lần suy luận ảnh đầu tiên tải CLIP nên có cold start, còn text-only dùng ngay các model nhỏ.

Cấu hình deploy:

Repository	dafiiscoding/ml-dss
Branch	main
Main file	app/streamlit_app.py
Python	3.12
Secrets	Không yêu cầu

Các bước trên được mô tả chi tiết trong docs/DEPLOY_STREAMLIT.md.

7.6 Kiểm thử giao diện và giới hạn triển khai

Sáu endpoint Streamlit gồm trang chính và năm trang chức năng được chạy bằng AppTest trong môi trường cloud Python 3.12. GitHub Actions kiểm tra bundle, dependency và text-only inference sau mỗi lần push. Unit test kiểm tra logic dữ liệu, duplicate mask, tuning, robustness và DSS; integration test chạy một ảnh thật qua CLIP.

Những kiểm thử này chứng minh app khởi động và luồng chính không phát sinh exception. Chúng chưa chứng minh khả năng chịu tải nhiều người dùng, bảo mật upload, phân quyền, lưu audit log hoặc SLA. Nếu triển khai thực tế cần thêm API, authentication, giới hạn file, quét nội dung, logging, giám sát latency và chính sách bảo vệ dữ liệu.

Phạm vi sản phẩm

Dashboard là một prototype DSS có frontend hoàn chỉnh cho học tập và trình diễn: người dùng có thể xem bằng chứng, thử ca mới và thao tác hàng đợi. Nó chưa phải hệ thống chỉ huy production và không được dùng để tự động điều động nguồn lực.

8 Kết luận và hướng phát triển

8.1 Kết luận

Dự án xây dựng một hệ hỗ trợ quyết định đa phương thức trên 18.082 cặp tweet–ảnh Crisis-MMD. Quy trình gồm hợp nhất nhãn chính thức, kiểm soát duplicate, EDA train-only, TF-IDF, CLIP frozen embedding, so sánh sáu classifier, tuning trên dev, Late Fusion, Risk Score, Routing, Manual Review và dashboard.

Với informative, Late Fusion đạt Accuracy .6948, F1 .8025 và F2 .9045 trên canonical test. F2 chỉ hơn always-informative .0106, nên kết luận được đặt trên nhiều metric thay vì một chỉ số. Với humanitarian, fusion đạt Macro-F1 .4005, cao hơn majority baseline .0686 và từng nhánh đơn lẻ. Robust test giữ F2 .9016 và Macro-F1 .3908 mà không tune lại; bootstrap cho thấy kết luận tổng thể ổn định, nhưng lớp hiếm và biến động theo event còn lớn.

Đóng góp quan trọng nhất không phải một Accuracy cao, mà là cách chuyển kết quả mô hình thành một quyết định có giới hạn: công thức Risk công khai, routing đủ tám lớp, review theo conflict dưới capacity, và con người giữ quyền xác minh. Ranh giới giữa dự báo đã được đánh giá và Priority chưa có ground truth được trình bày rõ.

8.2 Hạn chế

- Dữ liệu chỉ phản ánh bảy thảm họa năm 2017 và chưa đại diện mạng xã hội hiện tại hoặc ngôn ngữ ngoài tiếng Anh.
- Split chứa nhiều event ở cả train và test; chưa đo tổng quát hóa tới một event hoàn toàn chưa thấy.
- Ba lớp khẩn cấp có support rất thấp; metric riêng lớp có CI rộng.
- CLIP được giữ cố định, không thích nghi riêng cho ảnh thảm họa.
- Dữ liệu thiếu vị trí đáng tin, độ xác thực nguồn và kết quả xử lý thực địa.
- Risk Score/Priority là policy giả định, không phải optimum học được.
- Cloud prototype chưa có authentication, audit log và kiểm thử tải.

8.3 Hướng phát triển

1. **Đánh giá theo event chưa thấy:** dùng leave-one-event-out hoặc group split để đo domain shift nghiêm ngặt hơn.
2. **Bổ sung dữ liệu lớp hiếm:** thu thập và thẩm định thêm case injured, missing và vehicle; cân nhắc active learning với chuyên gia.
3. **Trích xuất vị trí:** dùng Named Entity Recognition, geocoding và xác minh địa danh để biến tweet thành thông tin có thể điều phối.
4. **Hiệu chỉnh xác suất:** đánh giá reliability diagram, Brier score và calibration error trước khi dùng xác suất cho policy.
5. **Học policy từ nghiệp vụ:** thu Priority do chuyên gia gán, thời gian phản ứng và chi phí sai số để tối ưu Risk/threshold.
6. **Fusion thích nghi:** thử trọng số theo category hoặc gating model, nhưng phải giữ test độc lập và so với late-fusion tuyến tính.
7. **Giám sát production:** thêm authentication, audit log, drift monitor, latency/error telemetry và quy trình human override.

Hướng phát triển ưu tiên dữ liệu và kiểm định chính sách trước khi tăng độ phức tạp mô hình. Một DSS đáng tin không chỉ cần dự báo tốt hơn mà còn phải chứng minh được khi nào nên sử dụng, khi nào cần dừng và ai chịu trách nhiệm quyết định.

A Phụ lục

A.1 Khai báo sử dụng công cụ AI

Theo yêu cầu công khai công cụ hỗ trợ, nhóm có sử dụng Claude và OpenAI Codex để gợi ý cấu trúc, hỗ trợ rà soát mã nguồn, kiểm thử và biên tập diễn đạt. Nhóm chịu trách nhiệm lựa chọn phương pháp, chạy chương trình, kiểm tra kết quả với dữ liệu CrisisMMD, đối chiếu metric và xác nhận nội dung báo cáo. Nội dung do công cụ sinh ra không được xem là bằng chứng nếu không có kết quả thực thi hoặc nguồn tham khảo tương ứng.

A.2 Bảng tự đánh giá

Bảng A.1: Tự đánh giá theo các nhóm tiêu chí của bài tập.

Tiêu chí	Tối đa	Tự đánh giá	Căn cứ
Hiểu bài toán và quyết định	15	14	Chương 1–2, stakeholder và năm quyết định
Dữ liệu và tiền xử lý	15	15	Nhấn chính thức, feature engineering, leakage audit
EDA và insight	20	19	Train-only, event, K sweep, Apriori, ảnh, conflict
Mô hình và DSS	20	18	Sáu model, tuning, fusion, robustness, policy test
Diễn giải và khuyến nghị	15	14	Chương 6, capacity, giới hạn bằng chứng
Báo cáo và minh chứng	10	9	PDF, notebook có output, dashboard, metrics
Tổ chức nhóm	5	2	Đã có danh sách; phân công/tỷ lệ cần nhóm xác nhận
Tổng	100	91	Không tự chấm tối đa ở phần chưa hoàn tất

A.3 Cấu hình và siêu tham số chính

Thành phần	Cấu hình đã khóa
TF-IDF	2.000 đặc trưng, word n-gram (1,2), stopwords tiếng Anh, L_2 .
Text informative	Linear SVM $C = 3$, class weight balanced, sigmoid calibration 3-fold.
Text humanitarian	Logistic Regression $C = 1$, class weight balanced.
Image informative	k-NN $k = 41$, distance weighting, Euclidean trên CLIP normalized.
Image humanitarian	Logistic Regression $C = 1$, class weight balanced.
Decision Tree	max depth 20 trong vòng so sánh thuật toán.
Random Forest	200 cây, balanced subsample.
K-Means	$K = 2, \dots, 12$, $n_{init} = 10$; $K = 8$ để đối chiếu taxonomy.
Apriori	min support .005, min confidence .25 trên transaction đã lọc.
CLIP	openai/clip-vit-base-patch32, frozen, embedding 512 chiều.
Late Fusion	Informative text/image .70/.30, threshold .38; category .55/.45.
Manual Review	Conflict threshold .54, capacity dev tối đa 25%.

A.4 Tập minh chứng và khả năng tái lập

- Notebook đã thực thi: notebooks/02_edu.ipynb và 03_modeling.ipynb.
- Kiểm tra dữ liệu: reports/metrics/data_quality_summary.json và data/processed/split_integrity.csv.
- Tuning và kết quả: reports/metrics/*_tuning.csv, tuned_model_summary.json và các bảng fusion.
- Robustness: canonical/robust comparison, bootstrap, event và class stability trong reports/metrics/.
- DSS: dss_scenarios.csv, dss_threshold_sensitivity.csv.
- Kiểm thử: 41 unit test, 6 Streamlit AppTest và integration ảnh thật.
- Mã nguồn: <https://github.com/dafiiscoding/ml-dss>.

A.5 Thông tin còn cần nhóm xác nhận

Tên, MSSV, giảng viên và nhóm đã được điền ở đầu báo cáo. Trước khi nộp chính thức, nhóm cần phân công các gói công việc và điền tỷ lệ đóng góp thực tế tại `docs/team_info.json`; tổng tỷ lệ của bốn thành viên cần bằng 100%.

Tài liệu tham khảo

- [1] Daniel J. Power. *Decision Support Systems: Concepts and Resources for Managers*. Quorum Books, 2002.
- [2] Herbert A. Simon. *The New Science of Management Decision*. Harper & Brothers, 1960.
- [3] Firoj Alam, Ferda Ofli, Muhammad Imran. *CrisisMMD: Multimodal Twitter Datasets from Natural Disasters*. ICWSM, 2018. <https://crisisnlp.qcri.org/crisismmd>
- [4] Ferda Ofli, Firoj Alam, Muhammad Imran. *Analysis of Social Media Data using Multimodal Deep Learning for Disaster Response*. ISCRAM, 2020.
- [5] Alec Radford et al. *Learning Transferable Visual Models From Natural Language Supervision (CLIP)*. ICML, 2021.
- [6] Gerard Salton and Christopher Buckley. *Term-weighting approaches in automatic text retrieval*. Information Processing & Management, 24(5), 1988.
- [7] Corinna Cortes and Vladimir Vapnik. *Support-vector networks*. Machine Learning, 20, 1995.
- [8] Leo Breiman. *Random Forests*. Machine Learning, 45, 2001.
- [9] J. MacQueen. *Some Methods for Classification and Analysis of Multivariate Observations*. Proceedings of the Fifth Berkeley Symposium, 1967.
- [10] Rakesh Agrawal and Ramakrishnan Srikant. *Fast Algorithms for Mining Association Rules*. Proceedings of VLDB, 1994.
- [11] Laurens van der Maaten and Geoffrey Hinton. *Visualizing Data using t-SNE*. Journal of Machine Learning Research, 2008.
- [12] Pedregosa et al. *Scikit-learn: Machine Learning in Python*. JMLR, 2011.
- [13] Sebastian Raschka. *MLxtend: Providing machine learning and data science utilities and extensions to Python's scientific computing stack*. JOSS, 2018.
- [14] Slide bài giảng và hướng dẫn bài tập nhóm học phần Hệ hỗ trợ quyết định do TS. Lê Hải Hà cung cấp, học kỳ 2025.2.